



ΤΜΗΜΑ ΕΦΑΡΜΟΣΜΕΝΗΣ ΠΛΗΡΟΦΟΡΙΚΗΣ

ΚΑΤΕΥΘΥΝΣΗ ΠΛΗΡΟΦΟΡΙΑΚΑ ΣΥΣΤΗΜΑΤΑ

Πτυχιακή Εργασία

Αξιοποίηση Τεχνικών Μηχανικής Μάθησης για την Παραγωγή

Πινάκων DMN

της

Ιορδάνας Κουιμτζίδου

Επιβλέπων Καθηγητής: Κωνσταντίνος Βεργίδης

Θεσσαλονίκη, Ιούνιος 2026

Πίνακας Περιεχομένων

Κεφάλαιο 1: Εισαγωγή	7
1.1 Περιγραφή του θέματος.....	7
1.2 Αντικείμενο και στόχοι της μελέτης	8
1.3 Περιεχόμενα της μελέτης	9
Κεφάλαιο 2: Βιβλιογραφική Ανασκόπηση	11
2.1 Χρήση τεχνικών μηχανικής μάθησης σε συστήματα BPM	11
2.2 Κανόνες απόφασης και επιχειρησιακή λογική	12
2.3 Πίνακες αποφάσεων και το πρότυπο DMN	12
2.4 Εξαγωγή κανόνων από μοντέλα μηχανικής μάθησης	13
2.5 Αλγόριθμοι CART και PRISM για την παραγωγή κανόνων	14
Κεφάλαιο 3: Μοντελοποίηση αποφάσεων με DMN: Ενοποίηση με BPMN	16
3.1 Διαχείριση Επιχειρησιακών Διαδικασιών (BPM)	16
3.2 Μοντελοποίηση με BPMN και DMN	17
3.3 Δομή και Επίπεδα Αναπαράστασης της DMN	20
3.4 Επίπεδο Απαιτήσεων Απόφασης (Decision Requirements Level)	23
3.5 Επίπεδο Λογικής Απόφασης (Decision Logic Level)	27
3.6 Υπηρεσία Απόφασης (Decision Service)	32
3.7 Σύνοψη	34
Κεφάλαιο 4: Δέντρα Απόφασης	35
4.1 Εισαγωγή στα Δέντρα Απόφασης	35
4.2 Βασικές Αρχές Λειτουργίας.....	36
4.3 Δομή Δέντρων Απόφασης.....	36
4.4 Διαδικασία Εκπαίδευσης του Δέντρου Απόφασης	40
4.5 Κλάδεμα (Pruning).....	44
4.6 Παράδειγμα Διαδικασίας Εκπαίδευσης Δέντρου Απόφασης.....	45
4.7 Αξιολόγηση Απόδοσης.....	47
4.8 Σύνοψη	50
Κεφάλαιο 5: Αλγόριθμος CART	51
5.1 Ερευνητικό πρόβλημα	51
5.2 Ο Αλγόριθμος CART για Εξαγωγή Κανόνων	52
5.3 Μεθοδολογία Εξαγωγής Κανόνων με τον CART	53
5.4 Πλεονεκτήματα του CART	55
5.5 Περιορισμοί του CART	56

5.6 Εφαρμογή της μεθόδου.....	57
5.7 Σύνοψη	67
Κεφάλαιο 6: Αλγόριθμος PRISM	69
6.1 Εισαγωγή στις Μεθόδους Επαγωγής Κανόνων	69
6.2 Ο Αλγόριθμος PRISM για Εξαγωγή Κανόνων	70
6.3 Μεθοδολογία Εξαγωγής Κανόνων με τον PRISM	71
6.4 Πλεονεκτήματα του PRISM	74
6.5 Περιορισμοί του PRISM	74
6.6 Θεωρητική εφαρμογή του PRISM	75
6.7 Πρακτική εφαρμογή του PRISM	81
6.8 Σύνοψη	91
Κεφάλαιο 7: Πειραματική Αξιολόγηση PRISM και CART σε Συνθετικό Σύνολο Δεδομένων	92
7.1 Σχεδιασμός Πειραματικού Πλαισίου.....	92
7.2 Σκοπός Πειραματικής Διαδικασίας	96
7.3 Εφαρμογή του Αλγορίθμου PRISM	97
7.4 Αξιολόγηση των Παραγόμενων Κανόνων PRISM.....	101
7.5 Εφαρμογή του Αλγορίθμου CART	102
7.6 Αξιολόγηση των Παραγόμενων Κανόνων CART.....	106
7.7 Συγκριτική Αποτίμηση PRISM και CART	110
7.8 Σύνοψη	112
Κεφάλαιο 8: Πειραματική Αξιολόγηση PRISM και CART σε Πραγματικό Σύνολο Δεδομένων	113
8.1 Σχεδιασμός Πειραματικού Πλαισίου.....	113
8.2 Σκοπός της Πειραματικής Διαδικασίας	116
8.3 Εφαρμογή του Αλγορίθμου PRISM	117
8.4 Αξιολόγηση των κανόνων PRISM	123
8.5 Εφαρμογή του Αλγορίθμου CART	125
8.6 Αξιολόγηση των κανόνων CART	127
8.7 Συγκριτική Αποτίμηση PRISM και CART	129
8.8 Σύνοψη	131
Κεφάλαιο 9: Συμπεράσματα	133
9.1 Ανασκόπηση εργασίας	133
9.2 Συνεισφορά έρευνας	135
9.3 Περιορισμοί έρευνας και μελλοντική κατεύθυνση.....	136
9.4 Σύνοψη	137

ΒΙΒΛΙΟΓΡΑΦΙΑ.....	139
--------------------------	------------

Κατάλογος Εικόνων

Εικόνα 3. 1 Μοντελοποίηση επιχειρησιακής διαδικασίας σε BPMN	17
Εικόνα 3. 2 Παράδειγμα “spaghetti-like” διαγράμματος	18
Εικόνα 3. 3 Διασύνδεση BPMN και DMN	20
Εικόνα 3. 4 Επίπεδα αναπαράστασης της DMN	22
Εικόνα 3. 5 Βασικά Στοιχεία DRD Διαγράμματος	23
Εικόνα 3. 6 Παράδειγμα υποαπόφασης σε DRD διάγραμμα	24
Εικόνα 3. 7 Ενδεικτικό Διάγραμμα DRD	26
Εικόνα 3. 8 Παράδειγμα Πίνακα Αποφάσεων	29
Εικόνα 3. 9 Παράδειγμα Boxed Expression τύπου Context	31
Εικόνα 3. 10 Υπηρεσία Απόφασης	32
Εικόνα 3.11 Υπηρεσία απόφασης με εισερχόμενη απόφαση	33
Εικόνα 4. 1 Δομή δέντρου απόφασης	36
Εικόνα 4. 2 Παράδειγμα λειτουργίας δέντρου απόφασης	37
Εικόνα 4. 3 Παράδειγμα δυαδικού δέντρου απόφασης	38
Εικόνα 4. 4 Παράδειγμα πολυκατηγορικού δέντρου απόφασης	39
Εικόνα 4. 5 Παράδειγμα πολυκατηγορικού δέντρου απόφασης	45
Εικόνα 5. 1 Οι 10 πρώτες εγγραφές του Iris Set	57
Εικόνα 5. 2 Παραγόμενο Δέντρο Απόφασης	58
Εικόνα 5. 3 Παραγόμενος Πίνακας αποφάσεων	65
Εικόνα 6. 1 Πίνακας Αποφάσεων DMN	90
Εικόνα 7. 1 Πίνακας Αποφάσεων του αλγορίθμου PRISM	101
Εικόνα 7. 2 Παραγόμενο Δέντρο Απόφασης	103
Εικόνα 7. 3 Πίνακας Αποφάσεων του αλγορίθμου CART	105
Εικόνα 8. 1 Πίνακας Αποφάσεων του αλγορίθμου PRISM	124
Εικόνα 8. 2 Παραγόμενο Δέντρο Απόφασης από τον αλγόριθμο CART	126
Εικόνα 8. 3 Πίνακας Αποφάσεων του αλγορίθμου CART	128

Κατάλογος Πινάκων

Πίνακας 4. 1 Παράδειγμα συνόλου εκπαίδευσης (Training Set)	44
Πίνακας 6. 1 Αρχικό Σύνολο Εκπαίδευσης Play Tennis	75
Πίνακας 6. 2 Περιορισμένο Σύνολο Εκπαίδευσης Play Tennis	76
Πίνακας 6. 3 Νέο Σύνολο Εκπαίδευσης Play Tennis	77
Πίνακας 6. 4 Περιορισμένο Σύνολο Εκπαίδευσης Play Tennis	79
Πίνακας 6. 5 Τελικό Σύνολο Εκπαίδευσης Play Tennis για την Κλάση Yes	80
Πίνακας 7. 1 Παρουσίαση Ενδεικτικών Εγγραφών	95
Πίνακας 7. 2 Ενδεικτικές εγγραφές μετά τη διακριτοποίηση	98
Πίνακας 8. 1 Παρουσίαση Ενδεικτικών Εγγραφών	115
Πίνακας 8. 2 Όρια διακριτοποίησης των μεταβλητών	118
Πίνακας 8. 3 Παρουσίαση Ενδεικτικών Εγγραφών του Διακριτοποιημένου Dataset	120

Κεφάλαιο 1: Εισαγωγή

1.1 Περιγραφή του θέματος

Η ανάπτυξη πληροφοριακών συστημάτων που υποστηρίζουν τη λήψη αποφάσεων αποτελεί βασικό στοιχείο της λειτουργίας των σύγχρονων οργανισμών. Οι επιχειρησιακές διαδικασίες συχνά περιλαμβάνουν σημεία στα οποία πρέπει να ληφθούν αποφάσεις με βάση συγκεκριμένα δεδομένα ή κανόνες. Η σωστή διαμόρφωση των κανόνων αυτών είναι ιδιαίτερα σημαντική, καθώς επηρεάζει άμεσα την αποτελεσματικότητα και την ποιότητα των επιχειρησιακών διαδικασιών.

Στο πλαίσιο των συστημάτων διαχείρισης επιχειρησιακών διαδικασιών (Business Process Management – BPM), η λογική λήψης αποφάσεων αναπαρίσταται συχνά μέσω πινάκων αποφάσεων. Οι πίνακες αυτοί οργανώνουν τις συνθήκες και τα αποτελέσματα σε μια δομημένη μορφή κανόνων, επιτρέποντας τη σαφή περιγραφή της επιχειρησιακής λογικής και την ενσωμάτωσή της σε πληροφοριακά συστήματα. Για την τυποποιημένη μοντελοποίηση τέτοιων κανόνων χρησιμοποιείται το πρότυπο Decision Model and Notation (DMN), το οποίο επιτρέπει την αναπαράσταση και την εκτέλεση επιχειρησιακών αποφάσεων.

Στην πράξη, οι πίνακες αποφάσεων δημιουργούνται συχνά χειροκίνητα από επιχειρησιακούς αναλυτές. Οι αναλυτές αυτοί καθορίζουν τις συνθήκες και τα αποτελέσματα των κανόνων με βάση τη γνώση τους για τη λειτουργία της διαδικασίας και τα δεδομένα που είναι διαθέσιμα. Ωστόσο, η διαδικασία αυτή μπορεί να οδηγήσει σε κανόνες που δεν αξιοποιούν πλήρως τη γνώση που περιέχεται στα δεδομένα ή που ενδέχεται να μην αντανακλούν με ακρίβεια τα πραγματικά πρότυπα που εμφανίζονται στις επιχειρησιακές διαδικασίες.

Τα τελευταία χρόνια, η ανάπτυξη τεχνικών μηχανικής μάθησης έχει δημιουργήσει νέες δυνατότητες για την ανάλυση δεδομένων και την εξαγωγή γνώσης από αυτά. Οι τεχνικές αυτές επιτρέπουν την ανακάλυψη προτύπων μέσα σε σύνολα δεδομένων και μπορούν να χρησιμοποιηθούν για την παραγωγή κανόνων που περιγράφουν τις σχέσεις μεταξύ των χαρακτηριστικών, των δεδομένων και των αποτελεσμάτων. Οι κανόνες αυτοί μπορούν να αξιοποιηθούν για τη βελτίωση της διαδικασίας λήψης αποφάσεων και για την υποστήριξη της ανάλυσης επιχειρησιακών κανόνων.

Ιδιαίτερο ενδιαφέρον παρουσιάζουν οι τεχνικές που μπορούν να παράγουν ερμηνεύσιμους κανόνες, όπως τα δέντρα αποφάσεων και οι αλγόριθμοι επαγωγής κανόνων. Μέσω τέτοιων τεχνικών είναι δυνατόν να εξαχθούν κανόνες της μορφής *if-then*, οι οποίοι μπορούν να συγκριθούν με τους υπάρχοντες επιχειρησιακούς κανόνες και να χρησιμοποιηθούν για την αξιολόγηση της συνέπειας μεταξύ δεδομένων και επιχειρησιακής λογικής. Επιπλέον, οι μέθοδοι αυτοί έχουν τη δυνατότητα να εξαγάγουν τους κανόνες αυτόματα από τα δεδομένα, χωρίς να απαιτείται η χειροκίνητη διατύπωση κανόνων από τον αναλυτή. Με τον τρόπο αυτό μειώνεται η ανθρώπινη παρέμβαση στη διαδικασία δημιουργίας κανόνων και διευκολύνεται η αξιοποίηση των δεδομένων για την υποστήριξη της λήψης αποφάσεων.

1.2 Αντικείμενο και στόχοι της μελέτης

Το αντικείμενο της παρούσας μελέτης είναι η διερεύνηση της χρήσης τεχνικών μηχανικής μάθησης για την εξαγωγή κανόνων από δεδομένα και τη μετατροπή τους σε μορφή που μπορεί να αξιοποιηθεί σε συστήματα επιχειρησιακών αποφάσεων.

Συγκεκριμένα, η εργασία εξετάζει τη χρήση τεχνικών που μπορούν να παράγουν κανόνες από δεδομένα και να τους αποτυπώσουν σε μορφή που είναι συμβατή με πίνακες αποφάσεων DMN. Οι κανόνες αυτοί μπορούν στη συνέχεια να συγκριθούν με υπάρχοντες επιχειρησιακούς κανόνες ή να χρησιμοποιηθούν για την υποστήριξη της διαδικασίας ανάλυσης και επικύρωσης της επιχειρησιακής λογικής.

Για την επίτευξη αυτού του στόχου, διερευνώνται δύο διαφορετικές προσεγγίσεις για την παραγωγή κανόνων από δεδομένα. Η πρώτη προσέγγιση βασίζεται σε δέντρα αποφάσεων και ειδικότερα στον αλγόριθμο CART, ο οποίος δημιουργεί μια ιεραρχική δομή αποφάσεων από την οποία μπορούν να εξαχθούν κανόνες. Η δεύτερη προσέγγιση βασίζεται στον αλγόριθμο PRISM, ο οποίος ανήκει στην κατηγορία των αλγορίθμων επαγωγής κανόνων και δημιουργεί κανόνες απευθείας από τα δεδομένα.

Οι βασικοί στόχοι της εργασίας είναι οι εξής:

- η μελέτη τεχνικών εξαγωγής κανόνων από δεδομένα,
- η μετατροπή των κανόνων που παράγονται από μοντέλα μηχανικής μάθησης σε πίνακες αποφάσεων,
- η διερεύνηση της δυνατότητας αξιοποίησης των κανόνων αυτών σε περιβάλλοντα επιχειρησιακών διαδικασιών,
- η σύγκριση διαφορετικών μεθόδων παραγωγής κανόνων ως προς τη δομή και τα χαρακτηριστικά τους.

Μέσω της ανάλυσης αυτής επιδιώκεται η διερεύνηση της δυνατότητας σύνδεσης τεχνικών μηχανικής μάθησης με συστήματα διαχείρισης επιχειρησιακών αποφάσεων, με στόχο την αξιοποίηση δεδομένων για την υποστήριξη, την ανάλυση και την επικύρωση επιχειρησιακών κανόνων.

1.3 Περιεχόμενα της μελέτης

Στην ενότητα αυτή παρουσιάζεται συνοπτικά το περιεχόμενο των κεφαλαίων της παρούσας πτυχιακής εργασίας, προκειμένου να δοθεί μια συνολική εικόνα της δομής και της οργάνωσης της μελέτης.

Το **Κεφάλαιο 1** εισάγει το θέμα της εργασίας και παρουσιάζει το γενικό πλαίσιο της μελέτης. Περιγράφεται η σημασία των συστημάτων λήψης αποφάσεων στις επιχειρησιακές διαδικασίες, καθώς και ο ρόλος των πινάκων αποφάσεων και των επιχειρησιακών κανόνων. Επιπλέον, παρουσιάζονται το αντικείμενο και οι βασικοί στόχοι της έρευνας.

Το **Κεφάλαιο 2** περιλαμβάνει τη βιβλιογραφική ανασκόπηση σχετικά με τη χρήση τεχνικών μηχανικής μάθησης σε συστήματα διαχείρισης επιχειρησιακών διαδικασιών (BPM). Παρουσιάζεται ο τρόπος με τον οποίο τα δεδομένα που παράγονται από τις επιχειρησιακές διαδικασίες μπορούν να αξιοποιηθούν για την υποστήριξη της διαδικασίας λήψης αποφάσεων.

Το **Κεφάλαιο 3** παρουσιάζει τα πρότυπα μοντελοποίησης επιχειρησιακών διαδικασιών και αποφάσεων, με ιδιαίτερη έμφαση στη συνεργασία των προτύπων BPMN και DMN. Αναλύεται πώς η συνδυαστική χρήση τους επιτρέπει τη σαφή αναπαράσταση της επιχειρησιακής λογικής και τη διαχείριση των διαδικασιών σε οργανισμούς.

Το **Κεφάλαιο 4** αναλύει τη μέθοδο των δέντρων απόφασης, η οποία αποτελεί μία από τις βασικές τεχνικές μηχανικής μάθησης για προβλήματα ταξινόμησης και παλινδρόμησης. Παρουσιάζονται η δομή τους, η διαδικασία εκπαίδευσης, καθώς και τα βασικά χαρακτηριστικά που τα καθιστούν κατάλληλα για την υποστήριξη της λήψης αποφάσεων.

Το **Κεφάλαιο 5** παρουσιάζει τον αλγόριθμο CART, ο οποίος αποτελεί μία από τις πιο διαδεδομένες υλοποιήσεις δέντρων απόφασης. Αναλύεται η διαδικασία κατασκευής του μοντέλου, ο τρόπος επιλογής των χαρακτηριστικών, η παραγωγή κανόνων ταξινόμησης από τη δομή του δέντρου και η μετατροπή τους σε πίνακες αποφάσεων σύμφωνα με το πρότυπο DMN.

Το **Κεφάλαιο 6** περιγράφει τον αλγόριθμο PRISM, ο οποίος ανήκει στις μεθόδους επαγωγής κανόνων και δημιουργεί κανόνες απόφασης απευθείας από τα δεδομένα. Παρουσιάζεται η διαδικασία παραγωγής των κανόνων καθώς και η μετατροπή τους σε πίνακες αποφάσεων σύμφωνα με το πρότυπο DMN.

Το **Κεφάλαιο 7** παρουσιάζει την πειραματική αξιολόγηση των αλγορίθμων CART και PRISM σε ένα συνθετικό σύνολο δεδομένων που αφορά την έγκριση ή την απόρριψη ενός δανείου. Στο πλαίσιο αυτό εφαρμόζονται οι δύο προσεγγίσεις για την εξαγωγή κανόνων απόφασης και τα αποτελέσματα μετατρέπονται σε πίνακες αποφάσεων DMN, ώστε να συγκριθούν τα χαρακτηριστικά και η δομή των παραγόμενων κανόνων.

Το **Κεφάλαιο 8** παρουσιάζει την πειραματική αξιολόγηση των αλγορίθμων CART και PRISM σε πραγματικό σύνολο δεδομένων που αφορά την πρόβλεψη αθέτησης δανείων. Περιγράφεται η διαδικασία προεπεξεργασίας των δεδομένων και η εφαρμογή των αλγορίθμων για την εξαγωγή κανόνων ταξινόμησης. Οι κανόνες αυτοί μετατρέπονται σε πίνακες αποφάσεων σύμφωνα με το πρότυπο DMN και πραγματοποιείται σύγκριση των αποτελεσμάτων των δύο προσεγγίσεων.

Τέλος, στο **Κεφάλαιο 9** παρουσιάζονται τα βασικά συμπεράσματα της εργασίας, συνοψίζονται τα αποτελέσματα και οι περιορισμοί της έρευνας και προτείνονται πιθανές κατευθύνσεις για μελλοντική έρευνα.

Κεφάλαιο 2: Βιβλιογραφική Ανασκόπηση

Το κεφάλαιο αυτό παρουσιάζει το θεωρητικό υπόβαθρο στο οποίο βασίζεται η παρούσα εργασία. Αρχικά εξετάζεται η αξιοποίηση τεχνικών μηχανικής μάθησης σε συστήματα διαχείρισης επιχειρησιακών διαδικασιών (BPM) και ο ρόλος των κανόνων απόφασης στην υποστήριξη της επιχειρησιακής λογικής. Στη συνέχεια παρουσιάζονται οι πίνακες αποφάσεων και το πρότυπο DMN, καθώς και οι τεχνικές εξαγωγής κανόνων από μοντέλα μηχανικής μάθησης. Τέλος, αναλύονται οι αλγόριθμοι CART και PRISM, οι οποίοι χρησιμοποιούνται στην εργασία για την παραγωγή κανόνων από δεδομένα και τη μετατροπή τους σε πίνακες αποφάσεων DMN.

2.1 Χρήση τεχνικών μηχανικής μάθησης σε συστήματα BPM

Τα τελευταία χρόνια η αξιοποίηση τεχνικών μηχανικής μάθησης σε πληροφοριακά συστήματα επιχειρήσεων έχει αυξηθεί σημαντικά. Η συνεχής παραγωγή μεγάλου όγκου δεδομένων από τις επιχειρησιακές διαδικασίες των οργανισμών δημιουργεί την ανάγκη για μεθόδους ανάλυσης που μπορούν να αξιοποιήσουν τα δεδομένα αυτά για την υποστήριξη της λήψης αποφάσεων (Marrella, 2019). Στο πλαίσιο αυτό, ιδιαίτερο ενδιαφέρον παρουσιάζει η εφαρμογή τεχνικών μηχανικής μάθησης σε συστήματα διαχείρισης επιχειρησιακών διαδικασιών (Business Process Management – BPM).

Τα συστήματα BPM χρησιμοποιούνται για τη μοντελοποίηση, την εκτέλεση και τη βελτιστοποίηση επιχειρησιακών διαδικασιών (Dumas et al., 2018). Η προσέγγιση BPM υποστηρίζει τον πλήρη κύκλο ζωής των επιχειρησιακών διαδικασιών, από τον σχεδιασμό και την υλοποίηση έως την παρακολούθηση και τη συνεχή βελτίωσή τους (Weske, 2012). Μέσω αυτών των συστημάτων οι οργανισμοί μπορούν να οργανώσουν τις διαδικασίες τους σε δομημένες ακολουθίες δραστηριοτήτων και να αυτοματοποιήσουν σημαντικά τμήματα της λειτουργίας τους. Παράλληλα, τα συστήματα BPM συλλέγουν δεδομένα σχετικά με την εκτέλεση των διαδικασιών, τα οποία μπορούν να χρησιμοποιηθούν για την ανάλυση της απόδοσης και τη βελτίωση των διαδικασιών (van der Aalst, 2011).

Η ενσωμάτωση τεχνικών μηχανικής μάθησης σε περιβάλλοντα BPM επιτρέπει την αξιοποίηση των δεδομένων που παράγονται κατά την εκτέλεση των διαδικασιών. Μέσω της ανάλυσης αυτών των δεδομένων είναι δυνατόν να εντοπιστούν πρότυπα και σχέσεις που μπορούν να υποστηρίξουν τη λήψη αποφάσεων ή να συμβάλουν στη βελτιστοποίηση των διαδικασιών. Οι τεχνικές αυτές χρησιμοποιούνται σε διάφορες εφαρμογές, όπως η πρόβλεψη αποτελεσμάτων διαδικασιών, η ανίχνευση αποκλίσεων από τις αναμενόμενες ροές εργασίας και η υποστήριξη της λήψης αποφάσεων μέσα στις επιχειρησιακές διαδικασίες.

Παρά τα σημαντικά πλεονεκτήματα των τεχνικών μηχανικής μάθησης, η ενσωμάτωσή τους σε επιχειρησιακά συστήματα παρουσιάζει ορισμένες προκλήσεις. Σε πολλές

περιπτώσεις οι οργανισμοί χρειάζονται μοντέλα των οποίων η λογική μπορεί να γίνει κατανοητή από ανθρώπους, ιδιαίτερα όταν οι αποφάσεις επηρεάζουν κρίσιμες επιχειρησιακές λειτουργίες. Για τον λόγο αυτό, ιδιαίτερη σημασία έχουν τα μοντέλα που μπορούν να αποδώσουν τα αποτελέσματά τους σε μορφή κανόνων.

2.2 Κανόνες απόφασης και επιχειρησιακή λογική

Οι κανόνες απόφασης αποτελούν έναν από τους πιο διαδεδομένους τρόπους αναπαράστασης γνώσης σε πληροφοριακά συστήματα. Ένας κανόνας απόφασης εκφράζεται συνήθως με τη μορφή if-then και περιγράφει τις συνθήκες υπό τις οποίες λαμβάνεται μια συγκεκριμένη απόφαση. Οι κανόνες αυτοί επιτρέπουν την περιγραφή της σχέσης μεταξύ των χαρακτηριστικών των δεδομένων και των αποτελεσμάτων που προκύπτουν.

Στα επιχειρησιακά συστήματα οι κανόνες χρησιμοποιούνται συχνά για την υλοποίηση επιχειρησιακών πολιτικών και διαδικασιών λήψης αποφάσεων (Dumas et al., 2018). Για παράδειγμα, ένας οργανισμός μπορεί να χρησιμοποιεί κανόνες για την αξιολόγηση αιτήσεων, την έγκριση συναλλαγών ή τη διαχείριση κινδύνου. Η χρήση κανόνων επιτρέπει τη σαφή αποτύπωση της επιχειρησιακής λογικής και διευκολύνει την κατανόηση και τη συντήρηση των συστημάτων.

Η δημιουργία και η διαχείριση κανόνων αποτελούν σημαντικό μέρος της λειτουργίας των συστημάτων υποστήριξης αποφάσεων. Ωστόσο, σε πολλές περιπτώσεις οι κανόνες αυτοί δημιουργούνται χειροκίνητα από αναλυτές, γεγονός που μπορεί να οδηγήσει σε περιορισμούς ως προς την αξιοποίηση των διαθέσιμων δεδομένων. Για τον λόγο αυτό, αρκετές ερευνητικές εργασίες έχουν εξετάσει τη δυνατότητα εξαγωγής κανόνων απευθείας από δεδομένα μέσω τεχνικών μηχανικής μάθησης (D. Etinger et al., 2019).

Η εξαγωγή κανόνων από δεδομένα επιτρέπει την ανακάλυψη προτύπων που ενδέχεται να μην είναι εύκολα αντιληπτά από ανθρώπους (Han et al., 2011). Οι αλγόριθμοι ταξινόμησης χρησιμοποιούνται ευρέως για την αναγνώριση τέτοιων προτύπων και την υποστήριξη προβλέψεων σε νέα δεδομένα, αποτελώντας βασικό πεδίο εφαρμογής της μηχανικής μάθησης (Kotsiantis, 2011). Οι κανόνες που προκύπτουν από τέτοιες τεχνικές μπορούν να χρησιμοποιηθούν για την κατανόηση των δεδομένων, την υποστήριξη της λήψης αποφάσεων και τη βελτίωση των επιχειρησιακών διαδικασιών.

2.3 Πίνακες αποφάσεων και το πρότυπο DMN

Για την αναπαράσταση επιχειρησιακών κανόνων σε πληροφοριακά συστήματα χρησιμοποιούνται συχνά πίνακες αποφάσεων. Οι πίνακες οργανώνουν τις συνθήκες και τα αποτελέσματα των κανόνων, επιτρέποντας τη σαφή και δομημένη παρουσίασή τους.

Σε έναν πίνακα αποφάσεων κάθε γραμμή αντιστοιχεί σε έναν κανόνα, ενώ οι στήλες αντιστοιχούν στις συνθήκες και στο αποτέλεσμα της απόφασης (Object Management Group, 2019). Η μορφή αυτή διευκολύνει την κατανόηση της επιχειρησιακής λογικής και επιτρέπει τη διαχείριση μεγάλου αριθμού κανόνων με συστηματικό τρόπο.

Για την τυποποιημένη μοντελοποίηση πινάκων αποφάσεων χρησιμοποιείται το πρότυπο Decision Model and Notation (DMN) (Object Management Group, 2019). Η DMN αποτελεί διεθνές πρότυπο για τη μοντελοποίηση και την εκτέλεση επιχειρησιακών αποφάσεων και χρησιμοποιείται ευρέως σε συστήματα BPM. Μέσω του προτύπου αυτού οι κανόνες μπορούν να οργανωθούν σε πίνακες αποφάσεων, οι οποίοι μπορούν να εκτελεστούν από πληροφοριακά συστήματα.

Οι πίνακες αποφάσεων DMN παρέχουν έναν τυποποιημένο τρόπο αναπαράστασης επιχειρησιακών κανόνων και διευκολύνουν τη σύνδεση μεταξύ της επιχειρησιακής λογικής και των πληροφοριακών συστημάτων. Η τυποποίηση αυτή συμβάλλει στη σαφή τεκμηρίωση των αποφάσεων, στη συνέπεια κατά την εφαρμογή των κανόνων και στη δυνατότητα επαναχρησιμοποίησής τους σε διαφορετικά πληροφοριακά συστήματα και επιχειρησιακά περιβάλλοντα. Επιπλέον, η δομημένη μορφή των πινάκων αποφάσεων διευκολύνει την επικοινωνία μεταξύ επιχειρησιακών αναλυτών και τεχνικών στελεχών, καθώς παρέχει μια κοινή και κατανοητή αναπαράσταση της επιχειρησιακής λογικής.

Παράλληλα, η αυξανόμενη διαθεσιμότητα δεδομένων που παράγονται κατά την εκτέλεση των επιχειρησιακών διαδικασιών έχει δημιουργήσει νέες δυνατότητες για την υποστήριξη της λήψης αποφάσεων μέσω τεχνικών ανάλυσης δεδομένων και μηχανικής μάθησης. Η αξιοποίηση των δεδομένων αυτών μπορεί να συμβάλει στην ανακάλυψη προτύπων και σχέσεων που δεν είναι άμεσα εμφανείς, υποστηρίζοντας τη δημιουργία, την αξιολόγηση και τη βελτίωση επιχειρησιακών κανόνων. Η ανάγκη αυτή έχει οδηγήσει στην ανάπτυξη μεθόδων που συνδυάζουν τεχνικές μηχανικής μάθησης με πίνακες αποφάσεων (D. Etinger et al., 2019).

2.4 Εξαγωγή κανόνων από μοντέλα μηχανικής μάθησης

Η εξαγωγή κανόνων από μοντέλα μηχανικής μάθησης αποτελεί σημαντικό αντικείμενο έρευνας στον τομέα της εξόρυξης δεδομένων (Fürnkranz, 1999). Οι τεχνικές αυτές επιτρέπουν τη μετατροπή των αποτελεσμάτων ενός μοντέλου μηχανικής μάθησης σε κανόνες που μπορούν να ερμηνευθούν από ανθρώπους.

Μία συνηθισμένη προσέγγιση είναι η εξαγωγή κανόνων από δέντρα αποφάσεων. Τα δέντρα αποφάσεων αποτελούν μία από τις πλέον διαδεδομένες τεχνικές ταξινόμησης, καθώς συνδυάζουν υψηλή ερμηνευσιμότητα με σχετικά απλή διαδικασία κατασκευής και αξιολόγησης (Safavian & Landgrebe, 1991). Κάθε διαδρομή από τη ρίζα έως ένα φύλλο του δέντρου αντιστοιχεί σε έναν κανόνα της μορφής if-then. Οι κανόνες αυτοί μπορούν να χρησιμοποιηθούν για την περιγραφή της λογικής του μοντέλου και για την κατανόηση των σχέσεων μεταξύ των

χαρακτηριστικών των δεδομένων (Quinlan, 1986). Επιπλέον, η ιεραρχική δομή των δέντρων αποφάσεων επιτρέπει την οπτική αναπαράσταση της διαδικασίας λήψης αποφάσεων, γεγονός που συμβάλλει στην ερμηνευσιμότητα των αποτελεσμάτων και στη δυνατότητα επαλήθευσης των κανόνων από τους χρήστες.

Πέρα από τα δέντρα αποφάσεων, σημαντική κατηγορία τεχνικών αποτελούν οι μέθοδοι επαγωγής κανόνων (rule induction). Οι μέθοδοι αυτές παράγουν άμεσα σύνολα κανόνων της μορφής if-then από τα δεδομένα εκπαίδευσης, χωρίς να απαιτείται η κατασκευή ενός ενδιάμεσου μοντέλου, όπως ένα δέντρο αποφάσεων. Στόχος τους είναι η ανακάλυψη σχέσεων μεταξύ των χαρακτηριστικών των δεδομένων και της μεταβλητής-στόχου, με τρόπο που να οδηγεί σε κανόνες εύκολα κατανοητούς από τον άνθρωπο (Fürnkranz, 1999).

Η δυνατότητα εξαγωγής κανόνων από μοντέλα μηχανικής μάθησης είναι ιδιαίτερα σημαντική σε εφαρμογές όπου απαιτείται ερμηνευσιμότητα των αποτελεσμάτων (Almutairi, 2022). Σε επιχειρησιακά περιβάλλοντα, οι κανόνες που προκύπτουν από δεδομένα μπορούν να συγκριθούν με τους υπάρχοντες επιχειρησιακούς κανόνες για τον έλεγχο της συνέπειας και της ορθότητάς τους, αλλά και να αξιοποιηθούν για την αυτόματη δημιουργία νέων κανόνων και πινάκων αποφάσεων, συμβάλλοντας στην ανάλυση, τη βελτίωση και την αυτοματοποίηση της επιχειρησιακής λογικής.

Η μετατροπή κανόνων που προκύπτουν είτε από δέντρα αποφάσεων είτε από μεθόδους επαγωγής κανόνων σε μορφή συμβατή με επιχειρησιακά συστήματα αποτελεί σημαντικό ερευνητικό πεδίο. Η διαδικασία αυτή επιτρέπει τη σύνδεση μεταξύ της ανάλυσης δεδομένων και των επιχειρησιακών διαδικασιών, διευκολύνοντας την αξιοποίηση των αποτελεσμάτων της μηχανικής μάθησης σε πραγματικά πληροφοριακά συστήματα.

2.5 Αλγόριθμοι CART και PRISM για την παραγωγή κανόνων

Μεταξύ των αλγορίθμων που χρησιμοποιούνται για την παραγωγή κανόνων από δεδομένα συγκαταλέγονται ο CART και ο PRISM. Οι δύο αυτοί αλγόριθμοι βασίζονται σε διαφορετικές προσεγγίσεις για τη δημιουργία κανόνων.

Ο αλγόριθμος CART (Classification and Regression Trees) αποτελεί μία από τις πιο γνωστές μεθόδους δημιουργίας δέντρων αποφάσεων. Ο αλγόριθμος αυτός δημιουργεί δυαδικά δέντρα αποφάσεων μέσω μιας διαδικασίας επαναληπτικής διάσπασης των δεδομένων. Σε κάθε βήμα επιλέγεται το χαρακτηριστικό και το κατώφλι τιμής που οδηγούν στον καλύτερο διαχωρισμό των δεδομένων. Μέσω αυτής της διαδικασίας δημιουργείται μια ιεραρχική δομή αποφάσεων από την οποία μπορούν να εξαχθούν κανόνες (Breiman et al., 1984).

Κάθε διαδρομή από τη ρίζα έως ένα φύλλο του δέντρου αντιστοιχεί σε έναν κανόνα απόφασης, ο οποίος περιγράφει τις συνθήκες υπό τις οποίες ένα παράδειγμα ταξινομείται σε μια συγκεκριμένη κατηγορία. Η δυνατότητα αυτή καθιστά τα δέντρα

αποφάσεων κατάλληλα για εφαρμογές όπου απαιτείται η κατανόηση της λογικής του μοντέλου.

Αντίθετα, ο αλγόριθμος PRISM ανήκει στην κατηγορία των αλγορίθμων επαγωγής κανόνων. Ο PRISM δημιουργεί κανόνες απευθείας από τα δεδομένα χωρίς να κατασκευάζει πρώτα ένα δέντρο αποφάσεων. Η διαδικασία βασίζεται στη σταδιακή επιλογή συνθηκών που μεγιστοποιούν την ακρίβεια ενός κανόνα για μια συγκεκριμένη κατηγορία (Cendrowska, 1987).

Το αποτέλεσμα της διαδικασίας είναι ένα σύνολο ανεξάρτητων κανόνων που περιγράφουν τις συνθήκες υπό τις οποίες ένα παράδειγμα ανήκει σε μια συγκεκριμένη κατηγορία. Οι κανόνες αυτοί μπορούν να χρησιμοποιηθούν για την κατανόηση των δεδομένων και για την υποστήριξη της λήψης αποφάσεων.

Η ύπαρξη διαφορετικών προσεγγίσεων για την παραγωγή κανόνων δημιουργεί ενδιαφέρον για τη σύγκριση των αποτελεσμάτων τους, ιδιαίτερα σε περιπτώσεις όπου οι κανόνες αυτοί πρόκειται να χρησιμοποιηθούν σε επιχειρησιακά συστήματα και να μετατραπούν σε πίνακες αποφάσεων (D. Ettinger et al., 2019).

Κεφάλαιο 3: Μοντελοποίηση αποφάσεων με DMN: Ενοποίηση με BPMN

Στο παρόν κεφάλαιο παρουσιάζονται οι βασικές αρχές της Διαχείρισης Επιχειρησιακών Διαδικασιών (BPM) και η σημασία της μοντελοποίησης μέσω BPMN και DMN για την αυτοματοποίηση και τεκμηρίωση της επιχειρησιακής λογικής. Εξετάζεται ο τρόπος με τον οποίο η BPMN αποτυπώνει τη ροή εργασιών, ενώ η DMN επικεντρώνεται στη λογική των αποφάσεων, προσφέροντας σαφήνεια, συνέπεια και δυνατότητα εκτέλεσης των επιχειρησιακών κανόνων. Μέσα από την ανάλυση των επιπέδων και των στοιχείων της DMN αναδεικνύεται ο τρόπος με τον οποίο επιτυγχάνεται η ολοκληρωμένη και διαφανής υποστήριξη της διαδικασίας λήψης αποφάσεων.

3.1 Διαχείριση Επιχειρησιακών Διαδικασιών (BPM)


Οι **επιχειρησιακές διαδικασίες (business processes)** αποτελούν τον πυρήνα κάθε οργανισμού, καθώς περιγράφουν τον τρόπο με τον οποίο οι άνθρωποι, οι δραστηριότητες και οι τεχνολογίες συνεργάζονται για την επίτευξη συγκεκριμένων επιχειρησιακών στόχων. Μια επιχειρησιακή διαδικασία (ΕΔ) ορίζεται ως ένα σύνολο διαδοχικών δραστηριοτήτων που ξεκινούν από τις ανάγκες ή τις απαιτήσεις του πελάτη ως παραμέτρους εισόδου και καταλήγουν στην παραγωγή προϊόντων ή υπηρεσιών που τις ικανοποιούν (επιθυμητό αποτέλεσμα). Κάθε επιχείρηση διαχειρίζεται πλήθος τέτοιων διαδικασιών σε καθημερινή βάση, όπως η διαχείριση παραγγελιών πελατών, η προμήθεια πρώτων υλών ή εμπορευμάτων, η παροχή υπηρεσιών υποστήριξης. Οι δραστηριότητες αυτές συχνά εκτείνονται σε διαφορετικά λειτουργικά τμήματα, όπως το Τμήμα Παραγωγής, το Μάρκετινγκ, την Εξυπηρέτηση Πελατών ή το Λογιστήριο, απαιτώντας αποτελεσματικό συντονισμό και ροή πληροφοριών για την ομαλή εκτέλεσή τους.

Η **Διαχείριση Επιχειρησιακών Διαδικασιών (Business Process Management – BPM)** αποτελεί μια συστηματική προσέγγιση που στοχεύει στη βελτιστοποίηση και συνεχή βελτίωση αυτών των διαδικασιών. Συνδυάζει μεθοδολογίες, τεχνολογίες και οργανωτικές πρακτικές, ώστε οι επιχειρησιακές διαδικασίες να ευθυγραμμίζονται με τους στρατηγικούς στόχους του οργανισμού. Ο κύκλος ζωής των διαδικασιών περιλαμβάνει τα στάδια: σχεδίαση, μοντελοποίηση, εκτέλεση, παρακολούθηση και βελτίωση, δημιουργώντας ένα πλαίσιο κατανόησης, ανάλυσης και ανασχεδιασμού των επιχειρησιακών διαδικασιών.

Κεντρικός πυλώνας της Διαχείρισης Επιχειρησιακών Διαδικασιών αποτελεί η μοντελοποίηση διαδικασιών, δηλαδή η οπτική αναπαράσταση των δραστηριοτήτων, των συμμετεχόντων και της ροής πληροφοριών μιας διαδικασίας. Η μοντελοποίηση συμβάλλει στην κατανόηση της συνολικής λειτουργίας, στον εντοπισμό σημείων βελτίωσης και στην υποστήριξη της αυτοματοποίησης και του ανασχεδιασμού. Το πιο ευρέως χρησιμοποιούμενο πρότυπο μοντελοποίησης είναι η **BPMN (Business Process Model and Notation)**, η οποία αναπτύχθηκε το 2004 και καθιερώθηκε από τον οργανισμό Object Management Group. Βασικός της στόχος είναι η γεφύρωση του

χάσματος μεταξύ επιχειρησιακής ανάλυσης και τεχνικής υλοποίησης, μέσω μιας κοινής οπτικής γλώσσας, κατανοητής τόσο από επιχειρησιακούς όσο και από τεχνικούς χρήστες.

Η BPMN παρέχει έναν τυποποιημένο και σαφή τρόπο απεικόνισης δραστηριοτήτων, γεγονότων και ροών ελέγχου, επιτρέποντας τη συστηματική τεκμηρίωση, την ανάλυση και την αξιολόγηση της απόδοσης των διαδικασιών. Με τον τρόπο αυτό, ενισχύεται η επικοινωνία μεταξύ των εμπλεκόμενων μερών και βελτιώνεται η συνολική αποτελεσματικότητα του οργανισμού.



Εικόνα 3. 1 Μοντελοποίηση επιχειρησιακής διαδικασίας σε BPMN


Η εικόνα 3.1 παρουσιάζει ένα παράδειγμα επιχειρησιακής διαδικασίας μοντελοποιημένης σε BPMN. Το διάγραμμα απεικονίζει τη ροή ενεργειών για τον προγραμματισμό ενός σεμιναρίου, ξεκινώντας από το γεγονός έναρξης (start event) και περιλαμβάνοντας δραστηριότητες (activities), πύλες απόφασης (gateways) που καθορίζουν την πορεία της διαδικασίας ανάλογα με τον τύπο του σεμιναρίου και την χρονική απόσταση από την ημερομηνία διεξαγωγής, καθώς και γεγονός λήξης (end event) που σηματοδοτεί την ολοκλήρωσή της. Μέσω της μοντελοποίησης καθίσταται δυνατή η κατανόηση της ροής εργασίας, η αναγνώριση πιθανών σημείων βελτίωσης και η υποστήριξη της αυτοματοποίησης της διαδικασίας.

3.2 Μοντελοποίηση με BPMN και DMN

Κατά την εκτέλεση επιχειρησιακών διαδικασιών, προκύπτουν συχνά σημεία όπου απαιτείται η λήψη απόφασης για τη συνέχιση της ροής. Μια απόφαση βασίζεται σε συγκεκριμένες εισροές δεδομένων και κανόνες, ώστε να προσδιοριστεί το κατάλληλο αποτέλεσμα σε κάθε περίπτωση. Σε πιο σύνθετα επιχειρησιακά σενάρια, οι

αποφάσεις αυτές δεν είναι απλές ή μεμονωμένες. Αντίθετα, εμπλέκουν πολλαπλές συνθήκες, δεδομένα και κανόνες που συνδυάζονται για την επίτευξη ενός συγκεκριμένου αποτελέσματος. Η πολυπλοκότητα αυτή καθιστά απαραίτητη τη μοντελοποίηση της λογικής των αποφάσεων με τρόπο σαφή, κατανοητό και επαναχρησιμοποιήσιμο.

Παραδοσιακά, οι αποφάσεις υλοποιούνται εσωτερικά στα μοντέλα διαδικασιών BPMN, συνήθως μέσω ροών υπό όρους (conditional flows) ή δραστηριοτήτων τύπου Business Rule Task. Ωστόσο, η ενσωμάτωση της λογικής των αποφάσεων μέσα στην BPMN οδηγεί σε διαγράμματα με αυξημένη πολυπλοκότητα, γνωστά ως “spaghetti-like diagrams”, εξαιτίας των πολλαπλών διαδρομών και εξαρτήσεων που δημιουργούνται. Αυτή η πρακτική δυσχεραίνει τόσο την κατανόηση όσο και τη συντήρηση των μοντέλων, καθώς η επιχειρησιακή λογική «κρύβεται» στο εσωτερικό των ροών και δεν μπορεί να αναλυθεί ή να επαναχρησιμοποιηθεί αυτόνομα.



Εικόνα 3. 2 Παράδειγμα “spaghetti-like” διαγράμματος

Το παραπάνω σχήμα απεικονίζει ένα παράδειγμα υπερβολικά πολύπλοκου διαγράμματος BPMN, γνωστού ως “spaghetti-like” διάγραμμα. Σε τέτοιες περιπτώσεις, η λογική των αποφάσεων είναι ενσωματωμένη μέσα στη ροή της διαδικασίας μέσω πολλαπλών πυλών (gateways) και διασταυρούμενων διαδρομών, γεγονός που καθιστά το μοντέλο δυσανάγνωστο και δύσκολο στη συντήρηση και στην κατανόηση.

Για την αντιμετώπιση αυτού του ζητήματος, προτείνεται ο διαχωρισμός της λογικής των αποφάσεων από τη ροή των διαδικασιών. Αντί οι αποφάσεις να ενσωματώνονται ως μέρος των δραστηριοτήτων BPMN, μπορούν να αντιμετωπίζονται ως ανεξάρτητες

οντότητες με δική τους μοντελοποίηση, σαφή ορισμό εισροών, αποτελεσμάτων και με καθορισμένη λογική. Με τον τρόπο αυτό, η διαδικασία παραμένει καθαρή και επικεντρωμένη στη ροή εργασίας, ενώ η απόφαση αναλύεται ξεχωριστά, ενισχύοντας τη σαφήνεια και τη διαφάνεια του συνολικού μοντέλου.


Η ανάγκη για έναν ενιαίο και τυποποιημένο τρόπο περιγραφής της λογικής των αποφάσεων οδήγησε στην ανάπτυξη του προτύπου **Decision Model and Notation (DMN)** από τον οργανισμό Object Management Group (OMG). Η DMN συμπληρώνει την BPMN, επιτρέποντας τον διαχωρισμό της λογικής των αποφάσεων από τη ροή των διαδικασιών, ώστε κάθε μοντέλο να παραμένει απλό, κατανοητό και ευέλικτο στη συντήρηση.

Σε αντίθεση με την BPMN, η οποία εστιάζει στη ροή εργασιών (ποιος κάνει τι και πότε), η DMN επικεντρώνεται στο γιατί λαμβάνεται μια συγκεκριμένη απόφαση και με ποια κριτήρια. Μέσω των πινάκων απόφασης (Decision Tables) και των διαγραμμάτων απαιτήσεων αποφάσεων (Decision Requirements Diagrams - DRD), η DMN επιτρέπει τον ορισμό εισόδων, κανόνων και αποτελεσμάτων με τρόπο κατανοητό τόσο από τεχνικούς όσο και από επιχειρησιακούς χρήστες.

Ο συνδυασμός των BPMN και DMN προσφέρει μια ολιστική προσέγγιση στη διαχείριση επιχειρησιακών διαδικασιών. Στα σημεία όπου απαιτείται λήψη απόφασης, το BPMN μοντέλο περιλαμβάνει μια δραστηριότητα τύπου Business Rule Task, η οποία παραπέμπει στο αντίστοιχο μοντέλο DMN. Κατά την εκτέλεση, τα δεδομένα της διαδικασίας αποστέλλονται στην DMN, η οποία αξιολογεί τους κανόνες και επιστρέφει το αποτέλεσμα στο BPMN μοντέλο, καθορίζοντας τη συνέχεια της ροής.

Η προσέγγιση αυτή εξασφαλίζει:

- **Μείωση πολυπλοκότητας** στα BPMN διαγράμματα.
- **Καλύτερη τεκμηρίωση και διαφάνεια** στη λογική των αποφάσεων.
- **Επαναχρησιμοποίηση** των ίδιων αποφάσεων σε διαφορετικές διαδικασίες.
- **Αυτοματοποίηση και ευκολία αλλαγών** χωρίς ανασχεδίαση του συνολικού μοντέλου.



Εικόνα 3. 3 Διασύνδεση BPMN και DMN

Η παραπάνω εικόνα απεικονίζει τη σχέση μεταξύ του επιχειρησιακού μοντέλου διαδικασίας (BPMN) και του μοντέλου λήψης απόφασης (DMN). Στο επάνω τμήμα, το BPMN διάγραμμα παρουσιάζει τη ροή εργασίας που ξεκινά με την παραλαβή μιας παραγγελίας και περιλαμβάνει μια δραστηριότητα τύπου *Business Rule Task* (“Decide order acceptance”). Η δραστηριότητα αυτή ενεργοποιεί έναν μηχανισμό λήψης απόφασης σχετικά με το αν η παραγγελία είναι αποδεκτή ή όχι, οδηγώντας αντίστοιχα σε αποδοχή ή απόρριψη της παραγγελίας.

Στο κάτω τμήμα, το DMN διάγραμμα αναλύει τη λογική που υποστηρίζει την απόφαση αυτή. Εμφανίζονται οι κύριες και επιμέρους αποφάσεις (*Decide order acceptance*, *Entity acceptance*, *CN acceptance*), καθώς και τα σχετικά επιχειρησιακά μοντέλα γνώσης (*business knowledge models*) και τα δεδομένα εισόδου (όπως η χωρητικότητα της οντότητας και του δικτύου). Με τον τρόπο αυτό, η DMN προσδιορίζει το “πώς” λαμβάνεται η απόφαση, ενώ η BPMN δείχνει το “πότε” και από ποιο σημείο της διαδικασίας αυτή καλείται.

Η συνδυασμένη χρήση των δύο προτύπων επιτρέπει τον σαφή διαχωρισμό της ροής της διαδικασίας από τη λογική των επιχειρησιακών κανόνων, ενισχύοντας τη διαφάνεια και την επαναχρησιμοποίηση των αποφάσεων.

3.3 Δομή και Επίπεδα Αναπαράστασης της DMN

Η DMN είναι σχεδιασμένη για την τυποποιημένη μοντελοποίηση, τεκμηρίωση και αυτοματοποίηση των επιχειρησιακών αποφάσεων. Ο κύριος σκοπός της είναι να παρέχει μια ενιαία και κατανοητή γλώσσα τόσο για τους επιχειρησιακούς αναλυτές

όσο και για τους τεχνικούς υλοποίησης. Μέσω της DMN, οι οργανισμοί μπορούν να αναπαριστούν με σαφή και εκτελέσιμο τρόπο το πώς λαμβάνονται οι αποφάσεις στο πλαίσιο των διαδικασιών τους, διασφαλίζοντας συνέπεια, διαφάνεια και επαναχρησιμοποίηση της επιχειρηματικής γνώσης.

Ένα επιπλέον αξιοσημείωτο χαρακτηριστικό της DMN είναι ότι τα μοντέλα της μπορούν να αποτυπωθούν σε τυποποιημένη μορφή XML. Η αναπαράσταση αυτή καθιστά τα μοντέλα διαλειτουργικά, επιτρέποντας την εύκολη ανταλλαγή, αποθήκευση και εκτέλεσή τους σε διαφορετικά πληροφοριακά συστήματα. Παράλληλα, η χρήση της XML διευκολύνει τους προγραμματιστές, καθώς τους παρέχει μια μηχανικά αναγνώσιμη δομή μέσα από την οποία μπορούν να ενσωματώνουν, να παραμετροποιούν ή να εκτελούν αποφάσεις μέσα σε εφαρμογές και συστήματα αυτοματοποίησης.


Η DMN βασίζεται σε δύο κύρια επίπεδα περιγραφής της λογικής των αποφάσεων:

1. Επίπεδο Απαιτήσεων Απόφασης (Decision Requirements Level)

2. Επίπεδο Λογικής Απόφασης (Decision Logic Level)

Το Επίπεδο Απαιτήσεων Απόφασης αποτυπώνει τη δομή και τις σχέσεις μεταξύ αποφάσεων, δεδομένων εισόδου, μοντέλων επιχειρηματικής γνώσης και πηγών γνώσης. Η κεντρική απεικόνιση σε αυτό το επίπεδο είναι το διάγραμμα απαιτήσεων απόφασης (decision requirements diagram – DRD), το οποίο καθορίζει ποιες αποφάσεις πρέπει να ληφθούν, ποιες πληροφορίες απαιτούνται και πώς οι αποφάσεις αλληλοεξαρτώνται.

Το Επίπεδο Λογικής Απόφασης, από την άλλη πλευρά, περιγράφει πώς ακριβώς λαμβάνεται κάθε απόφαση. Σε αυτό το επίπεδο ενσωματώνονται οι πίνακες αποφάσεων (decision tables) και οι κουτιασμένες εκφράσεις (boxed expressions), οι οποίες καθορίζουν τη λογική που μετατρέπει τις εισόδους σε αποτελέσματα με τη χρήση της γλώσσας FEEL (friendly enough expression language).



Εικόνα 3. 4 Επίπεδα αναπαράστασης της DMN

Η εικόνα παρουσιάζει τη δομή του προτύπου DMN και τη σύνδεσή του με τη διαδικασία BPMN “Decide on Credit Sales”. Στο δεξί τμήμα του διαγράμματος διακρίνονται τα δύο βασικά επίπεδα της DMN:


- **Επίπεδο Απαιτήσεων Απόφασης (Decision Requirements Level):** Μέσω του DRD διαγράμματος απεικονίζονται οι εξαρτήσεις μεταξύ των αποφάσεων, των κριτηρίων και των δεδομένων εισόδου (π.χ. Credit Sales, Credit Eligibility, Cheque Performance). Το διάγραμμα DRD καθορίζει ποιες αποφάσεις πρέπει να ληφθούν και με ποια σειρά.
- **Επίπεδο Λογικής Απόφασης (Decision Logic Level):** Εδώ παρουσιάζεται ο πίνακας αποφάσεων “Company Credit Eligibility Rules”. Σε αυτόν περιλαμβάνονται οι κανόνες που καθορίζουν αν ένας πελάτης είναι επιλέξιμος για πίστωση, με βάση συγκεκριμένες εισροές όπως η πιστοληπτική ικανότητα, τα διαθέσιμα όρια και οι τραπεζικές εγγυήσεις. Επίσης, περιλαμβάνει τη γλώσσα FEEL (Friendly Enough Expression Language), η οποία χρησιμοποιείται για να καθορίσει τις συνθήκες και τα αποτελέσματα κάθε κανόνα, μετατρέποντας τα δεδομένα εισόδου (όπως “Project Value” ή “Credit Limit”) σε ένα σαφές αποτέλεσμα (π.χ. “ELIGIBLE” ή “INELIGIBLE”).

Το παράδειγμα δείχνει πώς η DMN αποσαφηνίζει τη λογική της απόφασης που ενεργοποιείται από το Business Rule Task του BPMN μοντέλου, παρέχοντας έτσι πλήρη διαφάνεια και επαναχρησιμοποίηση της επιχειρησιακής γνώσης.

3.4 Επίπεδο Απαιτήσεων Απόφασης (Decision Requirements Level)

Στο Επίπεδο Απαιτήσεων Απόφασης (Decision Requirements Level), η DMN επιδιώκει να απεικονίσει με σαφή και κατανοητό τρόπο τη δομή των εξαρτήσεων ανάμεσα σε δεδομένα, αποφάσεις, πηγές γνώσης και μοντέλα επιχειρηματικής γνώσης. Το εργαλείο που χρησιμοποιείται για τον σκοπό αυτό είναι το Διάγραμμα Απαιτήσεων Απόφασης (Decision Requirements Diagram – DRD), το οποίο παρέχει μια οπτική αναπαράσταση της λογικής των αποφάσεων.

Η DMN ορίζει την **απόφαση (decision)** ως τη διαδικασία προσδιορισμού μιας τιμής εξόδου βάσει ενός συγκεκριμένου αριθμού **τιμών εισόδου (input data)**, με τη χρήση καθορισμένης λογικής που προσδιορίζει με ποιον τρόπο η έξοδος εξαρτάται από τις εισόδους. Η λογική αυτή μπορεί να περιλαμβάνει ένα ή περισσότερα **μοντέλα επιχειρηματικής γνώσης (Business Knowledge Models – BKM)**, τα οποία ενσωματώνουν την επιχειρηματική τεχνογνωσία υπό τη μορφή κανόνων, μοντέλων, συναρτήσεων ή άλλων δομημένων μορφών γνώσης. Παράλληλα, η DMN χρησιμοποιεί και **πηγές γνώσης (knowledge sources)**, οι οποίες αποτελούν αρχές ή οντότητες με τις οποίες οι αποφάσεις και τα μοντέλα επιχειρηματικής γνώσης οφείλουν να είναι συνεπή. Οι πηγές γνώσης αντιπροσωπεύουν τις βάσεις ή τα τεκμήρια στα οποία θεμελιώνεται η λογική των αποφάσεων. Μπορεί να είναι κανονιστικά έγγραφα, εσωτερικές πολιτικές, πρότυπα, ή σύνολα επιχειρηματικών κανόνων που έχουν καθοριστεί από συγκεκριμένα αρμόδια όργανα.




Εικόνα 3. 5 Βασικά Στοιχεία DRD διαγράμματος

Ωστόσο, δεν είναι απαραίτητο κάθε απόφαση να συνδέεται άμεσα με κάποιο μοντέλο επιχειρηματικής γνώσης. Σε αρκετές περιπτώσεις, η λογική μιας απόφασης μπορεί να είναι σχετικά απλή και να αποτυπώνεται απευθείας μέσα στο ίδιο το αντικείμενο της απόφασης, χωρίς την ανάγκη εξωτερικής αναφοράς σε μοντέλο επιχειρηματικής γνώσης.

Επιπλέον, οι πηγές γνώσης μπορούν να συνδέονται με μοντέλα επιχειρηματικής γνώσης ή αποφάσεις που είναι υπεύθυνα για την εφαρμογή, τη συντήρηση ή την

επαλήθευση της ορθότητας αυτών των αρχών. Σε ορισμένες περιπτώσεις, αποτελούν και τη βάση για τη δημιουργία δοκιμαστικών σεναρίων ή περιπτώσεων ελέγχου, ώστε να διασφαλίζεται ότι η λογική των αποφάσεων παραμένει σύμφωνη με τους επιχειρησιακούς κανόνες και τις στρατηγικές απαιτήσεις του οργανισμού.

Μια απόφαση «εξαρτάται» από τις αντίστοιχες εισροές της, καθώς αυτές είναι απαραίτητες για τον προσδιορισμό του τελικού αποτελέσματος. Αξίζει να σημειωθεί ότι ως εισροή δεν θεωρούνται μόνο τα πρωτογενή δεδομένα, αλλά μπορεί να περιλαμβάνεται και το αποτέλεσμα μιας άλλης, προηγούμενης απόφασης, η οποία ονομάζεται **υποαπόφαση (subdecision)**.




Εικόνα 3. 6 Παράδειγμα υποαπόφασης σε DRD διάγραμμα

Το σχήμα απεικονίζει ένα παράδειγμα υποαπόφασης, όπου το αποτέλεσμα μιας απόφασης (*Decision 2*) χρησιμοποιείται ως είσοδος για μια άλλη απόφαση (*Decision 1*) μέσα σε ένα DRD διάγραμμα.

Αξίζει να σημειωθεί ότι η ορθή σχεδίαση των Διαγραμμάτων Απαιτήσεων Απόφασης αποτελεί κρίσιμο παράγοντα για την αποτελεσματική εφαρμογή του προτύπου DMN σε πραγματικά επιχειρησιακά περιβάλλοντα. Η ποιότητα ενός DRD δεν εξαρτάται μόνο από την ακρίβεια της απεικόνισης των αποφάσεων, αλλά και από τον βαθμό σαφήνειας, απλότητας και επαναχρησιμοποίησης των επιμέρους στοιχείων του. Η αποτελεσματική σχεδίαση των DRD διαγραμμάτων στηρίζεται σε ορισμένες βασικές αρχές που αποσκοπούν στη δημιουργία σαφών, κατανοητών και λειτουργικών μοντέλων.

Οι κυριότερες από αυτές τις αρχές είναι:

- **Καθαρή ονομασία και νόημα των κόμβων:** Κάθε κόμβος απόφασης (Decision) στο DRD διάγραμμα πρέπει να φέρει σαφή και κατανοητό όνομα που να αποτυπώνει τη λειτουργία του. Αυτό ενισχύει την αναγνωσιμότητα και διευκολύνει τη συνεργασία μεταξύ επιχειρησιακών και τεχνικών ομάδων.
- **Αιτιώδεις συνδέσεις:** Οι σχέσεις μεταξύ των κόμβων, εισροές (Input Data), υποαποφάσεις (Sub-decisions), μοντέλα γνώσης (Business Knowledge Models) και πηγές γνώσης (Knowledge Sources), πρέπει να απεικονίζονται ρητά, ώστε να είναι προφανές ποιες πληροφορίες απαιτούνται σε κάθε απόφαση.
- **Διαχωρισμός της λογικής από τη ροή:** Το DRD διάγραμμα επικεντρώνεται στο τι και ποια είναι τα στοιχεία που εμπλέκονται στη λήψη μιας απόφασης, ενώ η λεπτομερής λογική (βάσει κανόνων) αποτυπώνεται σε επόμενο επίπεδο (Decision Logic). Ο διαχωρισμός αυτός συμβάλλει στην ευελιξία και επαναχρησιμοποίηση του μοντέλου.
- **Αποφυγή υπερβολικής πολυπλοκότητας:** Σε πολύπλοκα σημεία, είναι προτιμότερο να διασπώνται μεγάλα DRD σε υποδιαγράμματα (nested DRDs) ώστε να διατηρείται η σαφήνεια και η συντηρησιμότητα.
- **Τεκμηρίωση και ιχνηλασιμότητα:** Οι πηγές γνώσης (Knowledge Sources) και τα μοντέλα γνώσης πρέπει να τεκμηριώνονται και να συνδέονται με τις αντίστοιχες αποφάσεις, ώστε να υποστηρίζεται η αξιολόγηση, η συντήρηση και η συνεκτικότητα των λογικών μοντέλων.



Εικόνα 3. 7 Ενδεικτικό Διάγραμμα DRD

Το συγκεκριμένο παράδειγμα απεικονίζει τη διαδικασία λήψης της απόφασης σχετικά με την επιλογή φαγητού (*Dish Decision*), η οποία εξαρτάται από δύο επιμέρους αποφάσεις: τη *Season Decision* (εποχική απόφαση) και τον *Guest Count* (αριθμό καλεσμένων).

Η *Season Decision* προκύπτει με βάση τα δεδομένα εισόδου *Weather in Celsius* (θερμοκρασία σε βαθμούς Κελσίου), ενώ η *Guest Count* εξαρτάται από τον *Type of day* (είδος ημέρας), ο οποίος με τη σειρά του προσδιορίζεται από το *Weekday for the day of the event* (ημέρα της εβδομάδας του γεγονότος), το οποίο λειτουργεί ως επεξηγηματικό σχόλιο (Text annotation) που βοηθά στην κατανόηση του τρόπου με τον οποίο καθορίζεται το είδος της ημέρας.

Η απόφαση για τον αριθμό καλεσμένων (*Guest Count*) συνδέεται με την πηγή γνώσης *Guest Type* (τύπος καλεσμένων), η οποία καθορίζει τις επιχειρηματικές πολιτικές και τα κριτήρια ταξινόμησης των καλεσμένων που επηρεάζουν τη λήψη της απόφασης, καθώς και με το μοντέλο επιχειρηματικής γνώσης *El menú* (το μενού), το οποίο ενσωματώνει την επιχειρηματική τεχνογνωσία σχετικά με την επιλογή των διαθέσιμων πιάτων. Αντίστοιχα, η απόφαση για το φαγητό (*Dish Decision*) συνδέεται με την πηγή γνώσης *Host*, που αντιπροσωπεύει μια οντότητα που λειτουργεί ως φορέας ή αρχή λήψης αποφάσεων.

3.5 Επίπεδο Λογικής Απόφασης (Decision Logic Level)

Το Επίπεδο Λογικής Απόφασης (Decision Logic Level) στο πλαίσιο της DMN αποτελεί το στάδιο στο οποίο η επιχειρησιακή λογική μετασχηματίζεται σε ακριβή, εκτελέσιμη μορφή, δηλαδή στο σημείο όπου οι αποφάσεις αποκτούν συγκεκριμένες συνθήκες και αποτελέσματα. Στο επίπεδο αυτό ενσωματώνονται οι πίνακες απόφασης και άλλες εκφράσεις (boxed expressions), οι οποίοι ορίζουν πώς κάθε συνδυασμός εισόδων μετατρέπεται σε αποτελέσματα με χρήση της γλώσσας FEEL.

Η γλώσσα FEEL αποτελεί το πρότυπο μέσο αναπαράστασης της λογικής των αποφάσεων στη DMN, προσφέροντας μια συμβολική αλλά φιλική στη χρήση σύνταξη, σχεδιασμένη ώστε να είναι κατανοητή τόσο από αναλυτές επιχειρήσεων όσο και από προγραμματιστές. Μέσω της FEEL, καθορίζονται οι όροι, οι συνθήκες και οι υπολογισμοί που περιγράφουν τη συμπεριφορά κάθε απόφασης, εξασφαλίζοντας συνέπεια, ακρίβεια και εκτελεσιμότητα στα μοντέλα DMN.

Οι πίνακες απόφασης αποτελούν το κύριο μέσο αποτύπωσης της λογικής μιας απόφασης στο πλαίσιο της DMN. Ουσιαστικά, αποδίδουν με σαφή και τυποποιημένο τρόπο τη συσχέτιση μεταξύ εισόδων, συνθηκών και εξόδων, επιτρέποντας την κατανόηση και την αυτοματοποίηση των επιχειρησιακών κανόνων. Η λογική αυτή είναι πλήρως εκτελέσιμη από συστήματα που υποστηρίζουν DMN, χάρη στη γλώσσα FEEL (Friendly Enough Expression Language).


Ένας πίνακας απόφασης συνδέεται συνήθως με ένα **στοιχείο πληροφορίας (information item)**, δηλαδή ένα συγκεκριμένο αντικείμενο ή μεταβλητή που περιγράφει την απόφαση για την οποία ο πίνακας εκφράζει τη λογική. Το όνομα αυτού του στοιχείου αντιστοιχεί συχνά στην ονομασία της επιχειρηματικής γνώσης ή του ίδιου του μοντέλου απόφασης, υποδηλώνοντας έτσι τη λειτουργία του πίνακα ως "μηχανισμού" λήψης τιμών για τη συγκεκριμένη απόφαση.

Αναλυτικά τα βασικά στοιχεία που συγκροτούν έναν πίνακα απόφασης:

- **Στήλες Εισόδου (Input Columns):** Αντιπροσωπεύουν τα πεδία ή τις μεταβλητές που χρησιμοποιούνται ως είσοδοι στη διαδικασία λήψης απόφασης. Κάθε στήλη εισόδου περιλαμβάνει ένα όνομα και συνήθως έναν τύπο δεδομένων (π.χ. integer, string, date). Οι στήλες εισόδου ορίζουν ποια επιχειρηματικά δεδομένα αξιολογούνται από τον πίνακα.
- **Στήλες Εξόδου (Output Columns):** Προσδιορίζουν τα αποτελέσματα ή τις αποφάσεις που παράγει ο πίνακας. Κάθε στήλη εξόδου αντιστοιχεί σε ένα στοιχείο πληροφορίας που προκύπτει ως αποτέλεσμα της εφαρμογής των κανόνων. Στους πίνακες με μία μόνο έξοδο, η στήλη εξόδου συνήθως έχει ένα όνομα. Σε περιπτώσεις πολλαπλών εξόδων, κάθε στήλη εξόδου αντιπροσωπεύει ξεχωριστή πτυχή της τελικής απόφασης.

- **Κανόνες (Rules):** Οι κανόνες αντιστοιχούν στις επιμέρους γραμμές ή στήλες του πίνακα, ανάλογα με τον προσανατολισμό του. Κάθε κανόνας αποτελείται από ένα σύνολο καταχωρήσεων εισόδου, τις αντίστοιχες καταχωρήσεις εξόδου και, προαιρετικά, σχολιασμούς. Με άλλα λόγια, ένας κανόνας ορίζει ρητά τη λογική «εάν ισχύουν οι παρακάτω συνθήκες εισόδου, τότε το αποτέλεσμα είναι το εξής».
- **Καταχωρήσεις Εισόδου (Input Entries):** Αφορούν τις συγκεκριμένες τιμές ή τις συνθήκες που ελέγχονται για κάθε στήλη εισόδου, στο πλαίσιο κάθε κανόνα του πίνακα. Κάθε γραμμή (κανόνας) περιλαμβάνει μία καταχώρηση εισόδου για κάθε στήλη εισόδου. Οι καταχωρήσεις μπορεί να είναι απόλυτες τιμές, λογικές εκφράσεις (π.χ. $\leq$, $\geq$), εύρη τιμών (π.χ. [20.000..40.000]) ή ακόμη και η τιμή “–” που δηλώνει ότι η μεταβλητή δεν είναι σχετική για τον συγκεκριμένο κανόνα.
- **Καταχωρήσεις Εξόδου (Output Entries):** Αντιστοιχούν στις συγκεκριμένες τιμές ή κατηγορίες που επιστρέφονται ως αποτέλεσμα της εφαρμογής κάθε κανόνα. Κάθε γραμμή του πίνακα περιλαμβάνει μία καταχώρηση εξόδου για κάθε στήλη εξόδου. Οι καταχωρήσεις εξόδου λαμβάνουν συγκεκριμένες τιμές ή κατηγορίες. Σε πίνακες με πολλαπλές εξόδους, κάθε έξοδος πρέπει να έχει μοναδικό όνομα ώστε να διασφαλίζεται η σαφήνεια και η συνέπεια των αποτελεσμάτων.
- **Σχολιασμοί (Annotations):** Πρόκειται για προαιρετικά πεδία που συνοδεύουν τους κανόνες, παρέχοντας επεξηγήσεις ή πρόσθετες πληροφορίες σχετικά με το σκεπτικό ή τη χρήση του κάθε κανόνα. Οι σχολιασμοί βοηθούν στην τεκμηρίωση και κατανόηση της λογικής, ειδικά από μη τεχνικούς χρήστες.
- **Πολιτική Πίνακα (Hit Policy):** Η πολιτική πίνακα καθορίζει τον τρόπο με τον οποίο το σύστημα θα επιλέξει την τελική έξοδο σε περίπτωση που περισσότερες από μία γραμμές (κανόνες) ικανοποιούνται από τα δεδομένα εισόδου. Οι βασικοί τύποι πολιτικών περιλαμβάνουν:
 1. **Unique (U):** Επιτρέπεται το πολύ ένας κανόνας να ικανοποιηθεί. Εάν περισσότερες από μία γραμμές ικανοποιούνται, τότε θεωρείται σφάλμα.
 2. **First (F):** Οι κανόνες μπορούν να επικαλύπτονται. Ο πίνακας αξιολογείται με τη σειρά εμφάνισης των κανόνων, και μόλις βρεθεί η πρώτη ταιριαστή γραμμή, το αποτέλεσμα της γραμμής αυτής είναι η έξοδος. Οι υπόλοιποι κανόνες αγνοούνται.
 3. **Collect (C):** Όλες οι γραμμές που ικανοποιούνται συλλέγουν αποτελέσματα, που μπορεί να συνδυάζονται (π.χ. άθροιση ή μέσος όρος).

4. **Any (A):** Επιτρέπεται να ικανοποιούνται πολλοί κανόνες, εφόσον όλοι οι κανόνες αυτοί έχουν το ίδιο αποτέλεσμα. Εάν δύο (ή περισσότερες) γραμμές ταιριάζουν με διαφορετικό αποτέλεσμα, τότε παραβιάζεται η πολιτική.
5. **Priority (P):** Εφόσον πολλοί κανόνες ικανοποιούνται, επιλέγεται ο κανόνας με το υψηλότερο προτεραιότητα αποτέλεσμα. Ορίζεται συνήθως μια λίστα «επιτρεπτών τιμών» εξόδου με σειρά προτεραιότητας.



Εικόνα 3. 8 Παράδειγμα Πίνακα Αποφάσεων

Η εικόνα παρουσιάζει ένα παράδειγμα πίνακα αποφάσεων (Decision Table) με τίτλο "Loan Grade" (Table Name), ο οποίος χρησιμοποιείται για την αξιολόγηση της βαθμολογίας ενός δανείου βάσει δύο παραμέτρων εισόδου: Loan Duration (διάρκεια δανείου) και Annual Income (ετήσιο εισόδημα) (Input Columns). Οι δύο αυτές μεταβλητές καθορίζουν την κατηγορία βαθμολογίας (Grade), (Output Column) που θα αποδοθεί στο δάνειο, με πιθανές τιμές A, B ή C (Output Entries).

Στην επάνω αριστερή γωνία του πίνακα εμφανίζεται ο δείκτης πολιτικής εφαρμογής κανόνων (Hit Indicator) με την τιμή UC (Unique-Collect), που δηλώνει ότι κάθε σύνολο εισόδων αντιστοιχεί σε ένα μοναδικό αποτέλεσμα, ενώ τα αποτελέσματα μπορούν να συλλεχθούν συνολικά αν αξιολογούνται πολλαπλά δάνεια. Δίπλα του φαίνεται η ένδειξη πληρότητας (Completeness Indicator), η οποία υποδεικνύει αν ο πίνακας καλύπτει όλους τους δυνατούς συνδυασμούς εισόδου.

Η στήλη εξόδου περιλαμβάνει επίσης μια προαιρετική λίστα τιμών {A, B, C} (Optional list of values), η οποία ορίζει τις επιτρεπόμενες τιμές για το πεδίο "Grade" (Output

Column). Η χρήση τέτοιας λίστας συμβάλει στη διασφάλιση της ορθότητας των αποτελεσμάτων και της συνέπειας του πίνακα.

Κάθε γραμμή του πίνακα αντιστοιχεί σε έναν κανόνα απόφασης (Rule Number). Για παράδειγμα, ο κανόνας 1 δηλώνει ότι αν η διάρκεια του δανείου είναι 36 μήνες και το ετήσιο εισόδημα είναι μικρότερο ή ίσο από 56.943, τότε η κατηγορία του δανείου είναι C. Ο κανόνας 2 αφορά την ίδια διάρκεια δανείου (36 μήνες) αλλά με εισόδημα μεγαλύτερο από 56.943, οπότε το αποτέλεσμα είναι A. Τέλος, ο κανόνας 3 καλύπτει την περίπτωση όπου η διάρκεια του δανείου είναι 60 μήνες, ανεξάρτητα από το εισόδημα (δηλωμένο ως “–”, δηλαδή *μη σχετικό*), και αποδίδει κατηγορία B.

Συνολικά, το παράδειγμα αποτυπώνει τον τρόπο με τον οποίο οι κανόνες απόφασης μετατρέπουν συγκεκριμένα επιχειρηματικά δεδομένα σε τεκμηριωμένες αποφάσεις μέσα στο πλαίσιο της DMN.

Οι **Boxed Expressions** αποτελούν τον μηχανισμό της DMN για την αναπαράσταση της εσωτερικής λογικής μιας απόφασης με δομημένο και εκτελέσιμο τρόπο. Πρόκειται για «κουτιασμένες» μορφές έκφρασης, όπου η λογική κάθε απόφασης αποτυπώνεται μέσα σε πίνακες (κουτιά) με δύο συνήθως στήλες που περιέχουν ονόματα μεταβλητών και αντίστοιχες εκφράσεις στη γλώσσα FEEL (Friendly Enough Expression Language).

Στόχος των boxed expressions είναι να προσφέρουν ένα ενιαίο και κατανοητό τρόπο μοντελοποίησης της επιχειρησιακής λογικής, ώστε να είναι αναγνώσιμη από αναλυτές επιχειρήσεων και ταυτόχρονα εκτελέσιμη από τα πληροφοριακά συστήματα. Κάθε boxed expression αντιστοιχεί σε ένα είδος λογικής δομής και χρησιμοποιείται εντός ενός κόμβου απόφασης (decision node) ή ενός μοντέλου επιχειρησιακής γνώσης (Business Knowledge Model).

Οι βασικοί τύποι boxed expressions είναι:

- **Literal Expression:** Απλή έκφραση FEEL που αποδίδει μία τιμή.
- **Context:** Πίνακας που περιλαμβάνει ζεύγη μεταβλητής–έκφρασης, επιτρέποντας την εκτέλεση μιας ακολουθίας υπολογισμών με ενδιάμεσα βήματα.
- **Relation:** Πίνακας δεδομένων που λειτουργεί ως συλλογή (π.χ. λίστα τιμών).
- **Function Definition:** Ορισμός συνάρτησης με παραμέτρους και σώμα έκφρασης.

- **Invocation:** Κλήση μιας άλλης απόφασης ή επιχειρησιακής γνώσης (BKM).
- **Decision Table:** Πίνακας απόφασης με κανόνες εισόδου–εξόδου και πολιτική *hit policy*.

Installment calculation	
(Product Type, Rate, Term, Amount)	
Monthly Fee	if Product Type = "STANDARD LOAN" then 20.00 else if Product Type = "SPECIAL LOAN" then 25.00 else null
Monthly Repayment	PMT(Rate, Term, Amount)
Monthly Repayment + Monthly Fee	

Εικόνα 3. 9 Παράδειγμα Boxed Expression τύπου Context

Στο συγκεκριμένο παράδειγμα παρουσιάζεται η υλοποίηση ενός Boxed Expression τύπου Context, το οποίο χρησιμοποιείται για τον υπολογισμό της μηνιαίας δόσης ενός δανείου (*Installment calculation*). Το μοντέλο αυτό αντιστοιχεί σε ένα Business Knowledge Model (BKM), δηλαδή σε μια επαναχρησιμοποιήσιμη συνάρτηση επιχειρησιακής γνώσης, η οποία δέχεται τέσσερις παραμέτρους εισόδου: *Product Type*, *Rate*, *Term* και *Amount*.

Η πρώτη γραμμή του πίνακα δηλώνει τις παραμέτρους εισόδου της συνάρτησης. Στη συνέχεια, η μεταβλητή *Monthly Fee* υπολογίζεται μέσω μιας συνθήκης FEEL που καθορίζει διαφορετικό ποσό τέλους ανάλογα με τον τύπο του δανείου (*STANDARD* ή *SPECIAL LOAN*). Έπειτα, η μεταβλητή *Monthly Repayment* υπολογίζεται μέσω της συνάρτησης *PMT*, η οποία λαμβάνει ως ορίσματα το επιτόκιο, τη διάρκεια και το ποσό του δανείου. Η τελευταία γραμμή, γνωστή ως *final result box*, προσδιορίζει την τελική τιμή που επιστρέφει η συνάρτηση, υπολογίζοντας το άθροισμα της μηνιαίας δόσης και του μηνιαίου τέλους.


Η συγκεκριμένη μορφή Boxed Context Expression επιτρέπει τη σαφή, ιεραρχική οργάνωση της λογικής των υπολογισμών και καθιστά το μοντέλο εκτελέσιμο και επαναχρησιμοποιήσιμο. Μέσω της FEEL, η λογική παραμένει ανθρώπινα αναγνώσιμη αλλά και τεχνικά ακριβής, ενισχύοντας τη διαφάνεια, τη συνέπεια και τη δυνατότητα αυτοματοποίησης των επιχειρησιακών αποφάσεων.

3.6 Υπηρεσία Απόφασης (Decision Service)

Η έννοια της **Decision Service** αποτελεί ένα από τα κεντρικά στοιχεία του προτύπου DMN για τη μοντελοποίηση αποφάσεων. Μια Υπηρεσία Απόφασης αποτελεί μια εκτελέσιμη μονάδα λογικής απόφασης με σαφώς καθορισμένες εισόδους και εξόδους, η οποία μπορεί να καλείται από εξωτερική εφαρμογή ή διαδικασία. Με άλλα λόγια, μετά τη σχεδίαση της δομής της απόφασης και της λογικής, η Υπηρεσία Απόφασης είναι το σημείο όπου η λογική αυτή «παραδίδεται» προς εκτέλεση/κλήση από άλλα συστήματα.

Η διεπαφή της υπηρεσίας απόφασης αποτελείται από:

1. **Δεδομένα εισόδου:** Αναφέρονται στις πληροφορίες ή παραμέτρους που απαιτούνται για την εκτέλεση των ενθυλακωμένων αποφάσεων και τη σωστή λειτουργία της υπηρεσίας απόφασης.
2. **Εισερχόμενες αποφάσεις:** Αντιπροσωπεύουν τα αποτελέσματα ή τις ενδιάμεσες τιμές που προκύπτουν από τις ενθυλακωμένες αποφάσεις και χρησιμοποιούνται ως είσοδοι για τον υπολογισμό της τελικής απόφασης.
3. **Εξερχόμενες αποφάσεις:** Περιλαμβάνουν τα τελικά αποτελέσματα που παράγει η υπηρεσία απόφασης, τα οποία προκύπτουν από τη συνδυασμένη αξιοποίηση των εισερχόμενων αποφάσεων και των δεδομένων εισόδου.




Εικόνα 3. 10 Υπηρεσία Απόφασης

Το παραπάνω σχήμα απεικονίζει τη δομή και τη λειτουργική οργάνωση μιας Υπηρεσίας Απόφασης. Η υπηρεσία «*Decision Service 1*» περιλαμβάνει ένα σύνολο αποφάσεων και δεδομένων εισόδου που συνεργάζονται για την παραγωγή ενός τελικού αποτελέσματος.

Η *Decision 1* αποτελεί την εξερχόμενη απόφαση της υπηρεσίας, ενώ εισερχόμενες αποφάσεις δεν υπάρχουν. Ως εκ τούτου, η υπηρεσία παράγει τα αποτελέσματα των *Decision 1* και *Decision 2*, χωρίς να αξιοποιεί αποτελέσματα από εξωτερικές αποφάσεις. Επειδή η *Decision 1* εξαρτάται από την *Decision 2*, η οποία χρησιμοποιείται αποκλειστικά για τον υπολογισμό της και δεν αποτελεί είσοδο από το εξωτερικό περιβάλλον, η *Decision 2* πρέπει να ενθυλακωθεί εντός της υπηρεσίας. Αντίθετα, η *Decision 3* δεν χρειάζεται να συμπεριληφθεί, καθώς δεν εμπλέκεται στη λογική αλληλουχία της συγκεκριμένης υπηρεσίας. Όσον αφορά τα δεδομένα εισόδου, η υπηρεσία απαιτεί τα *Input data 1* και *Input data 2* για τον υπολογισμό των εσωτερικών αποφάσεων, ενώ το *Input data 3* παραμένει εκτός, καθώς δεν χρησιμοποιείται στο πλαίσιο της υλοποίησης της υπηρεσίας αυτής.

Η οριζόντια γραμμή που βρίσκεται στο εσωτερικό του πλαισίου μιας Υπηρεσίας Απόφασης χρησιμεύει για να διαχωρίζει τις αποφάσεις εξόδου από τις ενθυλακωμένες αποφάσεις. Οι αποφάσεις που βρίσκονται πάνω από τη γραμμή αποτελούν τις **αποφάσεις εξόδου** της υπηρεσίας, δηλαδή τα αποτελέσματα που εκτίθενται προς το εξωτερικό περιβάλλον και μπορούν να χρησιμοποιηθούν από άλλες αποφάσεις ή επιχειρησιακές διαδικασίες. Αντίθετα, οι αποφάσεις που βρίσκονται κάτω από τη γραμμή θεωρούνται **ενθυλακωμένες αποφάσεις**, οι οποίες εκτελούνται εσωτερικά στο πλαίσιο της υπηρεσίας και συμβάλλουν στον υπολογισμό των αποφάσεων εξόδου, χωρίς όμως να είναι ορατές ή προσβάσιμες εκτός αυτής.



Εικόνα 3.11 Υπηρεσία απόφασης με εισερχόμενη απόφαση

Μία εναλλακτική Υπηρεσία Απόφασης που μπορεί να οριστεί στο ίδιο μοντέλο παρουσιάζεται στο Σχήμα 10. Στην περίπτωση αυτή, η Decision 1 λειτουργεί ως εξερχόμενη απόφαση της υπηρεσίας, ενώ η Decision 2 αποτελεί την εισερχόμενη απόφαση, από την οποία εξαρτάται η λογική της υπηρεσίας. Οι ενθυλακωμένες αποφάσεις περιορίζονται αποκλειστικά στη Decision 1, η οποία υπολογίζεται εσωτερικά και παρέχει το τελικό αποτέλεσμα της υπηρεσίας.

Η συγκεκριμένη υπηρεσία απαιτεί ως δεδομένο εισόδου μόνο το Input data 1, το οποίο χρησιμοποιείται για τον υπολογισμό της Decision 1, ενώ τα Input data 2 και Input data 3 δεν αξιοποιούνται στο πλαίσιο αυτής της υλοποίησης. Με αυτόν τον τρόπο, η υπηρεσία αποτυπώνει μια πιο απλοποιημένη δομή εκτέλεσης, όπου η εξάρτηση από εξωτερικές αποφάσεις περιορίζεται στη λήψη του αποτελέσματος της Decision 2, διατηρώντας παράλληλα σαφή διαχωρισμό ανάμεσα στη λογική που ενθυλακώνεται και στις εισερχόμενες παραμέτρους.

Συνολικά, οι Υπηρεσίες Απόφασης αποτελούν το κρίσιμο σημείο σύνδεσης ανάμεσα στη μοντελοποίηση και την εκτέλεση των αποφάσεων στο πλαίσιο της DMN. Μέσω αυτών, η επιχειρησιακή λογική μετατρέπεται σε εκτελέσιμη και επαναχρησιμοποιήσιμη μορφή, η οποία μπορεί να κληθεί από άλλα συστήματα ή διαδικασίες, διασφαλίζοντας συνέπεια και διαφάνεια στη λήψη αποφάσεων. Επιτρέπουν την απομόνωση της λογικής απόφασης από το υπόλοιπο πληροφοριακό περιβάλλον, διευκολύνοντας την ενημέρωση και τη συντήρηση των επιχειρησιακών κανόνων. Συνολικά, οι Υπηρεσίες Απόφασης καθιστούν τη DMN ένα πρακτικά εφαρμόσιμο εργαλείο για την αυτοματοποίηση και τη διακυβέρνηση των αποφάσεων σε σύγχρονα πληροφοριακά συστήματα.

3.7 Σύνοψη

Το κεφάλαιο αυτό παρουσίασε τις βασικές αρχές της Διαχείρισης Επιχειρησιακών Διαδικασιών (BPM) και ανέδειξε τον καθοριστικό ρόλο της μοντελοποίησης μέσω των προτύπων BPMN και DMN στην αποτελεσματική απεικόνιση και αυτοματοποίηση της επιχειρησιακής λογικής. Η BPMN συμβάλλει στην αναπαράσταση και κατανόηση της ροής εργασιών, ενώ η DMN επιτρέπει τη σαφή και εκτελέσιμη μοντελοποίηση των αποφάσεων, προσφέροντας διαφάνεια και συνέπεια. Ο διαχωρισμός της ροής διαδικασιών από τη λογική αποφάσεων οδηγεί σε απλούστερα, επαναχρησιμοποιήσιμα και πιο ευέλικτα μοντέλα. Παρουσιάστηκαν τα επίπεδα αναπαράστασης της DMN, τα βασικά δομικά της στοιχεία (DRD, Decision Tables, Boxed Expressions) και η έννοια της Υπηρεσίας Απόφασης, η οποία συνδέει τη μοντελοποίηση με την εκτέλεση σε πραγματικά πληροφοριακά συστήματα. Συνολικά, το κεφάλαιο ανέδειξε πώς η ενσωμάτωση των BPMN και DMN υποστηρίζει την ολοκληρωμένη διαχείριση επιχειρησιακών διαδικασιών, ενισχύοντας την αποδοτικότητα, τη διαφάνεια και την προσαρμοστικότητα των οργανισμών στο σύγχρονο επιχειρηματικό περιβάλλον.

Κεφάλαιο 4: Δέντρα Απόφασης

Στο παρόν κεφάλαιο ορίζεται και αναλύεται η έννοια των δέντρων απόφασης (decision trees), μιας βασικής μεθόδου μηχανικής μάθησης που χρησιμοποιείται για προβλήματα ταξινόμησης και παλινδρόμησης. Παρουσιάζονται οι κύριες αρχές λειτουργίας τους, η δομή τους, η διαδικασία εκπαίδευσης και οι τεχνικές αξιολόγησης της απόδοσής τους. Στόχος είναι η κατανόηση του τρόπου με τον οποίο τα δέντρα απόφασης υποστηρίζουν τη λήψη αποφάσεων, προσφέροντας ακρίβεια, διαφάνεια και ευκολία ερμηνείας στα αποτελέσματα.

4.1 Εισαγωγή στα Δέντρα Απόφασης

Η ραγδαία ανάπτυξη της τεχνολογίας και η συνεχής αύξηση του όγκου των δεδομένων έχουν καταστήσει επιτακτική την ανάγκη για αποδοτικές μεθόδους ανάλυσης και εξαγωγής γνώσης. Η μηχανική μάθηση (machine learning) έχει αναδειχθεί ως ένα από τα σημαντικότερα εργαλεία για την αυτόματη ανάλυση δεδομένων και την υποστήριξη λήψης αποφάσεων. Στο πλαίσιο αυτό, τα **δέντρα απόφασης (decision trees)** αποτελούν μία από τις πιο δημοφιλείς και ευρέως χρησιμοποιούμενες τεχνικές, χάρη στην απλότητα, τη διαφάνεια και την υψηλή επεξηγηματικότητά τους.

Τα δέντρα απόφασης επιτρέπουν τη μοντελοποίηση πολύπλοκων συστημάτων λήψης αποφάσεων με τρόπο που διευκολύνει την κατανόηση και την ερμηνεία των αποτελεσμάτων από ένα ευρύτερο κοινό. Με την αξιοποίηση μιας δομής δέντρου, τα δεδομένα διαχωρίζονται σε υποσύνολα με βάση συγκεκριμένα χαρακτηριστικά, οδηγώντας σε μια ιεραρχική διαδικασία ταξινόμησης ή πρόβλεψης. Ο τρόπος αυτός προσφέρει όχι μόνο ακριβή αποτελέσματα, αλλά και τη δυνατότητα εξήγησης του «πώς» και «γιατί» μιας πρόβλεψης, καθιστώντας τα δέντρα απόφασης ιδανικά για εφαρμογές όπου η διαφάνεια έχει κρίσιμη σημασία.

Η ιστορική εξέλιξη των δέντρων απόφασης συνδέεται στενά με την ανάπτυξη θεμελιωδών αλγορίθμων που επέτρεψαν τη συστηματική δημιουργία και βελτιστοποίηση τους. Στη δεκαετία του 1980, ο J. Ross Quinlan εισήγαγε τον αλγόριθμο ID3 (Iterative Dichotomiser), ο οποίος βασίζεται στην έννοια της εντροπίας και του information gain για τον προσδιορισμό των βέλτιστων σημείων διάσπασης των δεδομένων. Αργότερα, ο ίδιος ερευνητής ανέπτυξε τους αλγορίθμους C4.5 και C5.0, που βελτίωσαν σημαντικά την απόδοση και την ακρίβεια των δένδρων μέσω τεχνικών όπως το pruning (κλάδεμα). Παράλληλα, οι Breiman, Friedman, Olshen και Stone πρότειναν το πλαίσιο CART (Classification and Regression Trees), το οποίο αποτέλεσε τη βάση για πολλές μεταγενέστερες εφαρμογές και αλγοριθμικές βελτιώσεις.

Σήμερα, τα δέντρα απόφασης χρησιμοποιούνται εκτενώς σε τομείς όπως η αναγνώριση προτύπων, η εξόρυξη δεδομένων, η ανάλυση κινδύνου και η τεχνητή νοημοσύνη. Παρά την εμφάνιση πιο σύνθετων μοντέλων, όπως τα νευρωνικά

δίκτυα τα δέντρα απόφασης παραμένουν βασικό εργαλείο λόγω της ευκολίας κατανόησης και της σταθερής τους απόδοσης σε πρακτικά προβλήματα.

4.2 Βασικές Αρχές Λειτουργίας

Τα δέντρα αποφάσεων αποτελούν μια από τις πιο δημοφιλείς και ερμηνεύσιμες μη παραμετρικές μεθόδους εποπτευόμενης μάθησης που χρησιμοποιούνται τόσο για ταξινόμηση όσο και για παλινδρόμηση. Ως μη παραμετρική μέθοδος, ένα δέντρο απόφασης δεν προϋποθέτει συγκεκριμένη μαθηματική μορφή ή κατανομή για τα δεδομένα. Αντίθετα, μαθαίνει απλούς κανόνες απόφασης που προκύπτουν από τα χαρακτηριστικά των δεδομένων, με στόχο την πρόβλεψη της τιμής μιας μεταβλητής-στόχου.

Η **ταξινόμηση (classification)** αφορά περιπτώσεις όπου η μεταβλητή-στόχος είναι κατηγορική, δηλαδή μπορεί να λάβει διακριτές τιμές που αντιπροσωπεύουν κατηγορίες ή ετικέτες. Στην πράξη, το μοντέλο «εκπαιδεύεται» με δεδομένα των οποίων οι κατηγορίες είναι γνωστές και προσπαθεί να μάθει τους κανόνες που τις διαχωρίζουν. Έτσι, μπορεί να προβλέπει σε ποια κατηγορία ανήκει μια νέα, άγνωστη εγγραφή. Εφαρμογές ταξινόμησης συναντώνται σε πλήθος πεδίων, όπως η αναγνώριση προτύπων (π.χ. αναγνώριση εικόνων ή φωνής), η ιατρική διάγνωση (π.χ. ασθενής ή υγιής), η ανίχνευση ανεπιθύμητης αλληλογραφίας (spam ή μη). Σκοπός είναι η δημιουργία ενός μοντέλου που μπορεί να κατατάσσει με ακρίβεια νέα δεδομένα στις σωστές κατηγορίες.


Αντίθετα, η **παλινδρόμηση (regression)** χρησιμοποιείται όταν η μεταβλητή-στόχος είναι συνεχής, δηλαδή μπορεί να λάβει οποιαδήποτε αριθμητική τιμή μέσα σε ένα εύρος. Σε αυτήν την περίπτωση, το δέντρο απόφασης επιχειρεί να προβλέψει μια αριθμητική τιμή βάσει των εισόδων. Για παράδειγμα, μπορεί να εκτιμήσει την τιμή ενός ακινήτου ανάλογα με χαρακτηριστικά όπως το εμβαδόν και η τοποθεσία ή να προβλέψει τη θερμοκρασία μιας ημέρας βάσει μετεωρολογικών δεδομένων. Ενώ στην ταξινόμηση ο στόχος είναι η σωστή κατηγορία, στην παλινδρόμηση ο στόχος είναι η ακριβής αριθμητική εκτίμηση.

Και στις δύο περιπτώσεις, τα δέντρα απόφασης επιδιώκει να διαχωρίσει τον χώρο των δεδομένων σε υποσύνολα όσο το δυνατόν πιο ομοιογενή ως προς τη μεταβλητή-στόχο. Η βασική διαφορά βρίσκεται στο είδος του προβλήματος που αντιμετωπίζει: η ταξινόμηση εστιάζει σε διακριτές κατηγορίες, ενώ η παλινδρόμηση σε συνεχείς τιμές. Παρόλα αυτά, η αρχή λειτουργίας τους, η σταδιακή διάσπαση του χώρου των δεδομένων μέσω κανόνων απόφασης, παραμένει κοινή.

4.3 Δομή Δέντρων Απόφασης

Η βασική δομή ενός δέντρου απόφασης αποτελείται από τρία κύρια είδη κόμβων: τη ρίζα, τους εσωτερικούς κόμβους και τα φύλλα. Η **ρίζα (root node)** βρίσκεται στην κορυφή του δέντρου και αντιπροσωπεύει το πλήρες σύνολο δεδομένων πριν από

οποιαδήποτε διάσπαση. Από αυτό το σημείο, ο αλγόριθμος επιλέγει το χαρακτηριστικό που προσφέρει τον καλύτερο διαχωρισμό και το χρησιμοποιεί για να πραγματοποιήσει την πρώτη διάσπαση των δεδομένων σε υποσύνολα. Οι **εσωτερικοί κόμβοι (internal nodes)** εκφράζουν ερωτήματα ή συνθήκες που εφαρμόζονται στα δεδομένα, με στόχο να τα χωρίσουν σε πιο ομοιογενείς ομάδες ως προς τη μεταβλητή-στόχο. Τα **φύλλα (leaf nodes)** είναι οι τελικοί κόμβοι του δέντρου και αντιστοιχούν στις τελικές αποφάσεις ή στις προβλεπόμενες τιμές. Η πορεία από τη ρίζα μέχρι ένα φύλλο αποτελεί μια ακολουθία λογικών συνθηκών (decision rules), οι οποίες συνολικά συνθέτουν τον μηχανισμό λήψης απόφασης του μοντέλου. Οι **κλάδοι (branches)** συνδέουν τους κόμβους μεταξύ τους και αντιπροσωπεύουν τα δυνατά αποτελέσματα κάθε συνθήκης. Ανάλογα με το είδος του χαρακτηριστικού, οι διακλαδώσεις μπορεί να είναι δυαδικές ή πολυκατηγορικές, σχηματίζοντας μια ιεραρχική δομή που εκτείνεται από τη ρίζα προς τα φύλλα.



Εικόνα 4. 1 Δομή δέντρου απόφασης

Η εικόνα 4.1 παρουσιάζει τη βασική ιεραρχική δομή ενός δέντρου απόφασης, η οποία αποτελείται από τη ρίζα, τους εσωτερικούς κόμβους και τα φύλλα.




Εικόνα 4. 2 Παράδειγμα λειτουργίας δέντρου απόφασης

Η εικόνα 4.2 παρουσιάζει ένα απλό παράδειγμα λειτουργίας δέντρου απόφασης, το οποίο καθοδηγεί τη λήψη απόφασης σχετικά με το αν οι συνθήκες είναι κατάλληλες για surf. Η ρίζα εκφράζει το ερώτημα «Υπάρχει κύμα;», δηλαδή την πρώτη συνθήκη που καθορίζει τη βασική διάκριση του προβλήματος. Στο παράδειγμα, ένας εσωτερικός κόμβος εξετάζει την παράμετρο της έντασης του ανέμου («Ο άνεμος είναι ισχυρός;»), ενώ ένας άλλος αξιολογεί την κατεύθυνσή του («Ο άνεμος είναι onshore ή offshore;»). Οι κλάδοι συνδέουν τους κόμβους μεταξύ τους και απεικονίζουν τις δυνατές απαντήσεις κάθε συνθήκης (π.χ. «Ναι» ή «Όχι»), καθοδηγώντας την πορεία της απόφασης μέσα στο δέντρο. Τέλος, τα φύλλα αντιστοιχούν στους τελικούς κόμβους του μοντέλου και περιλαμβάνουν τις αποφάσεις «Κάνε surf» και «Μην κάνεις surf», οι οποίες προκύπτουν μετά από μια διαδοχική ακολουθία λογικών ελέγχων από τη ρίζα προς τα κάτω.

Ανάλογα με τον τρόπο που πραγματοποιούνται οι διακλαδώσεις, τα δέντρα απόφασης διακρίνονται σε δυαδικά και πολυκατηγορικά (ή πολυδιάκλαδα).

Στα **δυαδικά δέντρα απόφασης**, κάθε εσωτερικός κόμβος διασπάται σε δύο υποκόμβους, αντιπροσωπεύοντας δύο δυνατές εκβάσεις μιας συνθήκης, όπως για παράδειγμα «αληθές/ψευδές» ή « $>$ / $\leq$ ». Αυτή η μορφή είναι ιδιαίτερα διαδεδομένη, καθώς εξασφαλίζει απλούστερη δομή και αποτελεσματικούς υπολογισμούς. Η διχοτομική τους φύση επιτρέπει την οργάνωση της πληροφορίας με τρόπο που διευκολύνει την ανάλυση, τη γενίκευση και την ερμηνεία των αποτελεσμάτων. Μέσα από τη διαδοχική εφαρμογή δυαδικών αποφάσεων, τα δεδομένα διαχωρίζονται


προοδευτικά σε ολοένα πιο εξειδικευμένα υποσύνολα, γεγονός που καθιστά τη διαδικασία λήψης απόφασης σαφή, ιεραρχική και εύκολα οπτικοποιήσιμη.



Εικόνα 4. 3 Παράδειγμα δυαδικού δέντρου απόφασης

Η εικόνα 4.3 απεικονίζεται ένα παράδειγμα δυαδικού δέντρου απόφασης, στο οποίο ο ριζικός κόμβος θέτει το ερώτημα «Είναι ο ασθενής μολυσμένος;». Από τον κόμβο αυτόν προκύπτουν δύο δυνατές εκβάσεις: «Yes» (Ναι) και «No» (Όχι). Η απάντηση «Yes» έχει επισημανθεί ως η επιλεγμένη ή σωστή απόφαση στο παράδειγμα, υποδεικνύοντας ότι ο ασθενής θεωρείται μολυσμένος. Το διάγραμμα αυτό δείχνει τη βασική λειτουργία των δυαδικών δέντρων απόφασης, στα οποία κάθε βήμα βασίζεται σε μια δυαδική επιλογή, οδηγώντας τελικά σε μια σαφή και εύκολα ερμηνεύσιμη απόφαση.

Αντίθετα, στα **πολυκατηγορικά ή πολυδιάκλαδα δέντρα (Multiclass / Multiway Trees)**, κάθε κόμβος οδηγεί σε περισσότερους από δύο κλάδους, επιτρέποντας τη διάκριση μεταξύ πολλαπλών πιθανών κατηγοριών. Η προσέγγιση αυτή αξιοποιείται όταν το υπό εξέταση χαρακτηριστικό μπορεί να λάβει περισσότερες από δύο διακριτές τιμές, με αποτέλεσμα η πληροφορία να κατανέμεται σε περισσότερες διαδρομές. Με αυτόν τον τρόπο, το δέντρο αποκτά πιο εκφραστική δομή και μπορεί να αποτυπώνει σύνθετες σχέσεις μεταξύ των δεδομένων, διατηρώντας παράλληλα την ιεραρχική και ερμηνεύσιμη φύση της διαδικασίας λήψης αποφάσεων.



Εικόνα 4. 4 Παράδειγμα πολυκατηγορικού δέντρου απόφασης

Η παραπάνω εικόνα απεικονίζεται ένα πολυκατηγορικό δέντρο απόφασης, στο οποίο ο ριζικός κόμβος θέτει το ερώτημα «Ποια είναι η αρχική ήπειρος;». Από τον κόμβο αυτό προκύπτουν πολλαπλές δυνατές εκβάσεις, που αντιστοιχούν στις κατηγορίες «Αφρική», «Ασία», «Αμερική», «Αυστραλία» και «Ευρώπη». Κάθε απάντηση οδηγεί σε διαφορετικό αποτέλεσμα, ανάλογα με την κατηγορία στην οποία ανήκει το αντικείμενο. Το διάγραμμα αυτό αποτυπώνει τη βασική λειτουργία των πολυκατηγορικών δέντρων απόφασης, στα οποία κάθε κόμβος μπορεί να οδηγεί σε περισσότερες από δύο επιλογές, επιτρέποντας στο μοντέλο να λαμβάνει πιο σύνθετες και λεπτομερείς αποφάσεις.

4.4 Διαδικασία Εκπαίδευσης του Δέντρου Απόφασης

Η εκπαίδευση ενός δέντρου απόφασης αποτελεί μια εποπτευόμενη διαδικασία μάθησης, κατά την οποία το μοντέλο κατασκευάζεται βηματικά με στόχο να ταξινομεί ή να προβλέπει σωστά τις εξόδους για νέα δεδομένα. Η διαδικασία ξεκινά από το σύνολο εκπαίδευσης (training set), το οποίο περιλαμβάνει ένα πλήθος παρατηρήσεων με συγκεκριμένα χαρακτηριστικά (features) και μία αντίστοιχη μεταβλητή-στόχο (target). Το σύνολο αυτό λειτουργεί ως “πηγή γνώσης” από την οποία το μοντέλο αντλεί πληροφορίες για να μάθει τους κανόνες που διέπουν τα δεδομένα.

- **Χαρακτηριστικά (Features):** Είναι οι μεταβλητές εισόδου που περιγράφουν κάθε παρατήρηση στο σύνολο δεδομένων και χρησιμοποιούνται από το δέντρο για τη λήψη αποφάσεων. Μπορεί να είναι αριθμητικά (π.χ. ηλικία, εισόδημα) ή κατηγορικά (π.χ. φύλο, τύπος προϊόντος), και καθορίζουν τον τρόπο με τον οποίο τα δεδομένα διαχωρίζονται σε κάθε κόμβο του δέντρου.
- **Μεταβλητή-στόχο (Target):** Είναι η μεταβλητή εξόδου που το δέντρο επιδιώκει να προβλέψει. Αντιπροσωπεύει το αποτέλεσμα ή την κατηγορία

που αντιστοιχεί σε κάθε παρατήρηση (π.χ έγκριση ή απόρριψη δανείου). Στην ταξινόμηση η ετικέτα είναι κατηγορική, ενώ στην παλινδρόμηση είναι αριθμητική.

Κατά τη διάρκεια της εκπαίδευσης, το δέντρο χρησιμοποιεί το σύνολο εκπαίδευσης για να αναγνωρίσει σχέσεις ανάμεσα στα χαρακτηριστικά εισόδου και στην μεταβλητή-στόχο. Αυτό επιτυγχάνεται μέσω της αναδρομικής διάσπασης των δεδομένων σε κόμβους, επιλέγοντας κάθε φορά το χαρακτηριστικό που προσφέρει τον βέλτιστο διαχωρισμό των κατηγοριών. Με τον τρόπο αυτό, το δέντρο «μαθαίνει» ένα σύνολο κανόνων της μορφής αν... τότε... που αποτυπώνουν τα πρότυπα και τις τάσεις που υπάρχουν στα δεδομένα.

Για παράδειγμα, σε ένα πρόβλημα πρόβλεψης αγοραστικής συμπεριφοράς, τα χαρακτηριστικά περιλαμβάνουν την ηλικία, το εισόδημα και το φύλο του καταναλωτή, ενώ η μεταβλητή-στόχος αντιπροσωπεύει το αν πραγματοποιήθηκε ή όχι αγορά. Μέσα από την ανάλυση πολλών παραδειγμάτων από το training set, το δέντρο μπορεί να γνωρίζει ότι οι πελάτες ηλικίας κάτω των 30 ετών με υψηλό εισόδημα παρουσιάζουν μεγαλύτερη πιθανότητα να αγοράσουν το προϊόν.

Όταν στη συνέχεια το μοντέλο κληθεί να αξιολογήσει νέα, άγνωστα δεδομένα, εφαρμόζει τους κανόνες που έχει αντλήσει από το σύνολο εκπαίδευσης, ώστε να παράγει μια πρόβλεψη. Η ικανότητα αυτή να εφαρμόζει τη μάθηση σε νέα δεδομένα αποτελεί τη διαδικασία της γενίκευσης, θεμελιώδες χαρακτηριστικό κάθε επιτυχημένου μοντέλου μηχανικής μάθησης.

Τεχνικές Διάσπασης

Κατά τη διαδικασία εκπαίδευσης ενός δέντρου απόφασης, η επιλογή του χαρακτηριστικού που θα χρησιμοποιηθεί για τη διάσπαση των δεδομένων σε κάθε κόμβο αποτελεί ένα από τα πιο κρίσιμα στάδια. Ο τρόπος με τον οποίο γίνεται αυτή η επιλογή επηρεάζει άμεσα τη δομή του δέντρου, την ακρίβεια των προβλέψεων και την ικανότητά του να γενικεύει σωστά σε νέα δεδομένα. Στόχος είναι η δημιουργία υποσυνόλων δεδομένων που είναι όσο το δυνατόν πιο «καθαρά», δηλαδή οι παρατηρήσεις μέσα σε κάθε κόμβο να ανήκουν, κατά το δυνατόν, στην ίδια κατηγορία του στόχου.

Για να επιτευχθεί αυτό, οι αλγόριθμοι υπολογίζουν για κάθε διαθέσιμο χαρακτηριστικό ποσοτικά μέτρα καθαρότητας ή πληροφορίας, τα οποία εκτιμούν πόσο καλά διαχωρίζει το χαρακτηριστικό τα δεδομένα. Τα κυριότερα από αυτά είναι τα εξής:

- **Εντροπία (Entropy):** Εκφράζει τον βαθμό αταξίας ή τυχαιότητας ενός συνόλου δεδομένων. Όταν όλα τα δείγματα ενός κόμβου ανήκουν στην ίδια κατηγορία, η εντροπία λαμβάνει τιμή μηδέν, γεγονός που υποδηλώνει πλήρη ομοιογένεια. Αντίθετα, όταν οι κατηγορίες κατανέμονται ομοιόμορφα, η εντροπία μεγιστοποιείται, υποδηλώνοντας υψηλό βαθμό τυχαιότητας και χαμηλή καθαρότητα του κόμβου.

- **Κέρδος Πληροφορίας (Information Gain):** Αναπαριστά τη μείωση της αβεβαιότητας που επιτυγχάνεται όταν ένα χαρακτηριστικό χρησιμοποιείται για τη διάσπαση των δεδομένων. Όσο μεγαλύτερη είναι η μείωση της εντροπίας μετά τη διάσπαση, τόσο υψηλότερο είναι το κέρδος πληροφορίας. Ένα χαρακτηριστικό με υψηλό κέρδος πληροφορίας θεωρείται περισσότερο διακριτικό και επομένως πιο κατάλληλο για τη δημιουργία κόμβων.
- **Δείκτης Gini (Gini Index):** Αποτελεί εναλλακτικό μέτρο καθαρότητας που ποσοτικοποιεί την πιθανότητα εσφαλμένης ταξινόμησης ενός δείγματος, εάν αυτό επιλεγεί τυχαία από το σύνολο. Τιμές κοντά στο μηδέν υποδηλώνουν υψηλή καθαρότητα (ομοιογένεια κατηγορίας), ενώ τιμές κοντά στο 0.5 εκφράζουν μέγιστη αβεβαιότητα και ετερογένεια.
- **Αναλογία Κέρδους Πληροφορίας (Gain Ratio):** Σε αντίθεση με το απλό Κέρδος Πληροφορίας, το οποίο μπορεί να ευνοεί χαρακτηριστικά που έχουν πολλές διαφορετικές τιμές (όπως αριθμός ταυτότητας), η Αναλογία Κέρδους Πληροφορίας λαμβάνει υπόψη και την πολυπλοκότητα της διάσπασης. Έτσι, επιλέγονται χαρακτηριστικά που προσφέρουν ουσιαστική πληροφόρηση και όχι απλώς τεχνητή διάκριση των δεδομένων, οδηγώντας σε πιο ισορροπημένες και αξιόπιστες αποφάσεις.

Αφού αξιολογηθούν όλα τα διαθέσιμα χαρακτηριστικά με βάση κάποιο από τα προαναφερθέντα κριτήρια καθαρότητας, επιλέγεται εκείνο που επιτυγχάνει τη μεγαλύτερη βελτίωση ως προς τη διάκριση των δεδομένων. Στην περίπτωση αριθμητικών χαρακτηριστικών, η διάσπαση πραγματοποιείται συνήθως με βάση ένα κατώφλι τιμής (π.χ. «Ηλικία < 35»), το οποίο χωρίζει τα δεδομένα σε δύο υποσύνολα. Αντίστοιχα, στα κατηγορικά χαρακτηριστικά, η διάκριση βασίζεται στις διακριτές τιμές των κατηγοριών (π.χ. «Τύπος προϊόντος = Premium»). Η διαδικασία αυτή επαναλαμβάνεται αναδρομικά για κάθε νέο υποσύνολο δεδομένων, οδηγώντας στη σταδιακή ανάπτυξη του δέντρου. Με κάθε νέα διάσπαση, το μοντέλο επιχειρεί να αυξήσει την ομοιογένεια των κόμβων και να μειώσει την αβεβαιότητα των προβλέψεων.

Κριτήρια Τερματισμού

Η διαδικασία διάσπασης του δέντρου συνεχίζεται μέχρι να ικανοποιηθεί κάποιο συγκεκριμένο κριτήριο τερματισμού. Ο σκοπός αυτών των κριτηρίων είναι να αποτραπεί η υπερβολική αύξηση της πολυπλοκότητας του δέντρου, που μπορεί να οδηγήσει σε υπερπροσαρμογή (overfitting). Τα πιο συνήθη κριτήρια τερματισμού περιλαμβάνουν:

- **Μέγιστο βάθος (maximum depth):** Ο καθορισμός ανώτατου βάθους περιορίζει τον αριθμό των επιπέδων κόμβων που μπορεί να δημιουργήσει το δέντρο. Με αυτόν τον τρόπο αποφεύγεται η υπερβολική λεπτομέρεια που μπορεί να προσαρμόσει το μοντέλο ακόμη και σε τυχαίες διακυμάνσεις των δεδομένων. Ένα μικρότερο βάθος οδηγεί σε πιο γενικά και σταθερά μοντέλα, αν και ενδέχεται να μειώσει ελαφρώς την ακρίβεια στα δεδομένα εκπαίδευσης.
- **Ελάχιστος αριθμός δειγμάτων ανά κόμβο (minimum samples per node):** Το κριτήριο αυτό απαιτεί κάθε κόμβος να περιέχει έναν ελάχιστο αριθμό δειγμάτων πριν επιτραπεί νέα διάσπαση. Αν ο αριθμός των δειγμάτων είναι μικρότερος από το προκαθορισμένο όριο, η διάσπαση σταματά, καθώς τα διαθέσιμα δεδομένα δεν επαρκούν για αξιόπιστη στατιστική εκτίμηση. Με αυτόν τον τρόπο μειώνεται η πιθανότητα δημιουργίας κόμβων που βασίζονται σε τυχαίους ή μη αντιπροσωπευτικούς διαχωρισμούς.
- **Ελάχιστο κέρδος πληροφορίας (minimum information gain):** Κάθε διάσπαση αξιολογείται ως προς το κέρδος πληροφορίας που προσφέρει, δηλαδή τη βελτίωση στην καθαρότητα των υποσυνόλων δεδομένων. Εάν το κέρδος αυτό είναι μικρότερο από ένα προκαθορισμένο όριο, η διάσπαση απορρίπτεται ως μη ουσιαστική. Το κριτήριο αυτό συμβάλλει στην αποφυγή περιττών διασπάσεων που αυξάνουν το μέγεθος του δέντρου χωρίς να βελτιώνουν σημαντικά την απόδοσή του.
- **Πλήρης καθαρότητα (pure nodes):** Η διαδικασία διάσπασης τερματίζεται όταν ένας κόμβος φτάσει σε κατάσταση πλήρους καθαρότητας, δηλαδή όταν όλα τα δείγματα που περιέχει ανήκουν στην ίδια κατηγορία ή παρουσιάζουν μηδενική διακύμανση στην τιμή-στόχο. Σε αυτήν την περίπτωση, περαιτέρω διάσπαση δεν προσφέρει πρόσθετη πληροφορία ούτε βελτίωση της πρόβλεψης. Η πλήρης καθαρότητα θεωρείται φυσικό σημείο τερματισμού, καθώς ο κόμβος αντιπροσωπεύει μια σαφώς ορισμένη απόφαση ή τιμή.

Η χρήση αυτών των υπερπαραμέτρων λειτουργεί ως ένας προληπτικός μηχανισμός ελέγχου της ανάπτυξης του δέντρου, διασφαλίζοντας ότι η εκπαίδευση δεν θα συνεχιστεί πέρα από το σημείο όπου σταματά να προσφέρει ουσιαστική πληροφορία. Ωστόσο, ακόμη και με την ύπαρξη αυτών των περιορισμών, το δέντρο ενδέχεται να παραμείνει πιο πολύπλοκο από όσο χρειάζεται. Σε αυτό το σημείο έρχεται να συμβάλει μια δεύτερη, εξίσου σημαντική διαδικασία, το κλάδεμα (pruning).

4.5 Κλάδεμα (Pruning)

Το κλάδεμα αποτελεί το στάδιο που ακολουθεί την αρχική εκπαίδευση του δέντρου απόφασης και έχει ως βασικό στόχο τη βελτίωση της ικανότητας γενίκευσης του μοντέλου. Κατά τη διάρκεια της εκπαίδευσης, το δέντρο μπορεί να προσαρμοστεί υπερβολικά στα δεδομένα του συνόλου εκπαίδευσης, δημιουργώντας περίπλοκες διασπάσεις που αναπαριστούν όχι πραγματικά πρότυπα, αλλά τυχαίες διακυμάνσεις ή «θόρυβο». Ο όρος «θόρυβος» αναφέρεται σε μη συστηματικά ή τυχαία σφάλματα και αποκλίσεις στα δεδομένα, τα οποία δεν εκφράζουν ουσιαστικές σχέσεις. Το φαινόμενο αυτό, γνωστό ως υπερπροσαρμογή (overfitting), μειώνει την απόδοση του μοντέλου όταν αυτό καλείται να προβλέψει νέα, άγνωστα δεδομένα. Το κλάδεμα επιχειρεί να αντιμετωπίσει το πρόβλημα αυτό απλοποιώντας τη δομή του δέντρου, μέσω της αφαίρεσης κόμβων ή ολόκληρων υποδέντρων που δεν συνεισφέρουν ουσιαστικά στη βελτίωση της προβλεπτικής του ικανότητας.

Υπάρχουν δύο κύριες προσεγγίσεις κλαδέματος:

- **Προληπτικό κλάδεμα (pre-pruning):** Στην προσέγγιση αυτή, η διαδικασία ανάπτυξης του δέντρου σταματά πρόωρα, όταν διαπιστωθεί ότι μια περαιτέρω διάσπαση δεν επιφέρει ουσιαστικό όφελος. Αυτό καθορίζεται από κριτήρια όπως το ελάχιστο Information Gain, ο ελάχιστος αριθμός δειγμάτων που απαιτείται για να δημιουργηθεί ένας νέος κόμβος ή το μέγιστο επιτρεπόμενο βάθος του δέντρου. Με αυτόν τον τρόπο, αποτρέπεται η δημιουργία υπερβολικά εξειδικευμένων κόμβων που θα περιέγραφαν μόνο μικρά, μη αντιπροσωπευτικά υποσύνολα των δεδομένων.
- **Εκ των υστέρων κλάδεμα (post-pruning):** Σε αυτή την προσέγγιση, το δέντρο αναπτύσσεται πλήρως μέχρι να επιτευχθεί μέγιστη καθαρότητα στους κόμβους και στη συνέχεια πραγματοποιείται αναδρομική αφαίρεση κόμβων που δεν προσφέρουν ουσιαστική βελτίωση στην απόδοση. Η διαδικασία αυτή συνήθως βασίζεται σε ένα ξεχωριστό σύνολο επικύρωσης (validation set), το οποίο χρησιμοποιείται για να αξιολογηθεί η ικανότητα γενίκευσης του μοντέλου μετά από κάθε πιθανή αφαίρεση κόμβου. Αν η αφαίρεση ενός κόμβου οδηγεί σε καλύτερη απόδοση στο validation set, τότε ο κόμβος αυτός απομακρύνεται οριστικά.

Ενώ τα κριτήρια τερματισμού περιορίζουν την ανάπτυξη του δέντρου κατά τη φάση εκπαίδευσης, το κλάδεμα λειτουργεί εκ των υστέρων, εντοπίζοντας και απομακρύνοντας τμήματα που αποτυπώνουν περισσότερο τον θόρυβο παρά τις γενικές τάσεις των δεδομένων. Με αυτόν τον τρόπο, το τελικό δέντρο καθίσταται απλούστερο, πιο αποδοτικό και ικανό να γενικεύει αποτελεσματικότερα.

4.6 Παράδειγμα Διαδικασίας Εκπαίδευσης Δέντρου Απόφασης

Για να γίνει πιο κατανοητή η διαδικασία εκπαίδευσης του δέντρου απόφασης, εξετάζεται ένα απλό παράδειγμα ταξινόμησης. Σκοπός είναι να προβλέψει αν η δραστηριότητα “παιχνίδι” θα πραγματοποιηθεί ή όχι, με βάση τέσσερα χαρακτηριστικά των καιρικών συνθηκών. Το training set περιλαμβάνει συνολικά 14 παρατηρήσεις.

Τα **χαρακτηριστικά (features)** είναι:

- Outlook (Καιρική κατάσταση): λαμβάνει τιμές *Sunny*, *Overcast*, ή *Rain*.
- Temperature (Θερμοκρασία): λαμβάνει τιμές *Hot*, *Mild*, ή *Cool*.
- Humidity (Υγρασία): λαμβάνει τιμές *High* ή *Normal*.
- Windy (Άνεμος): λαμβάνει τιμές *True* ή *False*.

Η **μεταβλητή στόχος (target)** είναι:


- Class (Play): δηλώνει αν η δραστηριότητα θα πραγματοποιηθεί ναι (*Yes*) ή όχι (*No*).

Πίνακας 4. 1 Παράδειγμα συνόλου εκπαίδευσης (*Training Set*)

No.	Outlook	Temperature	Humidity	Windy	Play
1	Sunny	Hot	High	False	No
2	Sunny	Hot	High	True	No
3	Overcast	Hot	High	False	Yes
4	Rain	Mild	High	False	Yes
5	Rain	Cool	Normal	False	Yes
6	Rain	Cool	Normal	True	No
7	Overcast	Cool	Normal	True	Yes
8	Sunny	Mild	High	False	No

9	Sunny	Cool	Normal	False	Yes
10	Rain	Mild	Normal	False	Yes
11	Sunny	Mild	Normal	True	Yes
12	Overcast	Mild	High	True	Yes
13	Overcast	Hot	Normal	False	Yes
14	Rain	Mild	High	True	No

Στο συγκεκριμένο παράδειγμα αλγόριθμος υπολογίζει για κάθε χαρακτηριστικό το Information Gain για να πραγματοποιήσει τις διασπάσεις του δέντρου. Η τελική δομή του δέντρου διακρίνεται στο παρακάτω σχήμα.



Εικόνα 4. 5 Παράδειγμα πολυκατηγορικού δέντρου απόφασης

Από την εικόνα διακρίνεται ότι το χαρακτηριστικό Outlook παρουσιάζει το μεγαλύτερο κέρδος πληροφορίας, καθώς διαχωρίζει αποτελεσματικά τις παρατηρήσεις σε πιο «καθαρές» ομάδες.

Έτσι, το Outlook επιλέγεται ως η ρίζα του δέντρου, και τα δεδομένα χωρίζονται σε τρεις κατηγορίες: sunny, overcast και rain. Στη συνέχεια, η διαδικασία επαναλαμβάνεται αναδρομικά για κάθε υποσύνολο. Για παράδειγμα:

- Όταν το **Outlook = Overcast**, όλες οι περιπτώσεις οδηγούν σε **Play = Yes**, άρα δεν απαιτείται περαιτέρω διάσπαση.

- Όταν το **Outlook = Sunny**, το επόμενο καλύτερο χαρακτηριστικό είναι η **Humidity**, καθώς μειώνει περισσότερο την αβεβαιότητα μέσα σε αυτό το υποσύνολο.
- Όταν το **Outlook = Rain**, το χαρακτηριστικό **Windy** προσφέρει την καλύτερη διάκριση μεταξύ των κατηγοριών.

Όταν ολοκληρωθεί η διαδικασία εκπαίδευσης, το δέντρο είναι πλέον σε θέση να πραγματοποιεί προβλέψεις για νέα, άγνωστα δεδομένα, εφαρμόζοντας τους κανόνες που έχει αντλήσει από το σύνολο εκπαίδευσης. Για παράδειγμα, αν δοθεί μια νέα παρατήρηση με τιμές *Outlook = Rain, Windy = False, Humidity = Normal* και *Temperature = Mild*, το δέντρο θα ακολουθήσει τη διαδρομή που αντιστοιχεί στις συγκεκριμένες τιμές των χαρακτηριστικών. Ξεκινώντας από τη ρίζα (*Outlook*), θα επιλέξει τον κλάδο *Rain*, στη συνέχεια θα εξετάσει το χαρακτηριστικό *Windy*, και, καθώς η τιμή είναι *False*, θα καταλήξει στο φύλλο *Play = Yes*.

Η διαδικασία αυτή αποδεικνύει τον τρόπο με τον οποίο ένα δέντρο αξιοποιεί τη γνώση που έχει αποκτήσει από τα δεδομένα εκπαίδευσης για να λάβει αποφάσεις σε νέες περιπτώσεις. Με αυτόν τον τρόπο, μπορεί να προβλέπει αποτελέσματα χωρίς να χρειάζεται να ανακαλεί τα αρχικά δεδομένα, αλλά στηριζόμενο στους κανόνες που έχει δημιουργήσει κατά τη διάρκεια της μάθησης.

Συνολικά το παράδειγμα αποτυπώνει τη λειτουργία του δέντρου απόφασης: πώς επιλέγονται τα χαρακτηριστικά, πώς καθορίζονται τα κριτήρια διάσπασης και πώς το τελικό μοντέλο μπορεί να προβλέπει νέες περιπτώσεις.

4.7 Αξιολόγηση Απόδοσης

Η αξιολόγηση της απόδοσης ενός δέντρου απόφασης αποτελεί κρίσιμο στάδιο της διαδικασίας μηχανικής μάθησης. Σκοπός της είναι να εκτιμηθεί η ικανότητα του μοντέλου να γενικεύει σωστά τη γνώση που απέκτησε από τα δεδομένα εκπαίδευσης, προβλέποντας αποτελέσματα για νέα, άγνωστα δεδομένα. Μέσω της αξιολόγησης καθίσταται δυνατός ο εντοπισμός φαινομένων υπερπροσαρμογής (*overfitting*), καθώς και η ρύθμιση κρίσιμων υπερπαραμέτρων του μοντέλου με σκοπό τη βελτιστοποίηση της γενικευτικής του ικανότητας.

Για την αντικειμενική αξιολόγηση της απόδοσης, το αρχικό σύνολο δεδομένων διαχωρίζεται σε ανεξάρτητα υποσύνολα, καθένα από τα οποία εξυπηρετεί διαφορετικό σκοπό:

- **Σύνολο εκπαίδευσης (Training set):** Αποτελεί το κύριο τμήμα των δεδομένων και χρησιμοποιείται για να μάθει το μοντέλο τους κανόνες που συνδέουν τα χαρακτηριστικά εισόδου με τη μεταβλητή-στόχο. Είναι το στάδιο όπου το μοντέλο «εκπαιδεύεται», αναγνωρίζοντας πρότυπα και σχέσεις μέσα στα

δεδομένα.

- **Σύνολο επικύρωσης (Validation set):** Χρησιμοποιείται για την αποτίμηση της απόδοσης του μοντέλου σε δεδομένα που δεν έχουν χρησιμοποιηθεί κατά την εκπαίδευση, καθώς και για τη ρύθμιση των υπερπαραμέτρων του (όπως το μέγιστο βάθος ή το ελάχιστο μέγεθος κόμβου σε ένα δέντρο απόφασης). Η χρήση του συνόλου επικύρωσης επιτρέπει τον εντοπισμό του σημείου στο οποίο το μοντέλο αρχίζει να υπερπροσαρμόζεται στα δεδομένα εκπαίδευσης, συμβάλλοντας έτσι στη βελτίωση της γενικευσιμότητάς του.
- **Σύνολο ελέγχου (Test set):** Αποτελεί το τελικό και πλήρως ανεξάρτητο υποσύνολο, το οποίο χρησιμοποιείται αποκλειστικά για την εκτίμηση της τελικής απόδοσης του μοντέλου σε νέα, άγνωστα δεδομένα. Το σύνολο ελέγχου δεν συμμετέχει σε καμία φάση εκπαίδευσης ή ρύθμισης παραμέτρων, ώστε να παρέχει μια αμερόληπτη εκτίμηση της ικανότητας γενίκευσης του μοντέλου σε πραγματικά περιβάλλοντα.

Όταν το διαθέσιμο δείγμα είναι περιορισμένο, εφαρμόζεται η **διασταυρούμενη επικύρωση (cross-validation)**. Η μέθοδος αυτή προϋποθέτει τον χωρισμό του συνόλου δεδομένων σε k ισομεγέθη τμήματα (folds). Το μοντέλο εκπαιδεύεται k φορές, κάθε φορά χρησιμοποιώντας διαφορετικό τμήμα ως σύνολο ελέγχου και τα υπόλοιπα $k-1$ τμήματα για εκπαίδευση. Η συνολική επίδοση του μοντέλου υπολογίζεται ως ο μέσος όρος των επιμέρους αποδόσεων, προσφέροντας έτσι μια σταθερότερη και πιο αξιόπιστη εκτίμηση της γενικευσιμότητας και της προβλεπτικής του ικανότητας.

Μετρικές Αξιολόγησης της Απόδοσης

Η επίδοση ενός δέντρου απόφασης μπορεί να αποτιμηθεί με βάση διάφορες μετρικές, ανάλογα με το είδος του προβλήματος (ταξινόμηση ή παλινδρόμηση). Οι μετρικές αυτές προσφέρουν ποσοτική εκτίμηση της ακρίβειας, της σταθερότητας και της αξιοπιστίας του μοντέλου.

Μετρικές για Ταξινόμηση (Classification)

- **Accuracy (Ακρίβεια):** Αποτυπώνει το ποσοστό των παρατηρήσεων που ταξινομήθηκαν σωστά από το δέντρο, σε σχέση με το συνολικό πλήθος των περιπτώσεων. Αποτελεί μια γενική ένδειξη απόδοσης του μοντέλου, αλλά μπορεί να είναι παραπλανητική σε ανισόρροπα σύνολα δεδομένων όπου ορισμένες κατηγορίες υπερσχύουν αριθμητικά.

- **Precision (Ακρίβεια Θετικών προβλέψεων):** Υπολογίζει πόσες από τις περιπτώσεις που το δέντρο προέβλεψε ως «θετικές» ήταν πράγματι σωστές. Αντικατοπτρίζει το ποσοστό των έγκυρων θετικών προβλέψεων και εκφράζει το πόσο «προσεκτικό» είναι το μοντέλο όταν χαρακτηρίζει μια παρατήρηση ως θετική.
- **Recall (Ανάκληση ή Ευαισθησία):** Υποδεικνύει το ποσοστό των πραγματικών θετικών περιπτώσεων που εντόπισε σωστά το δέντρο. Αξιολογεί, δηλαδή, την ικανότητα του μοντέλου να ανιχνεύει όλες τις θετικές παρατηρήσεις, αποτυπώνοντας την ευαισθησία του σε σφάλματα παράλειψης.
- **F1-score:** Συνδυάζει την ακρίβεια (Precision) και την ανάκληση (Recall) σε έναν ενιαίο δείκτη απόδοσης, εξισορροπώντας την ανάγκη για ακριβείς και πλήρεις προβλέψεις. Είναι ιδιαίτερα χρήσιμη σε περιπτώσεις ανισόρροπων κατηγοριών.
- **Καμπύλη ROC και AUC (Area Under Curve):** Η καμπύλη ROC παρουσιάζει τη σχέση μεταξύ των αληθώς θετικών και των ψευδώς θετικών προβλέψεων του δέντρου για διαφορετικά κατώφλια ταξινόμησης. Το εμβαδόν κάτω από την καμπύλη (AUC) εκφράζει τη συνολική ικανότητα του μοντέλου να διαχωρίζει σωστά τις κατηγορίες. Όσο μεγαλύτερη η τιμή AUC, τόσο υψηλότερη η διακριτική ικανότητα του δέντρου.

Μετρικές για Παλινδρόμηση (Regression)

- **Mean Squared Error (Μέσο Τετραγωνικό Σφάλμα):** Υπολογίζει τον μέσο βαθμό απόκλισης των προβλεπόμενων τιμών του δέντρου από τις πραγματικές τιμές. Δίνει μεγαλύτερη βαρύτητα στα μεγάλα σφάλματα, αναδεικνύοντας την ακρίβεια του μοντέλου σε αριθμητικές προβλέψεις.
- **Mean Absolute Error (Μέσο Απόλυτο Σφάλμα):** Εκφράζει τον μέσο βαθμό απόλυτης απόκλισης μεταξύ των πραγματικών και των προβλεπόμενων τιμών. Παρέχει μια πιο «ανθεκτική» εκτίμηση της απόδοσης του δέντρου, καθώς δεν επηρεάζεται έντονα από ακραίες τιμές.
- **R^2 (Συντελεστής Προσδιορισμού):** Δείχνει το ποσοστό της διακύμανσης της εξαρτημένης μεταβλητής που εξηγείται από το δέντρο παλινδρόμησης. Υψηλές τιμές του R^2 υποδηλώνουν ότι το μοντέλο προσαρμόζεται ικανοποιητικά στα δεδομένα, ενώ χαμηλές τιμές φανερώνουν περιορισμένη ικανότητα πρόβλεψης.

Η αξιολόγηση ενός δέντρου απόφασης δεν περιορίζεται σε μία μόνο μετρική, αλλά αποτελεί μια πολυδιάστατη διαδικασία που συνδυάζει στατιστικά κριτήρια και πειραματικές δοκιμές. Μέσω του διαχωρισμού των δεδομένων, των κατάλληλων μετρικών, εξασφαλίζεται ότι το τελικό μοντέλο είναι αξιόπιστο, ισορροπημένο και ικανό να γενικεύει σωστά. Η σωστή αξιολόγηση δεν αποτελεί απλώς ένα τελικό στάδιο της διαδικασίας μάθησης, αλλά βασική προϋπόθεση για την εγκυρότητα κάθε μοντέλου μηχανικής μάθησης.

4.8 Σύνοψη

Στο παρόν κεφάλαιο παρουσιάστηκαν τα δέντρα απόφασης, μία από τις πιο διαδεδομένες και ερμηνεύσιμες τεχνικές μηχανικής μάθησης για προβλήματα ταξινόμησης και παλινδρόμησης. Αναλύθηκαν οι βασικές αρχές λειτουργίας τους, η δομή τους και τα κύρια συστατικά τους, όπως η ρίζα, οι εσωτερικοί κόμβοι, οι κλάδοι και τα φύλλα.

Στη συνέχεια, περιγράφηκε η διαδικασία εκπαίδευσης ενός δέντρου απόφασης, δίνοντας έμφαση στις τεχνικές διάσπασης των δεδομένων και στα κριτήρια επιλογής χαρακτηριστικών, όπως η Εντροπία (Entropy), το Κέρδος Πληροφορίας (Information Gain), ο Δείκτης Gini και η Αναλογία Κέρδους Πληροφορίας (Gain Ratio). Παρουσιάστηκαν επίσης τα βασικά κριτήρια τερματισμού της εκπαίδευσης, καθώς και οι τεχνικές κλαδέματος (pruning) που συμβάλλουν στη μείωση της υπερπροσαρμογής και στη βελτίωση της γενικευτικής ικανότητας του μοντέλου.

Επιπλέον, μέσα από ένα αναλυτικό παράδειγμα εκπαίδευσης, παρουσιάστηκε ο τρόπος με τον οποίο ένα δέντρο απόφασης εξάγει κανόνες από τα δεδομένα και τους αξιοποιεί για την πραγματοποίηση προβλέψεων σε νέες περιπτώσεις. Τέλος, εξετάστηκαν οι κυριότερες μετρικές αξιολόγησης της απόδοσης των μοντέλων, τόσο για προβλήματα ταξινόμησης όσο και για προβλήματα παλινδρόμησης.

Η μελέτη των δέντρων απόφασης αποτελεί απαραίτητο θεωρητικό υπόβαθρο για την κατανόηση πιο εξειδικευμένων αλγορίθμων που βασίζονται στην ίδια φιλοσοφία κατασκευής μοντέλων. Στο επόμενο κεφάλαιο παρουσιάζεται αναλυτικά ο αλγόριθμος CART (Classification and Regression Trees), μία από τις σημαντικότερες και ευρύτερα χρησιμοποιούμενες μεθόδους δημιουργίας δέντρων απόφασης.

Κεφάλαιο 5: Αλγόριθμος CART

Στο παρόν κεφάλαιο παρουσιάζεται ο αλγόριθμος **CART (Classification and Regression Trees)**, ο οποίος αποτελεί μία από τις πιο διαδεδομένες μεθόδους κατασκευής δέντρων απόφασης. Αρχικά αναλύεται η βασική λειτουργία του αλγορίθμου και παρουσιάζεται η διαδικασία μέσω της οποίας η λογική του δέντρου απόφασης μπορεί να μετατραπεί σε ένα σύνολο κανόνων που αναπαρίστανται σε πίνακες αποφάσεων Decision Model and Notation (DMN). Ιδιαίτερη έμφαση δίνεται στη μεθοδολογία μετατροπής των decision paths ενός δέντρου αποφάσεων σε δομημένους κανόνες DMN, επιτρέποντας την ενσωμάτωση της γνώσης που προκύπτει από δεδομένα σε συστήματα Business Process Management (BPM). Μέσα από την ανάλυση της μεθόδου και την παρουσίαση ενός παραδείγματος εφαρμογής αναδεικνύεται ο τρόπος με τον οποίο τα δέντρα απόφασης μπορούν να αξιοποιηθούν για την υποστήριξη διαφανών και αυτοματοποιημένων διαδικασιών λήψης αποφάσεων.

5.1 Ερευνητικό πρόβλημα

Η αξιοποίηση τεχνικών μηχανικής μάθησης σε συστήματα Διαχείρισης Επιχειρησιακών Διαδικασιών (Business Process Management – BPM) έχει αυξηθεί σημαντικά τα τελευταία χρόνια, καθώς επιτρέπει την εξαγωγή χρήσιμης γνώσης από δεδομένα και την υποστήριξη της αυτοματοποιημένης λήψης αποφάσεων. Μεταξύ των πλέον διαδεδομένων μεθόδων ταξινόμησης συγκαταλέγονται τα δέντρα αποφάσεων, τα οποία χρησιμοποιούνται ευρέως σε προβλήματα πρόβλεψης, ανάλυσης δεδομένων και υποστήριξης αποφάσεων.

Παρά τα σημαντικά τους πλεονεκτήματα, η ενσωμάτωση της λογικής των δέντρων αποφάσεων σε περιβάλλοντα BPM παρουσιάζει ορισμένες προκλήσεις. Στα συστήματα διαχείρισης επιχειρησιακών διαδικασιών, οι αποφάσεις και οι κανόνες επιχειρησιακής λογικής μοντελοποιούνται συνήθως μέσω πινάκων αποφάσεων που βασίζονται στο πρότυπο Decision Model and Notation (DMN). Οι πίνακες αυτοί παρέχουν έναν τυποποιημένο τρόπο αναπαράστασης των κανόνων και μπορούν να εκτελεστούν από εξειδικευμένα εργαλεία BPM.

Το βασικό πρόβλημα προκύπτει από τη διαφορετική μορφή αναπαράστασης της γνώσης στα δύο μοντέλα. Τα δέντρα αποφάσεων οργανώνουν τη λογική τους σε μια ιεραρχική δομή κόμβων, όπου κάθε κόμβος αντιστοιχεί σε μια συνθήκη διάσπασης και κάθε διαδρομή από τη ρίζα έως ένα φύλλο αντιπροσωπεύει μια ακολουθία ελέγχων πάνω στα χαρακτηριστικά των δεδομένων. Αντίθετα, οι πίνακες αποφάσεων DMN χρησιμοποιούν μια επίπεδη δομή κανόνων, στην οποία κάθε γραμμή αντιστοιχεί σε έναν πλήρη κανόνα απόφασης.

Η διαφορά αυτή καθιστά δύσκολη την άμεση αντιστοίχιση μεταξύ των δύο μορφών αναπαράστασης. Επιπλέον, η απουσία καθιερωμένων διαδικασιών που να πραγματοποιούν τη μετατροπή αυτή με αυτοματοποιημένο τρόπο δημιουργεί ένα κενό στη σύνδεση μεταξύ μοντέλων μηχανικής μάθησης και συστημάτων BPM.

Στο πλαίσιο αυτό, στόχος της προτεινόμενης προσέγγισης είναι η ανάπτυξη μιας μεθοδολογίας που επιτρέπει την αυτόματη μετατροπή ενός δέντρου αποφάσεων σε πίνακα αποφάσεων DMN, ο οποίος μπορεί να αποθηκευτεί σε μορφή XML και να χρησιμοποιηθεί σε σύγχρονες πλατφόρμες BPM, όπως το Camunda Modeler. Η διαδικασία βασίζεται στην ανάλυση της δομής του δέντρου και στην εξαγωγή των διαδρομών από τη ρίζα έως τα φύλλα, οι οποίες αντιστοιχούν σε κανόνες της μορφής if-then. Οι κανόνες αυτοί μετατρέπονται σε γραμμές ενός πίνακα αποφάσεων, δημιουργώντας μια τυποποιημένη και εύκολα εκτελέσιμη αναπαράσταση της λογικής του μοντέλου.

Με τον τρόπο αυτό επιτυγχάνεται η γεφύρωση μεταξύ τεχνικών μηχανικής μάθησης και συστημάτων διαχείρισης επιχειρησιακών αποφάσεων, επιτρέποντας τη μεταφορά της γνώσης που εξάγεται από δεδομένα σε μορφή κατανοητών και επαναχρησιμοποιήσιμων επιχειρησιακών κανόνων.

5.2 Ο Αλγόριθμος CART για Εξαγωγή Κανόνων

Για την υλοποίηση της προτεινόμενης μεθοδολογίας απαιτείται αρχικά η δημιουργία ενός δέντρου αποφάσεων, από το οποίο θα εξαχθούν οι κανόνες που στη συνέχεια θα μετατραπούν σε πίνακα αποφάσεων DMN. Για τον σκοπό αυτό χρησιμοποιείται ο αλγόριθμος CART (Classification and Regression Trees), ο οποίος αποτελεί μία από τις πιο διαδεδομένες και αξιόπιστες μεθόδους δημιουργίας δέντρων αποφάσεων στη μηχανική μάθηση.

Ο αλγόριθμος CART αναπτύχθηκε από τους Breiman, Friedman, Olshen και Stone και χρησιμοποιείται τόσο για προβλήματα ταξινόμησης όσο και για προβλήματα παλινδρόμησης. Στην περίπτωση της ταξινόμησης, στόχος του είναι η δημιουργία ενός μοντέλου το οποίο κατηγοριοποιεί τα δεδομένα με βάση τις τιμές των χαρακτηριστικών τους. Ένα σημαντικό χαρακτηριστικό του αλγορίθμου είναι ότι μπορεί να χειριστεί αποτελεσματικά αριθμητικά (συνεχή) δεδομένα, καθώς πραγματοποιεί διαχωρισμούς με βάση κατώφλια τιμών των χαρακτηριστικών.

Η βασική ιδέα του αλγορίθμου είναι η επαναληπτική διάσπαση ενός συνόλου δεδομένων σε μικρότερα και περισσότερο ομοιογενή υποσύνολα. Η διαδικασία ξεκινά από τον κόμβο ρίζας, ο οποίος περιλαμβάνει όλα τα δεδομένα εκπαίδευσης. Στη συνέχεια, ο αλγόριθμος εξετάζει τα διαθέσιμα χαρακτηριστικά και εντοπίζει το χαρακτηριστικό και το αντίστοιχο κατώφλι τιμής που οδηγούν στον καλύτερο δυνατό διαχωρισμό των δεδομένων.

Για την αξιολόγηση της ποιότητας ενός διαχωρισμού χρησιμοποιείται ο δείκτης Gini. Ο δείκτης αυτός μετρά τον βαθμό ετερογένειας των δειγμάτων που περιέχονται σε έναν κόμβο. Όσο μικρότερη είναι η τιμή του δείκτη, τόσο πιο ομοιογενής θεωρείται ο κόμβος, γεγονός που υποδηλώνει ότι τα περισσότερα δείγματα ανήκουν στην ίδια κατηγορία.

Κατά τη διαδικασία εκπαίδευσης, ο αλγόριθμος επιλέγει το χαρακτηριστικό και το κατώφλι που οδηγούν στη μεγαλύτερη μείωση της τιμής του δείκτη Gini. Με τον

τρόπο αυτό δημιουργούνται δύο νέα υποσύνολα δεδομένων, τα οποία αποτελούν τους επόμενους κόμβους του δέντρου. Η διαδικασία αυτή επαναλαμβάνεται αναδρομικά μέχρι να ικανοποιηθούν συγκεκριμένα κριτήρια τερματισμού, όπως η επίτευξη υψηλής ομοιογένειας στους κόμβους ή ο περιορισμός του μεγέθους του δέντρου.

Το τελικό αποτέλεσμα είναι ένα δυαδικό δέντρο αποφάσεων, στο οποίο κάθε εσωτερικός κόμβος αντιστοιχεί σε μία συνθήκη διάσπασης, ενώ κάθε φύλλο αντιπροσωπεύει την τελική πρόβλεψη του μοντέλου. Κάθε διαδρομή από τη ρίζα μέχρι ένα φύλλο μπορεί να ερμηνευθεί ως ένας κανόνας απόφασης της μορφής:

IF συνθήκη₁ AND συνθήκη₂ AND ... THEN αποτέλεσμα.

Η ιδιότητα αυτή επιτρέπει την αναπαράσταση της λογικής του μοντέλου σε μορφή κανόνων απόφασης. Κάθε διαδρομή από τη ρίζα του δέντρου μέχρι ένα φύλλο αντιστοιχεί σε έναν κανόνα της μορφής if-then, ο οποίος περιγράφει τις συνθήκες υπό τις οποίες ένα παράδειγμα ταξινομείται σε μια συγκεκριμένη κατηγορία. Οι κανόνες που προκύπτουν από το δέντρο περιλαμβάνουν συνθήκες με αριθμητικά κατώφλια τιμών, γεγονός που οδηγεί συχνά σε αρκετά λεπτομερείς περιγραφές των δεδομένων. Παρά τη λεπτομέρεια αυτή, οι κανόνες αυτοί μπορούν να αξιοποιηθούν ως βάση για τη μετατροπή της λογικής του μοντέλου σε πίνακα αποφάσεων DMN, επιτρέποντας τη σύνδεση μεταξύ μοντέλων μηχανικής μάθησης και συστημάτων επιχειρησιακών αποφάσεων.

5.3 Μεθοδολογία Εξαγωγής Κανόνων με τον CART

Η μεθοδολογία που παρουσιάζεται βασίζεται σε μια αυτοματοποιημένη διαδικασία μετατροπής ενός δέντρου αποφάσεων σε έναν πίνακα αποφάσεων DMN (Decision Model and Notation). Η υλοποίηση πραγματοποιείται εξ ολοκλήρου σε γλώσσα προγραμματισμού Python και οργανώνεται γύρω από δύο βασικές κλάσεις, την **xmlDmn**, η οποία περιλαμβάνει τις συναρτήσεις για τη δημιουργία και διαχείριση της δομής ενός πίνακα αποφάσεων σε μορφή XML σύμφωνα με το πρότυπο DMN, και την **clfDmn**, η οποία ενσωματώνει το εκπαιδευμένο δέντρο απόφασης και υλοποιεί τη διαδικασία εξαγωγής των κανόνων από τη δομή του μοντέλου.

Η συνολική διαδικασία περιλαμβάνει τα στάδια της εκπαίδευσης του μοντέλου, της ανάλυσης της δομής του δέντρου, της ανακατασκευής των διαδρομών απόφασης (decision paths) και, τέλος, της μετατροπής των συνθηκών σε κανόνες ενός πίνακα αποφάσεων DMN.

Πιο συγκεκριμένα η διαδικασία ορίζεται ως εξής:

1. Εκπαίδευση και Ανάλυση του Δέντρου Απόφασης

Η διαδικασία ξεκινά με τη φόρτωση του συνόλου δεδομένων και την εκπαίδευση ενός μοντέλου δέντρου αποφάσεων χρησιμοποιώντας τον ταξινομητή DecisionTreeClassifier της βιβλιοθήκης scikit-learn. Κατά το στάδιο αυτό τα δεδομένα προετοιμάζονται κατάλληλα, ενώ καθορίζονται τα χαρακτηριστικά που θα

χρησιμοποιηθούν ως μεταβλητές εισόδου, καθώς και η μεταβλητή κλάσης που αποτελεί την έξοδο του μοντέλου.

Μετά την εκπαίδευση, το μοντέλο δημιουργεί ένα δέντρο αποφάσεων στο οποίο κάθε εσωτερικός κόμβος περιέχει μια συνθήκη διαχωρισμού βασισμένη σε κάποιο χαρακτηριστικό και σε ένα συγκεκριμένο κατώφλι τιμής. Μέσω αυτών των διαδοχικών διαχωρισμών το αρχικό σύνολο δεδομένων χωρίζεται σε μικρότερα υποσύνολα, τα οποία είναι περισσότερο ομοιογενή ως προς την κλάση τους. Οι τελικοί κόμβοι του δέντρου, γνωστοί ως κόμβοι-φύλλα, αντιστοιχούν στις τελικές προβλέψεις του μοντέλου.

Η ανάλυση της δομής του δέντρου πραγματοποιείται στο πλαίσιο της κλάσης *clfDmn*, η οποία αξιοποιεί το εκπαιδευμένο μοντέλο για να εξαγάγει τις απαραίτητες πληροφορίες της δομής του, όπως τους κόμβους απόφασης, τα χαρακτηριστικά που χρησιμοποιούνται στους διαχωρισμούς και τα αντίστοιχα κατώφλια τιμών. Η πληροφορία αυτή αποτελεί τη βάση για τη μετατροπή της δομής του δέντρου σε σύνολο κανόνων απόφασης.

2. Αναδόμηση των Decision Paths

Στο επόμενο στάδιο εντοπίζονται όλοι οι κόμβοι-φύλλα του δέντρου αποφάσεων. Κάθε φύλλο αντιπροσωπεύει μια τελική απόφαση του μοντέλου και αντιστοιχεί σε μία συγκεκριμένη κλάση εξόδου.

Η διαδικασία αυτή υλοποιείται επίσης στο πλαίσιο της κλάσης *clfDmn*, όπου ανακατασκευάζεται η διαδρομή που οδηγεί από τη ρίζα του δέντρου μέχρι κάθε φύλλο. Η διαδρομή αυτή αποτελεί μια ακολουθία συνθηκών που εφαρμόζονται σε διαφορετικά χαρακτηριστικά του συνόλου δεδομένων. Κάθε συνθήκη εκφράζει έναν περιορισμό σε μια μεταβλητή εισόδου, συνήθως με τη μορφή σύγκρισης με κάποιο κατώφλι τιμής.

Η συλλογή όλων αυτών των συνθηκών επιτρέπει την πλήρη περιγραφή της διαδρομής απόφασης που οδηγεί στο συγκεκριμένο φύλλο. Δεδομένου ότι όλα τα δείγματα που καταλήγουν στο ίδιο φύλλο έχουν ακολουθήσει την ίδια διαδρομή μέσα στο δέντρο, κάθε τέτοια διαδρομή μπορεί να μετατραπεί σε έναν κανόνα της μορφής IF–THEN. Το σύνολο των συνθηκών που εμφανίζονται κατά μήκος της διαδρομής αποτελεί το τμήμα IF του κανόνα, ενώ η κλάση που αντιστοιχεί στο φύλλο αποτελεί το τμήμα THEN.

3. Μετασχηματισμός των Συνθηκών σε DMN Κανόνες

Αφού ανακατασκευαστούν οι διαδρομές απόφασης του δέντρου, οι συνθήκες που προκύπτουν μετατρέπονται σε κανόνες ενός πίνακα αποφάσεων σύμφωνα με το πρότυπο DMN. Η διαδικασία αυτή πραγματοποιείται μέσω της κλάσης *xm1Dmn*, η οποία είναι υπεύθυνη για τη δημιουργία και τη διαχείριση της δομής του πίνακα αποφάσεων.

Σε έναν πίνακα αποφάσεων DMN κάθε χαρακτηριστικό του συνόλου δεδομένων αντιστοιχεί σε μία στήλη εισόδου, ενώ η μεταβλητή κλάσης αντιστοιχεί στη στήλη εξόδου. Για κάθε διαδρομή του δέντρου δημιουργείται μία γραμμή του πίνακα αποφάσεων, στην οποία καταγράφονται οι συνθήκες που προκύπτουν από τους διαχωρισμούς του μοντέλου.

Όταν ένα χαρακτηριστικό δεν εμφανίζεται στη συγκεκριμένη διαδρομή, το αντίστοιχο κελί παραμένει κενό, γεγονός που δηλώνει ότι η τιμή του χαρακτηριστικού δεν επηρεάζει τη συγκεκριμένη απόφαση. Αντίθετα, όταν ένα χαρακτηριστικό συμμετέχει στη διαδρομή, η συνθήκη εκφράζεται είτε ως απλή σύγκριση με ένα κατώφλι τιμής είτε ως εύρος τιμών που ορίζεται από δύο όρια.

4. Παραγωγή του DMN Δέντρου Απόφασης σε XML μορφή

Στο τελικό στάδιο η κλάση *xmlDmn* δημιουργεί το πλήρες μοντέλο του πίνακα αποφάσεων σε μορφή XML σύμφωνα με το πρότυπο DMN. Η διαδικασία περιλαμβάνει τη δημιουργία της βασικής δομής του μοντέλου, των στοιχείων εισόδου και εξόδου καθώς και των γραμμών που αντιστοιχούν στους κανόνες που προέκυψαν από το δέντρο αποφάσεων.

Το παραγόμενο αρχείο DMN περιέχει όλες τις απαραίτητες πληροφορίες για την αναπαράσταση των κανόνων απόφασης και είναι συμβατό με εργαλεία μοντελοποίησης επιχειρησιακών αποφάσεων, όπως το Camunda Modeler. Με τον τρόπο αυτό οι κανόνες που εξάγονται από το δέντρο αποφάσεων μπορούν να ενσωματωθούν σε συστήματα διαχείρισης επιχειρησιακών διαδικασιών και να αξιοποιηθούν σε πραγματικά περιβάλλοντα λήψης αποφάσεων.

5.4 Πλεονεκτήματα του CART

Ο αλγόριθμος CART παρουσιάζει μια σειρά από πλεονεκτήματα που τον καθιστούν κατάλληλο για προβλήματα ταξινόμησης και ανάλυσης δεδομένων. Ένα από τα βασικά χαρακτηριστικά του είναι ότι μπορεί να χρησιμοποιηθεί τόσο για προβλήματα ταξινόμησης όσο και για προβλήματα παλινδρόμησης, χρησιμοποιώντας την ίδια βασική δομή δέντρου. Η διαφοροποίηση μεταξύ των δύο περιπτώσεων πραγματοποιείται μέσω των κριτηρίων που χρησιμοποιούνται για την αξιολόγηση της ποιότητας των διασπάσεων, όπως ο δείκτης Gini για προβλήματα ταξινόμησης.

Ένα ακόμη σημαντικό πλεονέκτημα του CART είναι η χρήση της διαδικασίας της αναδρομικής δυαδικής διάσπασης (recursive binary partitioning), μέσω της οποίας το σύνολο των δεδομένων χωρίζεται επαναληπτικά σε μικρότερα υποσύνολα. Σε κάθε βήμα επιλέγεται το χαρακτηριστικό και η τιμή κατωφλίου που οδηγούν στη μεγαλύτερη μείωση της ακαθαρσίας των κόμβων, με αποτέλεσμα τη δημιουργία υποσυνόλων δεδομένων με μεγαλύτερη ομοιογένεια ως προς την κλάση στόχο.

Επιπλέον, ο αλγόριθμος CART δεν απαιτεί εκτεταμένη προεπεξεργασία των δεδομένων πριν από την εκπαίδευση του μοντέλου. Οι αριθμητικές μεταβλητές μπορούν να χρησιμοποιηθούν απευθείας χωρίς να απαιτείται κανονικοποίηση ή

τυποποίηση των τιμών τους, γεγονός που απλοποιεί σημαντικά τη διαδικασία προετοιμασίας των δεδομένων.

Ένα ακόμη πλεονέκτημα είναι η δυνατότητα ενσωματωμένης επιλογής χαρακτηριστικών κατά τη διαδικασία εκπαίδευσης. Κατά την κατασκευή του δέντρου, ο αλγόριθμος αξιολογεί όλα τα διαθέσιμα χαρακτηριστικά και επιλέγει εκείνο που οδηγεί στον καλύτερο διαχωρισμό των δεδομένων σε κάθε κόμβο. Με τον τρόπο αυτό εντοπίζονται αυτόματα τα πιο σημαντικά χαρακτηριστικά που επηρεάζουν την τελική πρόβλεψη του μοντέλου. Παράλληλα, η δομή του δέντρου επιτρέπει την ερμηνεία των κανόνων που παράγονται, καθώς κάθε κανόνας αντιστοιχεί σε μία διαδρομή από τη ρίζα έως ένα φύλλο και μπορεί να αναλυθεί εξετάζοντας τα διαδοχικά κριτήρια διαχωρισμού που εφαρμόστηκαν.

Τέλος, η δομή του δέντρου επιτρέπει την εύκολη εξαγωγή κανόνων απόφασης από το εκπαιδευμένο μοντέλο. Κάθε διαδρομή από τη ρίζα έως ένα φύλλο του δέντρου αντιστοιχεί σε έναν κανόνα της μορφής if-then, ο οποίος περιγράφει τις συνθήκες που οδηγούν σε μια συγκεκριμένη πρόβλεψη. Η ιδιότητα αυτή καθιστά τον αλγόριθμο ιδιαίτερα χρήσιμο σε εφαρμογές όπου απαιτείται η μετατροπή των αποτελεσμάτων της μηχανικής μάθησης σε σύνολα κανόνων που μπορούν να χρησιμοποιηθούν σε συστήματα υποστήριξης αποφάσεων.

5.5 Περιορισμοί του CART

Παρά τα σημαντικά πλεονεκτήματά του, ο αλγόριθμος CART παρουσιάζει ορισμένους περιορισμούς. Ένας από τους βασικότερους περιορισμούς αφορά την τάση των δέντρων αποφάσεων να δημιουργούν ιδιαίτερα πολύπλοκες δομές όταν το σύνολο δεδομένων περιλαμβάνει μεγάλο αριθμό χαρακτηριστικών ή όταν τα δεδομένα παρουσιάζουν υψηλή ποικιλία τιμών. Σε τέτοιες περιπτώσεις το δέντρο μπορεί να αναπτυχθεί σε μεγάλο βάθος και να περιλαμβάνει μεγάλο αριθμό κόμβων και φύλλων, γεγονός που αυξάνει σημαντικά την πολυπλοκότητα του μοντέλου.

Η αυξημένη πολυπλοκότητα του δέντρου οδηγεί συχνά στην παραγωγή μεγάλου αριθμού κανόνων απόφασης, καθώς κάθε διαδρομή από τη ρίζα έως ένα φύλλο αντιστοιχεί σε έναν ξεχωριστό κανόνα. Όταν το δέντρο περιλαμβάνει πολλά φύλλα, ο αριθμός των κανόνων που προκύπτουν αυξάνεται σημαντικά, γεγονός που μπορεί να οδηγήσει σε ιδιαίτερα εκτεταμένα σύνολα κανόνων και να δυσχεράνει την κατανόηση και τη διαχείρισή τους από τους χρήστες.

Ένας ακόμη περιορισμός του CART σχετίζεται με την ευαισθησία του μοντέλου σε μικρές μεταβολές των δεδομένων εκπαίδευσης. Δεδομένου ότι οι διασπάσεις των κόμβων βασίζονται σε συγκεκριμένα δείγματα του συνόλου δεδομένων, μικρές αλλαγές στα δεδομένα μπορούν να οδηγήσουν σε διαφορετική δομή δέντρου και σε διαφορετικούς κανόνες απόφασης. Η ιδιότητα αυτή μπορεί να επηρεάσει τη σταθερότητα του μοντέλου και αποτελεί γνωστό χαρακτηριστικό των μεθόδων που βασίζονται σε δέντρα αποφάσεων.

Επιπλέον, τα δέντρα αποφάσεων εμφανίζουν συχνά το φαινόμενο της υπερπροσαρμογής (overfitting), ιδιαίτερα όταν το μοντέλο επιτρέπεται να αναπτυχθεί χωρίς περιορισμούς. Σε αυτή την περίπτωση το δέντρο μπορεί να προσαρμοστεί υπερβολικά στα δεδομένα εκπαίδευσης, δημιουργώντας κόμβους που περιγράφουν πολύ συγκεκριμένα μοτίβα των δεδομένων. Ως αποτέλεσμα, το μοντέλο μπορεί να εμφανίζει μειωμένη ικανότητα γενίκευσης όταν εφαρμόζεται σε νέα δεδομένα.

Τέλος, ένας ακόμη περιορισμός αφορά τον τρόπο με τον οποίο ο αλγόριθμος πραγματοποιεί τις διασπάσεις των δεδομένων. Ο CART δημιουργεί αποκλειστικά δυαδικούς διαχωρισμούς βασισμένους σε ένα μόνο χαρακτηριστικό κάθε φορά. Η προσέγγιση αυτή μπορεί να δυσκολεύεται να αποτυπώσει σύνθετες σχέσεις μεταξύ πολλών μεταβλητών, ιδιαίτερα όταν οι αλληλεπιδράσεις μεταξύ των χαρακτηριστικών είναι μη γραμμικές ή εξαρτώνται από συνδυασμούς μεταβλητών.

5.6 Εφαρμογή της μεθόδου

Για την επίδειξη της μεθόδου που περιγράφεται εφαρμόστηκε η ίδια διαδικασία μετατροπής δέντρου απόφασης σε DMN πίνακα απόφασης, χρησιμοποιώντας το σύνολο δεδομένων *Iris*. Στο πλαίσιο αυτό, το δέντρο απόφασης εκπαιδεύτηκε και οπτικοποιήθηκε, ενώ στη συνέχεια η λογική του μετατράπηκε σε έναν πίνακα αποφάσεων DMN.

Εκπαίδευση Δέντρου Απόφασης

Για την εφαρμογή της προτεινόμενης μεθόδου πραγματοποιήθηκε αρχικά η εκπαίδευση ενός δέντρου αποφάσεων, χρησιμοποιώντας το κλασικό σύνολο δεδομένων εκπαίδευσης *Iris*, μέσω της βιβλιοθήκης *scikit-learn*. Το dataset περιλαμβάνει τέσσερα αριθμητικά χαρακτηριστικά, *sepal length*, *sepal width*, *petal length* και *petal width*, καθώς και τις κλάσεις στις οποίες ανήκουν τα λουλούδια (*setosa*, *versicolor*, *virginica*).

Η διαδικασία ξεκίνησε με τη φόρτωση των δεδομένων μέσω της συνάρτησης `load_iris()`, ενώ στη συνέχεια τα χαρακτηριστικά και οι κλάσεις χρησιμοποιήθηκαν για την εκπαίδευση του ταξινομητή *DecisionTreeClassifier*.

Ως ενδεικτικό παράδειγμα παρουσιάζονται οι δέκα πρώτες εγγραφές του συνόλου δεδομένων, οι οποίες αποτυπώνουν τις τιμές των χαρακτηριστικών και την αντίστοιχη κλάση:

sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	class
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa
4.6	3.1	1.5	0.2	setosa
5.0	3.6	1.4	0.2	setosa
5.4	3.9	1.7	0.4	setosa
4.6	3.4	1.4	0.3	setosa
5.0	3.4	1.5	0.2	setosa
4.4	2.9	1.4	0.2	setosa
4.9	3.1	1.5	0.1	setosa

Εικόνα 5. 1 Οι 10 πρώτες εγγραφές του Iris Set

Ο κώδικας που χρησιμοποιήθηκε για τη φόρτωση του iris dataset παρουσιάζεται στον Κώδικα 5.1.

Κώδικας 5.1 Φόρτωση του Iris dataset


```
from sklearn.datasets import load_iris

iris = load_iris()
df = pd.DataFrame(iris.data, columns=iris.feature_names)

df["class"] = iris.target_names[iris.target]
```

Μετά την εκπαίδευση, το μοντέλο οπτικοποιήθηκε σε μορφή γραφήματος, στο οποίο κάθε κόμβος αναπαριστά μια συνθήκη διάσπασης βασισμένη σε κάποιο χαρακτηριστικό των δεδομένων. Η διαδικασία ξεκινά από τον κόμβο ρίζας και ακολουθεί διαδοχικούς λογικούς ελέγχους (thresholds), έως ότου καταλήξει σε ένα φύλλο, όπου και αποδίδεται η τελική ταξινόμηση.

Το παρακάτω διάγραμμα παρουσιάζει το δέντρο αποφάσεων που δημιουργήθηκε. Παρατηρείται ότι το πρώτο σημείο διάσπασης του δέντρου επιλέγεται στο χαρακτηριστικό *petal width*, καθώς η συγκεκριμένη μεταβλητή οδηγεί στη μεγαλύτερη μείωση της τιμής Gini σε σχέση με όλα τα υπόλοιπα χαρακτηριστικά. Κάθε διαδρομή από τη ρίζα μέχρι τα φύλλα καθορίζει μια συγκεκριμένη λογική απόφαση, η οποία στη συνέχεια θα μετατραπεί σε κανόνα στον πίνακα DMN.



Εικόνα 5. 2 Παραγόμενο Δέντρο Απόφασης

Το δέντρο απόφασης που παρήχθη από το μοντέλο αποτελείται από μια σειρά κόμβων (nodes), όπου κάθε κόμβος περιλαμβάνει συγκεκριμένες πληροφορίες που σχετίζονται με τον τρόπο με τον οποίο το μοντέλο διαχωρίζει τα δεδομένα. Κάθε κόμβος στο δέντρο περιλαμβάνει τα ακόλουθα στοιχεία:

1. **Το χαρακτηριστικό διάσπασης (feature):** Στο επάνω μέρος κάθε εσωτερικού κόμβου εμφανίζεται το χαρακτηριστικό που χρησιμοποιείται για τη διάσπαση της τρέχουσας ομάδας δειγμάτων, μαζί με την τιμή κατωφλίου που καθορίζει τον διαχωρισμό. Για παράδειγμα, μια συνθήκη της μορφής: $\text{petal width (cm)} \leq 0.8$, σημαίνει ότι ο κόμβος διαχωρίζει τα δείγματα ανάλογα με το αν το πλάτος του πετάλου είναι μικρότερο ή ίσο από 0.8. Όσα δείγματα ικανοποιούν τη συνθήκη οδηγούνται στο αριστερό υποδέντρο, ενώ όσα δεν την ικανοποιούν οδηγούνται στο δεξί.
2. **Τιμή Gini:** Η τιμή Gini αποτελεί μέτρο «ακαθαρσίας» του κόμβου και χρησιμοποιείται για να εκτιμήσει πόσο ομοιογενής είναι η ομάδα των δειγμάτων που καταλήγουν σε αυτόν. Η τιμή της Gini κυμαίνεται από 0 έως

$1-1/K$, όπου K είναι ο αριθμός των κλάσεων του προβλήματος. Στην περίπτωση του συνόλου δεδομένων Iris, το οποίο περιλαμβάνει τρεις κλάσεις, η μέγιστη θεωρητική τιμή της Gini είναι περίπου 0.67. Τιμή ίση με μηδέν αντιστοιχεί σε πλήρως καθαρό κόμβο, στον οποίο όλα τα δείγματα ανήκουν στην ίδια κλάση, ενώ υψηλότερες τιμές υποδηλώνουν μεγαλύτερο βαθμό ανάμειξης μεταξύ των κλάσεων. Καθώς η κατασκευή του δέντρου αποφάσεων προχωρά και πραγματοποιούνται διαδοχικές διασπάσεις των δεδομένων, οι κόμβοι γίνονται σταδιακά πιο ομοιογενείς, γεγονός που αντανακλάται στη μείωση της τιμής Gini. Για τον λόγο αυτό, στους τελικούς κόμβους (φύλλα) του δέντρου η τιμή της Gini είναι συνήθως μηδενική, υποδηλώνοντας ότι όλα τα δείγματα που καταλήγουν σε αυτούς ανήκουν στην ίδια κλάση.

3. **Αριθμός δειγμάτων (samples):** Η ένδειξη samples δείχνει πόσα δείγματα του συνόλου δεδομένων φτάνουν στον συγκεκριμένο κόμβο. Στον αρχικό κόμβο εμφανίζονται και τα 150 δείγματα του Iris dataset, ενώ σε χαμηλότερα επίπεδα ο αριθμός μειώνεται, καθώς κάθε διάσπαση χωρίζει τα δεδομένα σε μικρότερες υποομάδες.
4. **Κατανομή δειγμάτων (value):** Το πεδίο value εμφανίζει την κατανομή των δειγμάτων ανά κλάση στον συγκεκριμένο κόμβο. Για το Iris dataset, η κατανομή δίνεται στη μορφή: [setosa, versicolor, virginica]. Παράδειγμα: value = [0, 47, 1], σημαίνει ότι στον συγκεκριμένο κόμβο βρίσκονται 47 δείγματα versicolor και 1 δείγμα virginica. Καθώς κατεβαίνουμε στο δέντρο, οι κατανομές γίνονται όλο και πιο ομογενείς, μέχρι να φτάσουν σε πλήρως καθαρές ομάδες.
5. **Πλειοψηφική κλάση (class):** Η ένδειξη class παρουσιάζει την κλάση με τον μεγαλύτερο αριθμό δειγμάτων στον συγκεκριμένο κόμβο. Στους ενδιαμέσους κόμβους, η πλειοψηφική κλάση δείχνει ποια κλάση είναι πιο πιθανή ανάμεσα στα δείγματα που έχουν φτάσει σε αυτό το σημείο, παρέχοντας μια εικόνα για το πώς κατευθύνεται το μοντέλο πριν εφαρμόσει την επόμενη διάσπαση. Στα φύλλα του δέντρου, η κλάση είναι πλήρως καθορισμένη και αντιστοιχεί στην τελική πρόβλεψη του μοντέλου.

Ο κώδικας που χρησιμοποιήθηκε για την εκπαίδευση και την οπτικοποίηση του δέντρου παρουσιάζεται στον κώδικα 5.2.

Κώδικας 5.2 Εκπαίδευση και οπτικοποίηση του δέντρου

```
clf = DecisionTreeClassifier(random_state=0)
clf.fit(df[iris.feature_names].values, df["class"].values)
graph = graphviz.Source(dot_data)
output_img = "decision_tree_graphviz"
graph.format = "png"
```

```
graph.render(output_img, cleanup=True)

print("Graphviz tree saved as:", output_img + ".png")

img = Image.open(output_img + ".png")
plt.figure(figsize=(12, 12))
plt.imshow(img)
plt.axis("off")
plt.show()
```

Μετατροπή του Δέντρου Απόφασης σε DMN Πίνακα Απόφασης

Αφού ολοκληρώθηκε η εκπαίδευση και η οπτικοποίηση του δέντρου αποφάσεων, εφαρμόστηκε η προτεινόμενη μέθοδος για τη μετατροπή της λογικής του μοντέλου σε πίνακα αποφάσεων DMN.

Αρχικά εντοπίστηκαν οι τελικοί κόμβοι (φύλλα) του δέντρου, οι οποίοι αντιστοιχούν στις τελικές προβλέψεις του μοντέλου. Για κάθε φύλλο εξήχθη η αντίστοιχη διαδρομή απόφασης από τη ρίζα έως τον τελικό κόμβο. Η διαδρομή αυτή περιλαμβάνει όλες τις συνθήκες διάσπασης που εφαρμόστηκαν στο δέντρο, δηλαδή τα χαρακτηριστικά που χρησιμοποιήθηκαν, τις τιμές κατωφλίου και τον τύπο της σύγκρισης.

Οι συνθήκες που συγκεντρώθηκαν από κάθε διαδρομή οργανώθηκαν σε μορφή κανόνα. Κάθε κανόνας περιλαμβάνει τις προϋποθέσεις που πρέπει να ικανοποιούνται για τα χαρακτηριστικά εισόδου, καθώς και την αντίστοιχη κλάση εξόδου που προβλέπει το μοντέλο.

Στη συνέχεια οι κανόνες αυτοί μετατράπηκαν σε γραμμές ενός DMN Πίνακα Απόφασης. Τα χαρακτηριστικά του dataset αντιστοιχούν στις στήλες εισόδου του πίνακα, ενώ η προβλεπόμενη κλάση του μοντέλου αποτελεί τη στήλη εξόδου. Με αυτόν τον τρόπο κάθε μονοπάτι του δέντρου μετατρέπεται σε έναν σαφώς καθορισμένο κανόνα απόφασης.

Η παραπάνω διαδικασία υλοποιήθηκε σε γλώσσα προγραμματισμού Python μέσω δύο βασικών κλάσεων: της `clfDmn` και της `xmlDmn`. Η κλάση `clfDmn` είναι υπεύθυνη για την ανάλυση του εκπαιδευμένου δέντρου αποφάσεων και την εξαγωγή των διαδρομών απόφασης που οδηγούν στα φύλλα του δέντρου. Αντίστοιχα, η κλάση `xmlDmn` αναλαμβάνει τη δημιουργία της δομής του πίνακα αποφάσεων σε μορφή DMN και τη μετατροπή των εξαγόμενων κανόνων σε στοιχεία XML σύμφωνα με το πρότυπο DMN.

Κώδικας 5.3 Υλοποίηση της κλάσης `clfDmn`

```
class clfDmn:

    def __init__(self, clf=None, df=None, featureColNames=None,
classColName=None):
        self.clf = clf
```

```

self.df = df
self.dfFeature = featureColNames
self.dfClassColumn = classColName

self.dfData = df[featureColNames].values

self.xml = xmlDmn()

def clearDecisionTable(self):
    for child in list(self.xml.decisionTableElement):
        self.xml.decisionTableElement.remove(child)

def generateTableFromClf(self):
    tree_ = self.clf.tree_
    leafChildren_left = tree_.children_left
    leafChildren_right = tree_.children_right
    thresholds = tree_.threshold

    featuresForDiagram = list(self.dfFeature)
    featuresForDiagram.append(self.dfClassColumn)

    self.clearDecisionTable()
    self.xml.generateTableColumns(featuresForDiagram)

    decPath = self.clf.decision_path(self.dfData)
    leafIds = np.where(
        (leafChildren_left == -1) & (leafChildren_right == -
1)
    )[0]

    for i in set(leafIds):
        samplesInNode = decPath.getcol(i).copy()
        rows = samplesInNode.nonzero()[0]
        if len(rows) == 0:
            continue

        sampleId = rows[0]

        nodeIndex = decPath.indices[
            decPath.indptr[sampleId] :
decPath.indptr[sampleId + 1]
        ]

        inputOutput = defaultdict(dict)

        class_index =
int(np.argmax(self.clf.tree_.value[i]))
        className = self.clf.classes_[class_index]
        inputOutput[className] = {}

        for feat in featuresForDiagram[:-1]:
            inputOutput[className][feat] = {}

        for idx_pos in range(len(nodeIndex) - 1):
            node_id = nodeIndex[idx_pos]

```

```

        feat_idx = tree_.feature[node_id]
        if feat_idx < 0:
            continue

        feat_name = self.dfFeature[feat_idx]
        node_threshold = float(thresholds[node_id])

        next_node = nodeIndex[idx_pos + 1]
        if next_node == leafChildren_left[node_id]:
            inputOutput[className][feat_name]["<="] =
node_threshold
        elif next_node == leafChildren_right[node_id]:
            inputOutput[className][feat_name][">"] =
node_threshold

        self.xml.generateTableRows([
            (className, inputOutput[className])
        ])

    return self.xml.writeTree("dmn_output.dmn")

```

Κώδικας 5.4 Υλοποίηση της κλάσης xmlDmn

```

class xmlDmn:

    def __init__(self):
        self.dmn_ns = "http://www.omg.org/spec/DMN/20151101/dmn.xsd"
        self.root = et.Element(
            "{%s}definitions" % self.dmn_ns,
            {
                "id": "definitions_1",
                "name": "Decision Model",
                "namespace": "http://example.org/dmn",
                "xmlns:dmn": self.dmn_ns,
            },
        )
        self.decision = et.SubElement(
            self.root,
            "{%s}decision" % self.dmn_ns,
            {"id": "decision_1", "name": "Decision"},
        )
        self.decisionTableElement = et.SubElement(
            self.decision,
            "{%s}decisionTable" % self.dmn_ns,
            {"id": "decisionTable_1", "hitPolicy": "UNIQUE"},
        )

        self._id_counter = 0

    def idGen(self, prefix):
        self._id_counter += 1

```

```

        return f"{prefix}{self._id_counter}"

def generateTableColumns(self, names):
    outputName = names[-1]
    inputNames = names[:-1]

    for name in inputNames:
        newInput = et.SubElement(
            self.decisionTableElement,
            "{%s}input" % self.dmn_ns,
            {"id": self.idGen("input_")},
        )

        newInputExpression = et.SubElement(
            newInput,
            "{%s}inputExpression" % self.dmn_ns,
            {"id": self.idGen("inputExpression_"), "typeRef":
"double"},
        )

        newText = et.SubElement(newInputExpression, "{%s}text" %
self.dmn_ns)
        newText.text = name

        et.SubElement(
            self.decisionTableElement,
            "{%s}output" % self.dmn_ns,
            {"id": self.idGen("output_"), "name": outputName,
"typeRef": "string"},
        )

def createRuleCell(self, ruleElement, text=""):
    # <inputEntry>
    cell = et.SubElement(
        ruleElement,
        "{%s}inputEntry" % self.dmn_ns,
        {"id": self.idGen("inputEntry_")},
    )

    t = et.SubElement(cell, "{%s}text" % self.dmn_ns)
    t.text = text
    return cell

def generateTableRows(self, mIDict):
    for k, v in mIDict:

        newRule = et.SubElement(
            self.decisionTableElement,
            "{%s}rule" % self.dmn_ns,
            {"id": self.idGen("rule_")},
        )

        for keyFeature in v:
            signDict = v[keyFeature]
            tSignList = list(signDict.keys())

```

```

        if len(signDict) == 0:
            self.createRuleCell(newRule, "")
            continue

        if len(signDict) == 1:
            s = tSignList[0]
            val = signDict[s]
            if s == "<=":
                self.createRuleCell(newRule, f"<= {val:.4f}")
            else:
                self.createRuleCell(newRule, f"> {val:.4f}")
            continue

        if len(signDict) == 2 and (">" in signDict) and ("<="
in signDict):
            low = signDict[">"]
            high = signDict["<="]
            self.createRuleCell(newRule,
f"{low:.4f}..{high:.4f}")
            continue

        self.createRuleCell(newRule, "")

        newOutEntry = et.SubElement(
            newRule,
            "%s$outputEntry" % self.dmn_ns,
            {"id": self.idGen("LiteralExpression_")},
        )
        newOutText = et.SubElement(newOutEntry, "%s$text" %
self.dmn_ns)
        newOutText.text = str(k)

    def writeTree(self, filename="dmn_output.dmn"):
        tree = et.ElementTree(self.root)
        tree.write(filename, encoding="utf-8", xml_declaration=True)
        return filename

```

Έπειτα, πραγματοποιήθηκε η διαδικασία μετατροπής της λογικής του μοντέλου σε πίνακα αποφάσεων DMN. Για τον σκοπό αυτό δημιουργήθηκε ένα αντικείμενο της κλάσης `clfDmn`, το οποίο λειτουργεί ως ενδιάμεσος μηχανισμός (wrapper) μεταξύ του εκπαιδευμένου ταξινομητή και της διαδικασίας παραγωγής του πίνακα αποφάσεων. Στο αντικείμενο αυτό μεταβιβάστηκαν το εκπαιδευμένο μοντέλο του δέντρου αποφάσεων, το σύνολο δεδομένων, τα ονόματα των χαρακτηριστικών εισόδου και το όνομα της στήλης που αντιστοιχεί στην κλάση στόχο.

Στη συνέχεια ενεργοποιήθηκε η διαδικασία δημιουργίας του πίνακα αποφάσεων μέσω της κλήσης της μεθόδου `generateTableFromClf()`. Η διαδικασία αυτή αναλύει τη δομή του δέντρου αποφάσεων, εξάγει τις διαδρομές απόφασης που οδηγούν στα φύλλα του δέντρου και μετατρέπει τις αντίστοιχες συνθήκες σε κανόνες ενός DMN πίνακα απόφασης. Το αποτέλεσμα αποθηκεύτηκε σε αρχείο μορφής XML σύμφωνα

με το πρότυπο DMN, το οποίο μπορεί να χρησιμοποιηθεί σε εργαλεία διαχείρισης επιχειρησιακών κανόνων, όπως το Camunda Modeler.

Στη συνέχεια παρουσιάζεται το αντίστοιχο απόσπασμα κώδικα που υλοποιεί τη διαδικασία δημιουργίας του αρχείου DMN.

Κώδικας 5.5 Δημιουργία αρχείου DMN

```
wrapper = clfDmn(  
    clf=clf,  
    df=df,  
    featureColNames=iris.feature_names,  
    classColName="class",  
)  
  
dmn_path = wrapper.generateTableFromClf()  
print("DMN generated at:", dmn_path)
```

Μετά τη δημιουργία του αρχείου DMN, το παραγόμενο αρχείο εισήχθη στο περιβάλλον του Camunda Modeler, το οποίο αποτελεί εργαλείο μοντελοποίησης και εκτέλεσης επιχειρησιακών κανόνων σύμφωνα με το πρότυπο DMN. Με την εισαγωγή του αρχείου, το εργαλείο αναπαριστά γραφικά τον πίνακα αποφάσεων που προκύπτει από τους κανόνες του δέντρου αποφάσεων.

Decision						
Hit policy: Unique						
	When	And	And	And	Then	Annotations
	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	class	
1	--	--	--	≤ 0.8000	setosa	
2	--	--	≤ 4.9500	$[0.8000..1.6100]$	versicolor	
3	--	--	≤ 4.9500	$[1.6100..1.7500]$	virginica	
4	--	--	> 4.9500	$[0.8000..1.5500]$	virginica	
5	--	--	$[4.9500..5.4500]$	$[1.5500..1.7500]$	versicolor	
6	--	--	> 5.4500	$[1.5500..1.7500]$	virginica	
7	--	≤ 3.1000	≤ 4.8500	> 1.7500	virginica	
8	--	> 3.1000	≤ 4.8500	> 1.7500	versicolor	
9	--	--	> 4.8500	> 1.7500	virginica	
+	--	--	--	--	--	

Εικόνα 5. 3 Παραγόμενος Πίνακας Αποφάσεων

Ο παραγόμενος DMN πίνακας αποφάσεων αποτυπώνει τη λογική του δέντρου αποφάσεων σε μορφή κανόνων. Κάθε γραμμή του πίνακα αντιστοιχεί σε μία διαδρομή από τη ρίζα του δέντρου έως ένα φύλλο και περιγράφει τις συνθήκες που πρέπει να ικανοποιούνται ώστε να προκύψει μια συγκεκριμένη ταξινόμηση.

Οι στήλες εισόδου του πίνακα αντιστοιχούν στα χαρακτηριστικά του συνόλου δεδομένων Iris, δηλαδή sepal length, sepal width, petal length και petal width. Για κάθε χαρακτηριστικό καταγράφονται τα όρια τιμών που προέκυψαν από τις διασπάσεις του δέντρου αποφάσεων. Οι συνθήκες αυτές εκφράζονται είτε ως απλές συγκρίσεις (π.χ. ≤ 0.8) είτε ως εύρη τιμών, τα οποία αντιπροσωπεύουν τα διαστήματα μέσα στα οποία πρέπει να βρίσκεται ένα χαρακτηριστικό ώστε να ενεργοποιηθεί ο αντίστοιχος κανόνας.

Η τελευταία στήλη του πίνακα αντιστοιχεί στην κλάση εξόδου (class), η οποία αποτελεί την τελική απόφαση του μοντέλου. Για παράδειγμα, όταν η τιμή του χαρακτηριστικού *petal width* είναι μικρότερη ή ίση με 0.8, το μοντέλο ταξινομεί το δείγμα στην κατηγορία *setosa*, γεγονός που αποτυπώνεται στον πρώτο κανόνα του πίνακα.

Παρατηρείται επίσης ότι σε ορισμένους κανόνες κάποια χαρακτηριστικά παραμένουν κενά. Αυτό συμβαίνει επειδή τα συγκεκριμένα χαρακτηριστικά δεν συμμετείχαν στη διαδρομή απόφασης του αντίστοιχου φύλλου του δέντρου. Στην περίπτωση αυτή, το κενό κελί υποδηλώνει ότι η τιμή του χαρακτηριστικού δεν επηρεάζει την ενεργοποίηση του κανόνα.

Με τον τρόπο αυτό, η ιεραρχική δομή του δέντρου αποφάσεων μετασχηματίζεται σε ένα σύνολο σαφώς ορισμένων κανόνων σε μορφή πίνακα, διατηρώντας παράλληλα τη λογική και την ερμηνευσιμότητα του αρχικού μοντέλου.

Η ολοκληρωμένη υλοποίηση της παραπάνω διαδικασίας για τον αλγόριθμο CART είναι διαθέσιμη στον ακόλουθο σύνδεσμο:

<https://github.com/DanaeKouimtzipou/decision-tree-to-dmn>

5.7 Σύνοψη

Στο κεφάλαιο αυτό παρουσιάστηκε η αξιοποίηση του αλγορίθμου CART για την εξαγωγή κανόνων από δεδομένα και τη μετατροπή τους σε πίνακα αποφάσεων σύμφωνα με το πρότυπο DMN. Αρχικά αναλύθηκε το ερευνητικό πρόβλημα που αφορά τη σύνδεση δέντρων αποφάσεων με συστήματα Business Process Management (BPM), καθώς και η ανάγκη αναπαράστασης της γνώσης που προκύπτει από δεδομένα σε μορφή κατανοητών και δομημένων επιχειρησιακών κανόνων.

Στη συνέχεια παρουσιάστηκε ο αλγόριθμος CART και η διαδικασία δημιουργίας δέντρων αποφάσεων, καθώς και ο τρόπος με τον οποίο οι διαδρομές από τη ρίζα έως τα φύλλα του δέντρου μπορούν να ερμηνευθούν ως κανόνες απόφασης της μορφής if-then. Ακολούθως, περιγράφηκε η προτεινόμενη μεθοδολογία μετατροπής των decision paths ενός δέντρου αποφάσεων σε κανόνες ενός DMN πίνακα απόφασης, επιτρέποντας τη μεταφορά της λογικής του μοντέλου σε ένα τυποποιημένο περιβάλλον λήψης επιχειρησιακών αποφάσεων.

Επιπλέον, παρουσιάστηκαν ορισμένα από τα βασικά πλεονεκτήματα της προσέγγισης, όπως η δυνατότητα εξαγωγής άμεσα ερμηνεύσιμων κανόνων απόφασης από τη δομή του δέντρου και η περιορισμένη ανάγκη προεπεξεργασίας των δεδομένων κατά τη διαδικασία εκπαίδευσης. Παράλληλα, επισημάνθηκαν και ορισμένοι περιορισμοί της μεθόδου, όπως η πιθανότητα δημιουργίας ιδιαίτερα πολύπλοκων δέντρων όταν το σύνολο δεδομένων περιλαμβάνει μεγάλο αριθμό χαρακτηριστικών, καθώς και η ευαισθησία του μοντέλου σε μικρές μεταβολές των δεδομένων εκπαίδευσης. Τέλος, παρουσιάστηκε η εφαρμογή της μεθόδου χρησιμοποιώντας το σύνολο δεδομένων Iris, μέσω της οποίας επιδείχθηκε στην πράξη η μετατροπή της λογικής ενός δέντρου απόφασης σε πίνακα αποφάσεων DMN.

Η προσέγγιση αυτή αποτελεί ένα πρώτο βήμα προς τη σύνδεση τεχνικών μηχανικής μάθησης με συστήματα επιχειρησιακών αποφάσεων. Στο επόμενο κεφάλαιο παρουσιάζεται μια διαφορετική προσέγγιση εξαγωγής κανόνων από δεδομένα μέσω του αλγορίθμου PRISM, η οποία βασίζεται σε τεχνικές rule learning για την παραγωγή κανόνων απόφασης.

Κεφάλαιο 6: Αλγόριθμος PRISM

Στο παρόν κεφάλαιο παρουσιάζεται ο αλγόριθμος PRISM, ένας αλγόριθμος επαγωγής κανόνων που χρησιμοποιείται σε προβλήματα ταξινόμησης για την παραγωγή κανόνων της μορφής *if-then*. Αρχικά αναλύονται οι βασικές αρχές λειτουργίας του αλγορίθμου και η διαδικασία δημιουργίας κανόνων μέσω της στρατηγικής *separate-and-conquer*. Στη συνέχεια περιγράφονται τα βασικά βήματα της μεθόδου, όπως η επιλογή της κλάσης στόχου, ο υπολογισμός πιθανοτήτων για τα χαρακτηριστικά και η επαναληπτική εξειδίκευση των κανόνων.

Έπειτα αναλύονται τα βασικά πλεονεκτήματα και οι περιορισμοί του αλγορίθμου. Τέλος, παρουσιάζεται ένα αναλυτικό παράδειγμα εφαρμογής του PRISM στο σύνολο δεδομένων *Play Tennis*, καθώς και η υλοποίησή του σε γλώσσα Python για την μετατροπή των παραγόμενων κανόνων σε πίνακα αποφάσεων DMN.

6.1 Εισαγωγή στις Μεθόδους Επαγωγής Κανόνων

Στη προηγούμενη ενότητα παρουσιάστηκε η μεθοδολογία του αλγορίθμου CART, ο οποίος αποτελεί μία από τις πιο διαδεδομένες τεχνικές ταξινόμησης στη μηχανική μάθηση. Τα δέντρα αποφάσεων προσφέρουν ένα μοντέλο το οποίο είναι σχετικά εύκολο στην κατανόηση, καθώς η διαδικασία λήψης απόφασης αναπαρίσταται ως μια διαδοχική ακολουθία ελέγχων πάνω στα χαρακτηριστικά των δεδομένων.

Παρότι τα δέντρα αποφάσεων αποτελούν ένα ισχυρό και ερμηνεύσιμο μοντέλο, η γνώση που παράγεται οργανώνεται σε ιεραρχική δομή. Αυτό σημαίνει ότι οι κανόνες εξαρτώνται από τη συγκεκριμένη δομή του δέντρου και η διαδικασία ταξινόμησης ακολουθεί πάντα μία συγκεκριμένη διαδρομή από τη ρίζα προς τα φύλλα. Σε ορισμένες περιπτώσεις, ιδιαίτερα όταν το ζητούμενο είναι η άμεση εξαγωγή και αξιοποίηση επιχειρησιακών κανόνων, είναι προτιμότερη η χρήση μεθόδων που παράγουν ένα σύνολο ανεξάρτητων κανόνων ταξινόμησης απευθείας από τα δεδομένα.

Η ανάγκη αυτή οδηγεί στην κατηγορία των μεθόδων επαγωγής κανόνων (*rule induction*). Στον χώρο της μηχανικής μάθησης και της εξόρυξης δεδομένων, η επαγωγή κανόνων αποτελεί μία σημαντική τεχνική για την ανακάλυψη γνώσης από σύνολα δεδομένων. Η βασική της ιδέα είναι η εξαγωγή προτύπων και σχέσεων από τα δεδομένα και η αναπαράστασή τους με τη μορφή κατανοητών κανόνων. Οι κανόνες αυτοί εκφράζονται συνήθως με τη μορφή *if-then*, επιτρέποντας την περιγραφή των συνθηκών υπό τις οποίες ένα παράδειγμα ανήκει σε μια συγκεκριμένη κατηγορία.

Η προσέγγιση αυτή παρουσιάζει ιδιαίτερο ενδιαφέρον σε εφαρμογές όπου η διαφάνεια και η ερμηνευσιμότητα των αποτελεσμάτων αποτελούν κρίσιμους παράγοντες. Σε τομείς όπως η επιχειρησιακή ανάλυση, τα συστήματα υποστήριξης αποφάσεων και η διαχείριση επιχειρησιακών κανόνων, δεν αρκεί ένα μοντέλο να

παρέχει μόνο ακριβείς προβλέψεις, είναι εξίσου σημαντικό να μπορεί να εξηγηθεί η λογική που οδηγεί σε αυτές.

Για τον λόγο αυτό, η επαγωγή κανόνων χρησιμοποιείται συχνά σε προβλήματα ταξινόμησης, όπου στόχος είναι η δημιουργία ενός συνόλου κανόνων που να περιγράφουν με σαφήνεια τη σχέση μεταξύ των χαρακτηριστικών των δεδομένων και των αντίστοιχων κλάσεων. Τα μοντέλα που βασίζονται σε κανόνες είναι συνήθως εύκολα στην κατανόηση και μπορούν να ενσωματωθούν απευθείας σε συστήματα που βασίζονται σε επιχειρησιακή λογική.

6.2 Ο Αλγόριθμος PRISM για Εξαγωγή Κανόνων

Στο πλαίσιο των μεθόδων επαγωγής κανόνων, ένας από τους πιο γνωστούς και κλασικούς αλγόριθμους είναι ο **PRISM (Process for Identifying Subgroup Membership)**. Ο αλγόριθμος αυτός σχεδιάστηκε με στόχο την παραγωγή σαφών, ακριβών και ερμηνεύσιμων κανόνων ταξινόμησης απευθείας από τα δεδομένα εκπαίδευσης, χωρίς να απαιτείται η κατασκευή ενδιάμεσων δομών όπως τα δέντρα αποφάσεων.

Ο PRISM ανήκει στην κατηγορία των αλγορίθμων επαγωγής κανόνων για προβλήματα ταξινόμησης και παράγει ένα σύνολο κανόνων της μορφής *if-then*, όπου κάθε κανόνας αντιστοιχεί σε μία συγκεκριμένη κλάση του συνόλου δεδομένων. Οι κανόνες αυτοί περιγράφουν τις συνθήκες υπό τις οποίες ένα παράδειγμα ταξινομείται σε μια συγκεκριμένη κατηγορία, επιτρέποντας την άμεση ερμηνεία της διαδικασίας λήψης απόφασης.

Η βασική ιδέα του αλγορίθμου είναι η σταδιακή δημιουργία κανόνων μέσω μιας διαδικασίας επαναληπτικής εξειδίκευσης. Για κάθε κλάση του προβλήματος, ο PRISM αναζητά συνδυασμούς χαρακτηριστικών και τιμών που εμφανίζονται με υψηλή συχνότητα στα παραδείγματα της συγκεκριμένης κλάσης. Μέσω της αξιολόγησης αυτών των συνδυασμών, επιλέγονται σταδιακά οι όροι που οδηγούν στη δημιουργία ενός κανόνα με υψηλή ακρίβεια ως προς την κλάση στόχο. Η διαδικασία συνεχίζεται μέχρι να παραχθεί ένας κανόνας που να καλύπτει κυρίως ή αποκλειστικά παραδείγματα της συγκεκριμένης κλάσης.

Ένα σημαντικό χαρακτηριστικό του PRISM είναι ότι η διαδικασία επαγωγής κανόνων πραγματοποιείται ξεχωριστά για κάθε κλάση του προβλήματος. Με τον τρόπο αυτό ο αλγόριθμος μπορεί να εντοπίσει τα χαρακτηριστικά που είναι περισσότερο αντιπροσωπευτικά για κάθε κατηγορία, δημιουργώντας κανόνες που περιγράφουν με σαφήνεια τα μοτίβα που εμφανίζονται στα δεδομένα.

Ο αλγόριθμος μπορεί να χειριστεί αποτελεσματικά κατηγορικά χαρακτηριστικά, τα οποία χρησιμοποιούνται άμεσα στη διαδικασία δημιουργίας των κανόνων. Στην περίπτωση συνεχών χαρακτηριστικών απαιτείται προηγουμένως η διαδικασία της διακριτοποίησης, κατά την οποία οι αριθμητικές τιμές μετατρέπονται σε διακριτές κατηγορίες. Η προϋπόθεση αυτή επιτρέπει στον PRISM να εφαρμόζεται σε ευρύ φάσμα προβλημάτων ταξινόμησης που βασίζονται σε δομημένα δεδομένα.

Σε αντίθεση με τους αλγορίθμους που βασίζονται σε δέντρα αποφάσεων, ο PRISM δεν οργανώνει τη γνώση σε ιεραρχική δομή. Αντίθετα, παράγει απευθείας ένα σύνολο ανεξάρτητων κανόνων ταξινόμησης, οι οποίοι είναι αρθρωτοί (modular) και μη διατεταγμένοι. Κάθε κανόνας λειτουργεί ανεξάρτητα από τους υπόλοιπους και μπορεί να εφαρμοστεί χωρίς να απαιτείται συγκεκριμένη σειρά αξιολόγησης. Η ιδιότητα αυτή προσφέρει μεγαλύτερη ευελιξία στην αξιοποίηση των κανόνων, καθώς μπορούν να αναλυθούν, να τροποποιηθούν ή να επεκταθούν χωρίς να επηρεάζεται η συνολική δομή του μοντέλου.

6.3 Μεθοδολογία Εξαγωγής Κανόνων με τον PRISM

Ο αλγόριθμος PRISM βασίζεται στη στρατηγική *separate-and-conquer*, σύμφωνα με την οποία οι κανόνες δημιουργούνται σταδιακά ώστε να καλύπτουν συγκεκριμένα υποσύνολα των δεδομένων εκπαίδευσης. Σε κάθε επανάληψη δημιουργείται ένας κανόνας που περιγράφει ένα μέρος των παραδειγμάτων της κλάσης στόχου και στη συνέχεια τα παραδείγματα αυτά αφαιρούνται από το σύνολο εκπαίδευσης. Η διαδικασία συνεχίζεται έως ότου καλυφθούν όλα τα παραδείγματα της κλάσης.

Η λειτουργία του αλγορίθμου μπορεί να συνοψιστεί στα ακόλουθα βασικά στάδια

- **Δημιουργία ενός κανόνα που καλύπτει μέρος των δεδομένων:** Σε αυτό το στάδιο, ο αλγόριθμος κατασκευάζει έναν κανόνα ταξινόμησης μέσω σταδιακής προσθήκης όρων, με στόχο να επιτευχθεί υψηλή ακρίβεια ως προς μια συγκεκριμένη κλάση. Ο κανόνας επιλέγεται έτσι ώστε να καλύπτει ένα υποσύνολο των παραδειγμάτων του συνόλου εκπαίδευσης, τα οποία παρουσιάζουν κοινά χαρακτηριστικά και ανήκουν κυρίως στην κλάση στόχο.
- **Αφαίρεση των παραδειγμάτων που καλύπτονται από τον κανόνα:** Αφού ολοκληρωθεί η κατασκευή του κανόνα, όλα τα παραδείγματα που ικανοποιούν τις συνθήκες του θεωρούνται πλέον επαρκώς περιεγραμμένα και αφαιρούνται από το σύνολο δεδομένων που εξετάζεται για την κλάση στόχο. Η αφαίρεση αυτή αποτρέπει την επανεξέταση των ίδιων παραδειγμάτων και επιτρέπει στον αλγόριθμο να επικεντρωθεί στα εναπομείναντα, μη καλυφθέντα δεδομένα.
- **Επανάληψη της διαδικασίας έως ότου καλυφθούν όλα τα παραδείγματα της κλάσης στόχου:** Η διαδικασία δημιουργίας και αφαίρεσης κανόνων επαναλαμβάνεται επαναληπτικά, με κάθε νέο κανόνα να καλύπτει ένα διαφορετικό υποσύνολο των παραδειγμάτων της ίδιας κλάσης. Η επανάληψη συνεχίζεται έως ότου δεν απομένουν παραδείγματα της κλάσης στόχου ή έως ότου δεν είναι δυνατή η παραγωγή νέου κανόνα που να πληροί τα κριτήρια ποιότητας.

Η διαδικασία αυτή εφαρμόζεται ξεχωριστά για κάθε κλάση, γεγονός που επιτρέπει στον αλγόριθμο να παράγει κανόνες ειδικά προσαρμοσμένους στα χαρακτηριστικά κάθε κατηγορίας.

Η διαδικασία εξαγωγής κανόνων του αλγορίθμου μπορεί να αποτυπωθεί στα παρακάτω βήματα:

1. Επιλογή κλάσης στόχου

Ο αλγόριθμος PRISM ξεκινά τη διαδικασία επαγωγής επιλέγοντας μία συγκεκριμένη κλάση από το σύνολο των διαθέσιμων κλάσεων του προβλήματος ταξινόμησης. Η κλάση αυτή ορίζεται ως κλάση στόχος, και για αυτήν παράγεται ένα σύνολο κανόνων που σκοπό έχουν να περιγράψουν με ακρίβεια και πληρότητα τα παραδείγματα που ανήκουν σε αυτήν.

Η διαδικασία επιλογής και επεξεργασίας της κλάσης στόχου πραγματοποιείται ανεξάρτητα από τις υπόλοιπες κλάσεις. Με τον τρόπο αυτό, ο PRISM διαφοροποιείται ουσιαστικά από αλγορίθμους που επιχειρούν να κατασκευάσουν ένα ενιαίο μοντέλο το οποίο διαχωρίζει όλες τις κλάσεις ταυτόχρονα. Η ανεξάρτητη επεξεργασία κάθε κλάσης επιτρέπει στον αλγόριθμο να επικεντρώνεται αποκλειστικά στα χαρακτηριστικά που είναι περισσότερο αντιπροσωπευτικά για τη συγκεκριμένη κλάση, οδηγώντας στην παραγωγή πιο εξειδικευμένων αλλά και πιο κατανοητών κανόνων.

2. Υπολογισμός πιθανοτήτων χαρακτηριστικών

Για την επιλεγμένη κλάση στόχο, ο PRISM εξετάζει όλα τα διαθέσιμα χαρακτηριστικά (*attributes*) του συνόλου εκπαίδευσης, καθώς και τις πιθανές τιμές που μπορεί να λάβει το καθένα από αυτά. Για κάθε ζεύγος χαρακτηριστικού–τιμής υπολογίζεται η υπό συνθήκη πιθανότητα:

$$P(\text{Class}|\text{Attribute}=\text{Value})$$

Η πιθανότητα αυτή εκφράζει τον βαθμό συσχέτισης της συγκεκριμένης τιμής με την κλάση στόχο και υπολογίζεται με βάση τη συχνότητα εμφάνισής της στα δεδομένα εκπαίδευσης. Συγκεκριμένα, λαμβάνεται υπόψη ο αριθμός των παραδειγμάτων που ικανοποιούν τον συγκεκριμένο όρο και ανήκουν στην κλάση στόχο, σε σχέση με το σύνολο των παραδειγμάτων που ικανοποιούν τον ίδιο όρο.

Ο υπολογισμός αυτός επιτρέπει στον αλγόριθμο να αξιολογήσει ποιοι όροι συμβάλλουν περισσότερο στη διάκριση της κλάσης στόχου από τις υπόλοιπες κλάσεις.

3. Επιλογή του καλύτερου όρου κανόνα

Μετά τον υπολογισμό των πιθανοτήτων για όλα τα διαθέσιμα ζεύγη χαρακτηριστικού–τιμής, ο PRISM επιλέγει τον όρο (*attribute = value*) που μεγιστοποιεί την υπό συνθήκη πιθανότητα της κλάσης στόχου. Ο επιλεγμένος όρος αποτελεί το πρώτο συστατικό του κανόνα που κατασκευάζεται.

Στη συνέχεια, το σύνολο των δεδομένων περιορίζεται αποκλειστικά στα παραδείγματα που ικανοποιούν τον συγκεκριμένο όρο. Η διαδικασία αυτή είναι καθοριστικής σημασίας, καθώς διασφαλίζει ότι κάθε νέα προσθήκη στον κανόνα αυξάνει τη συγκέντρωση παραδειγμάτων της κλάσης στόχου, βελτιώνοντας σταδιακά την ακρίβεια του κανόνα.

Με τον τρόπο αυτό, ο αλγόριθμος ακολουθεί μια στρατηγική σταδιακής εξειδίκευσης, αποφεύγοντας την εισαγωγή όρων που δεν συμβάλλουν ουσιαστικά στη διάκριση της κλάσης.

4. Επαναληπτική εξειδίκευση του κανόνα

Η διαδικασία υπολογισμού πιθανοτήτων και επιλογής όρων επαναλαμβάνεται στο περιορισμένο πλέον σύνολο δεδομένων που καλύπτεται από τους ήδη επιλεγμένους όρους του κανόνα. Σε κάθε επανάληψη, ο κανόνας εμπλουτίζεται με έναν επιπλέον όρο, ο οποίος επιλέγεται με το ίδιο κριτήριο μεγιστοποίησης της υπό συνθήκη πιθανότητας.

Η επαναληπτική αυτή διαδικασία συνεχίζεται έως ότου ικανοποιηθεί μία από τις ακόλουθες συνθήκες:

- ο κανόνας καλύπτει αποκλειστικά παραδείγματα της κλάσης στόχου, επιτυγχάνοντας ιδανική καθαρότητα,
- ή δεν υπάρχει διαθέσιμος όρος που να μπορεί να βελτιώσει περαιτέρω την ακρίβεια του κανόνα.

Το αποτέλεσμα είναι η δημιουργία ενός κανόνα ταξινόμησης της μορφής:

$$\text{IF } (a_1=v_1) \wedge (a_2=v_2) \wedge \dots \wedge (a_k=v_k) \text{ THEN Class} = \delta n,$$

που χαρακτηρίζεται από υψηλή ακρίβεια και επαρκή εξειδίκευση, χωρίς περιττούς ή άσχετους όρους.

5. Αφαίρεση καλυπτόμενων παραδειγμάτων

Μετά την ολοκλήρωση ενός κανόνα, όλα τα παραδείγματα του συνόλου εκπαίδευσης που καλύπτονται από αυτόν αφαιρούνται από το σύνολο δεδομένων που αντιστοιχεί στη συγκεκριμένη κλάση στόχο. Η αφαίρεση αυτή αποτρέπει την επανεμφάνιση των ίδιων παραδειγμάτων στη διαδικασία επαγωγής επόμενων κανόνων.

Στη συνέχεια, ο αλγόριθμος επαναλαμβάνει τη διαδικασία επαγωγής για την ίδια κλάση, δημιουργώντας νέους κανόνες που καλύπτουν τα εναπομείναντα παραδείγματα, έως ότου καλυφθούν πλήρως όλα τα παραδείγματα της κλάσης στόχου. Με τον τρόπο αυτό, ο PRISM διασφαλίζει την παραγωγή ενός πλήρους συνόλου κανόνων που περιγράφουν συνολικά τη συμπεριφορά της κάθε κλάσης.

6.4 Πλεονεκτήματα του PRISM

Ο αλγόριθμος PRISM παρουσιάζει σημαντικά πλεονεκτήματα ως μέθοδος επαγωγής κανόνων για προβλήματα ταξινόμησης. Ένα από τα βασικά χαρακτηριστικά του είναι ότι παράγει απευθείας κανόνες της μορφής *if-then*, χωρίς να απαιτείται η κατασκευή μιας ενδιάμεσης δομής, όπως συμβαίνει στους αλγορίθμους δέντρων αποφάσεων. Η διαδικασία αυτή βασίζεται στην επαγωγική δημιουργία κανόνων που καλύπτουν σταδιακά τα παραδείγματα κάθε κλάσης, επιτρέποντας τη δημιουργία ενός συνόλου κανόνων που περιγράφουν άμεσα τα πρότυπα που εμφανίζονται στα δεδομένα.

Ένα σημαντικό πλεονέκτημα του PRISM είναι ότι κάθε κανόνας κατασκευάζεται με στόχο τη μεγιστοποίηση της πιθανότητας εμφάνισης μιας συγκεκριμένης κλάσης. Κατά τη διαδικασία δημιουργίας των κανόνων, ο αλγόριθμος επιλέγει επαναληπτικά τα ζεύγη χαρακτηριστικού-τιμής που μεγιστοποιούν την αναλογία των θετικών παραδειγμάτων για την υπό εξέταση κλάση. Η προσέγγιση αυτή οδηγεί στη δημιουργία κανόνων με υψηλή ακρίβεια, οι οποίοι αποτυπώνουν αποτελεσματικά τα χαρακτηριστικά μοτίβα που σχετίζονται με κάθε κατηγορία των δεδομένων.

Επιπλέον, ο PRISM δημιουργεί ένα σύνολο κανόνων στο οποίο κάθε κανόνας περιγράφει ένα συγκεκριμένο υποσύνολο των δεδομένων. Με τον τρόπο αυτό καθίσταται δυνατή η άμεση συσχέτιση των κανόνων με συγκεκριμένα πρότυπα που εμφανίζονται στο σύνολο δεδομένων, διευκολύνοντας την κατανόηση της σχέσης μεταξύ των χαρακτηριστικών και της κλάσης στόχου.

Ένα ακόμη σημαντικό πλεονέκτημα του αλγορίθμου είναι ότι οι κανόνες παράγονται ανεξάρτητα για κάθε κλάση. Η διαδικασία δημιουργίας κανόνων συνεχίζεται έως ότου καλυφθούν όλα τα παραδείγματα της συγκεκριμένης κλάσης, με αποτέλεσμα τη δημιουργία ενός πλήρους συνόλου κανόνων που περιγράφουν τη συμπεριφορά των δεδομένων για κάθε κατηγορία.

Τέλος, οι κανόνες που παράγονται από τον PRISM είναι άμεσα ερμηνεύσιμοι και κατανοητοί, καθώς έχουν τη μορφή απλών λογικών συνθηκών. Η δομή αυτή επιτρέπει την εύκολη ανάλυση και αξιολόγηση των κανόνων από ανθρώπινους χρήστες, ακόμη και χωρίς εξειδικευμένη γνώση σε σύνθετες μεθόδους μηχανικής μάθησης. Για τον λόγο αυτό, ο αλγόριθμος χρησιμοποιείται συχνά σε εφαρμογές όπου η κατανόηση και η αιτιολόγηση των αποφάσεων είναι ιδιαίτερα σημαντική, όπως σε συστήματα υποστήριξης αποφάσεων και σε εφαρμογές ανάλυσης δεδομένων.

6.5 Περιορισμοί του PRISM

Παρά τα σημαντικά του πλεονεκτήματα, ο PRISM παρουσιάζει και ορισμένους περιορισμούς. Ο αλγόριθμος βασίζεται στην υπόθεση ότι το σύνολο εκπαίδευσης είναι πλήρες και ακριβές, χωρίς σημαντικό θόρυβο ή σφάλματα στις ετικέτες των δεδομένων. Σε περιβάλλοντα με θορυβώδη δεδομένα, η αυστηρή απαίτηση για παραγωγή κανόνων υψηλής ακρίβειας μπορεί να οδηγήσει στην προσθήκη ολοένα και περισσότερων όρων, με σκοπό τον αποκλεισμό μεμονωμένων εξαιρέσεων.

Το φαινόμενο αυτό έχει ως αποτέλεσμα την παραγωγή υπερβολικά εξειδικευμένων κανόνων, οι οποίοι παρουσιάζουν χαμηλή ικανότητα γενίκευσης σε νέα δεδομένα. Με άλλα λόγια, ο PRISM είναι επιρρεπής στο φαινόμενο της υπερπροσαρμογής (overfitting) όταν εφαρμόζεται σε σύνολα δεδομένων με θόρυβο, εκτός αν συνοδεύεται από μηχανισμούς χαλάρωσης των κριτηρίων ακρίβειας ή τεχνικές κλαδέματος κανόνων. Επιπλέον, ο αλγόριθμος PRISM δεν ενσωματώνει εγγενώς μηχανισμούς κλαδέματος (pruning) κατά τη διαδικασία δημιουργίας των κανόνων, γεγονός που μπορεί να οδηγήσει στην παραγωγή ιδιαίτερα εξειδικευμένων ή περίπλοκων κανόνων όταν τα δεδομένα περιλαμβάνουν θόρυβο ή μεμονωμένες εξαιρέσεις. Ως αποτέλεσμα, χωρίς πρόσθετες τεχνικές επεξεργασίας ή απλοποίησης των κανόνων, το μοντέλο ενδέχεται να παρουσιάζει μειωμένη απόδοση κατά την εφαρμογή του σε νέα, μη παρατηρημένα δεδομένα.

Ένας ακόμη περιορισμός αφορά το υπολογιστικό κόστος του αλγορίθμου. Επειδή η διαδικασία επαγωγής επαναλαμβάνεται ανεξάρτητα για κάθε κλάση, ο συνολικός χρόνος εκτέλεσης αυξάνεται γραμμικά με τον αριθμό των κλάσεων. Σε προβλήματα με μεγάλο πλήθος κλάσεων ή χαρακτηριστικών, ο PRISM μπορεί να αποδειχθεί πιο αργός σε σύγκριση με αλγορίθμους βασισμένους σε δέντρα αποφάσεων, οι οποίοι κατασκευάζουν ένα ενιαίο μοντέλο για όλες τις κλάσεις.

Τέλος, όπως και οι περισσότεροι κλασικοί αλγόριθμοι επαγωγής κανόνων, ο PRISM σχεδιάστηκε αρχικά για κατηγορικά δεδομένα. Η εφαρμογή του σε συνεχή χαρακτηριστικά προϋποθέτει προηγούμενη διακριτοποίηση, διαδικασία που ενδέχεται να επηρεάσει την ποιότητα των παραγόμενων κανόνων αν δεν πραγματοποιηθεί προσεκτικά, καθώς η ακατάλληλη επιλογή ορίων διακριτοποίησης μπορεί να οδηγήσει σε απώλεια σημαντικής πληροφορίας.

6.6 Θεωρητική εφαρμογή του PRISM

Η εφαρμογή του αλγορίθμου PRISM παρουσιάζεται μέσω ενός χαρακτηριστικού παραδείγματος που βασίζεται στο γνωστό σύνολο δεδομένων **Play Tennis**, το οποίο χρησιμοποιείται συχνά στη βιβλιογραφία της μηχανικής μάθησης για την κατανόηση αλγορίθμων ταξινόμησης. Το σύνολο δεδομένων περιλαμβάνει παρατηρήσεις που περιγράφουν διαφορετικές καιρικές συνθήκες και την αντίστοιχη απόφαση για το αν θα πραγματοποιηθεί ή όχι ένα παιχνίδι τένις.

Κάθε εγγραφή του συνόλου δεδομένων περιλαμβάνει μια σειρά από κατηγορικά χαρακτηριστικά, όπως η μεταβλητή Outlook, η οποία περιγράφει την κατάσταση του καιρού (Sunny, Overcast ή Rain), η Humidity, που δηλώνει το επίπεδο υγρασίας (High ή Normal), καθώς και η μεταβλητή Wind, η οποία εκφράζει την ένταση του ανέμου (Weak ή Strong). Η μεταβλητή στόχος είναι η Class, η οποία λαμβάνει τις τιμές Yes ή No και υποδηλώνει αν τελικά θα παιχτεί τένις υπό τις συγκεκριμένες συνθήκες.

Το αρχικό σύνολο εκπαίδευσης παρουσιάζεται στον Πίνακα 6.1.

Πίνακας 6. 1 Αρχικό Σύνολο Εκπαίδευσης Play Tennis

#	Outlook	Humidity	Wind	Class
1	Sunny	High	Weak	No
2	Sunny	High	Strong	No
3	Overcast	High	Weak	Yes
4	Rain	Normal	Weak	Yes
5	Rain	Normal	Strong	No
6	Overcast	Normal	Strong	Yes
7	Sunny	Normal	Weak	Yes
8	Rain	High	Weak	No
9	Overcast	High	Strong	Yes

Στο παρόν παράδειγμα, η διαδικασία εφαρμόζεται για την κλάση *Class = Yes*.

Βήμα 1: Υπολογισμός πιθανοτήτων χαρακτηριστικών

Στο πρώτο στάδιο υπολογίζονται οι πιθανότητες εμφάνισης της κλάσης Yes για κάθε δυνατή τιμή των χαρακτηριστικών του συνόλου δεδομένων.

Χαρακτηριστικό: Outlook

- **Outlook = Sunny**
Σύνολο: 3, Yes: 1
 $P(\text{Yes}|\text{Sunny})=1/3$

- **Outlook = Overcast**
Σύνολο: 3, Yes: 3
 $P(\text{Yes}|\text{Overcast})=3/3=1$
- **Outlook = Rain**
Σύνολο: 3, Yes: 1
 $P(\text{Yes}|\text{Rain})=1/3$

Χαρακτηριστικό: Humidity

- **Humidity = High**
Σύνολο: 5, Yes: 2
 $P(\text{Yes}|\text{High})=2/5$
- **Humidity = Normal**
Σύνολο: 4, Yes: 3
 $P(\text{Yes}|\text{Normal})=3/4$

Χαρακτηριστικό: Wind

- **Wind = Weak**
Σύνολο: 5, Yes: 3
 $P(\text{Yes}|\text{Weak})=3/5$
- **Wind = Strong**
Σύνολο: 4, Yes: 2
 $P(\text{Yes}|\text{Strong})=2/4$

Η μέγιστη πιθανότητα είναι: $\max P=P(\text{Yes}|\text{Outlook}=\text{Overcast})=1.0$, άρα επιλέγεται ο όρος Outlook=Overcast.

Ο προσωρινός κανόνας είναι:

IF Outlook = Overcast THEN Class = Yes

Βήμα 2: Επαναληπτική εξειδίκευση του κανόνα

Τα παραδείγματα που καλύπτονται: Γραμμές 3, 6, 9, όλα ανήκουν στην κλάση Yes.

Το πλέον περιορισμένο σύνολο εκπαίδευσης παρουσιάζεται στον Πίνακα 6.2.

Πίνακας 6. 2 Περιορισμένο Σύνολο Εκπαίδευσης Play Tennis

#	Outlook	Humidity	Wind	Class
3	Overcast	High	Weak	Yes

6	Overcast	Normal	Strong	Yes
9	Overcast	High	Strong	Yes

Από τον πίνακα προκύπτει ότι η ακρίβεια είναι: $Accuracy = 3/3 = 1$.

Ο κανόνας είναι απολύτως καθαρός, συνεπώς δεν προστίθεται άλλος όρος.

Άρα ο τελικός κανόνας είναι: **IF Outlook = Overcast THEN Class = Yes**

Βήμα 3: Αφαίρεση καλυπτόμενων παραδειγμάτων

Αφαιρούνται τα παραδείγματα 3, 6 και 9 από το σύνολο δεδομένων για την κλάση Yes.

Ο νέος πίνακας παρουσιάζεται στον Πίνακα 6.3.

Πίνακας 6. 3 Νέο Σύνολο Εκπαίδευσης Play Tennis

#	Outlook	Humidity	Wind	Class
1	Sunny	High	Weak	No
2	Sunny	High	Strong	No
4	Rain	Normal	Weak	Yes
5	Rain	Normal	Strong	No
7	Sunny	Normal	Weak	Yes
8	Rain	High	Weak	No

Συνεχίζεται η διαδικασία επαγωγής κανόνων για την κλάση Class = Yes.

Βήμα 1: Υπολογισμός πιθανοτήτων χαρακτηριστικών

Χαρακτηριστικό: Outlook

- Outlook = Sunny
Σύνολο: 3, Yes: 1
 $P(\text{Yes}|\text{Outlook} = \text{Sunny}) = 1/3$
- Outlook = Rain
Σύνολο: 3, Yes: 1
 $P(\text{Yes}|\text{Outlook} = \text{Rain}) = 1/3$

Χαρακτηριστικό: Humidity

- Humidity = High
Σύνολο: 3, Yes: 0
 $P(\text{Yes}|\text{Humidity} = \text{High}) = 0$
- Humidity = Normal
Σύνολο: 3, Yes: 2
 $P(\text{Yes}|\text{Humidity} = \text{Normal}) = 2/3$

Χαρακτηριστικό: Wind

- Wind = Weak
Σύνολο: 4, Yes: 2
 $P(\text{Yes}|\text{Wind} = \text{Weak}) = 2/4 = 1/2$
- Wind = Strong
Σύνολο: 2, Yes: 0
 $P(\text{Yes}|\text{Wind} = \text{Strong}) = 0$

Η μέγιστη πιθανότητα είναι: $\max_{\{H\}} P = P(\text{Humidity} = \text{Normal}) = 2/3$, άρα επιλέγεται ο όρος Humidity = Normal.

Ο προσωρινός κανόνας είναι:

IF Humidity = Normal THEN Class = Yes

Βήμα 2: Επαναληπτική εξειδίκευση του κανόνα

Κρατάμε μόνο τα παραδείγματα με Humidity = Normal.

Πίνακας 6. 4 Περιορισμένο Σύνολο Εκπαίδευσης Play Tennis

#	Outlook	Humidity	Wind	Class
---	---------	----------	------	-------

4	Rain	Normal	Weak	Yes
5	Rain	Normal	Strong	No
7	Sunny	Normal	Weak	Yes

Από τον πίνακα προκύπτει ότι η ακρίβεια είναι: $Accuracy=2/3$

Δεν είναι απολύτως καθαρός, άρα συνεχίζουμε.

Νέος υπολογισμός πιθανοτήτων

Χαρακτηριστικό: Outlook

- Outlook = Rain
Σύνολο: 2, Yes: 1
 $P(Yes|Rain) = 1/2$
- Outlook = Sunny
Σύνολο: 1, Yes: 1
 $P(Yes|Sunny) = 1$

Χαρακτηριστικό: Wind

- Wind = Weak
Σύνολο: 2, Yes: 2
 $P(Yes|Weak) = 1$
- Wind = Strong
Σύνολο: 1, Yes: 0
 $P(Yes|Strong) = 0$

Χαρακτηριστικό: Humidity

- Humidity = Normal
Σύνολο: 3, Yes: 2
 $P(Yes|Humidity = Normal) = 2/3$

Επιλογή καλύτερου όρου:

Οι όροι:

- Outlook = Sunny
- Wind = Weak

έχουν ίση μέγιστη πιθανότητα (1.0).

Σύμφωνα με τη συνήθη πρακτική του PRISM, επιλέγεται ο όρος που καλύπτει περισσότερα παραδείγματα

Άρα επιλέγεται:

Wind = Weak

Τελικός δεύτερος κανόνας

IF Humidity = Normal AND Wind = Weak THEN Class = Yes

Βήμα 3: Αφαίρεση καλυπτόμενων παραδειγμάτων

Παραδείγματα που καλύπτονται: Γραμμές 4 και 7, και τα δύο ανήκουν στην κλάση Yes και αφαιρούνται από τον πίνακα.

Πίνακας 6. 5 Τελικό Σύνολο Εκπαίδευσης Play Tennis για την Κλάση Yes

#	Outlook	Humidity	Wind	Class
5	Rain	Normal	Strong	No

Accuracy=2/2=1, Ο κανόνας είναι πλήρως καθαρός, άρα η εξειδίκευση σταματά.

Σύνολο κανόνων για Class = Yes

1. IF Outlook = Overcast THEN Class = Yes
2. IF Humidity = Normal AND Wind = Weak THEN Class = Yes

6.7 Πρακτική εφαρμογή του PRISM

Η πρακτική υλοποίηση του αλγορίθμου PRISM πραγματοποιήθηκε σε γλώσσα Python με στόχο την αναπαραγωγή της διαδικασίας επαγωγής κανόνων που περιγράφηκε παραπάνω. Η υλοποίηση ακολουθεί πιστά τα βασικά βήματα του αλγορίθμου, δηλαδή την επιλογή του καλύτερου όρου, την επαναληπτική εξειδίκευση των κανόνων, την παραγωγή καθαρών κανόνων ταξινόμησης και την αφαίρεση των παραδειγμάτων που καλύπτονται από αυτούς.

Ο κώδικας σχεδιάστηκε με αντικειμενοστραφή προσέγγιση και υλοποιείται μέσω της κλάσης **CanonicalPrism**, η οποία περιλαμβάνει τις βασικές λειτουργίες εκπαίδευσης, δημιουργίας κανόνων. Παράλληλα, υλοποιείται μηχανισμός εξαγωγής των παραγόμενων κανόνων σε πίνακα αποφάσεων DMN, επιτρέποντας την ενσωμάτωσή τους σε συστήματα διαχείρισης επιχειρησιακών κανόνων.

Γενική Αρχιτεκτονική της Υλοποίησης

Η υλοποίηση οργανώνεται γύρω από την κλάση CanonicalPrism, η οποία ενθυλακώνει τη λογική λειτουργίας του αλγορίθμου PRISM. Η κλάση αυτή διαχειρίζεται:

- την αποθήκευση των κανόνων που παράγονται,
- την εκπαίδευση του μοντέλου πάνω στα δεδομένα,
- τον καθορισμό της προεπιλεγμένης κλάσης (default class).

Οι κανόνες αποθηκεύονται σε μια δομή λεξικού, όπου κάθε κλάση του προβλήματος αντιστοιχεί σε μια λίστα κανόνων. Κάθε κανόνας αναπαρίσταται ως λίστα ζευγών της μορφής attribute = value γεγονός που επιτρέπει την εύκολη επεξεργασία και μετατροπή τους σε άλλες μορφές αναπαράστασης.

Η προσέγγιση αυτή αντικατοπτρίζει τη βασική φιλοσοφία του PRISM, σύμφωνα με την οποία οι κανόνες δημιουργούνται ανεξάρτητα για κάθε κλάση και μπορούν να εφαρμοστούν χωρίς να απαιτείται συγκεκριμένη ιεραρχική δομή.

Η υλοποίηση ορίζεται ως εξής:

Επιλογή του καλύτερου όρου κανόνα

Η επιλογή του καταλληλότερου όρου για την κατασκευή ενός κανόνα πραγματοποιείται μέσω της συνάρτησης **_best_term()**. Η συνάρτηση αυτή εξετάζει όλα τα διαθέσιμα χαρακτηριστικά του συνόλου δεδομένων και τις δυνατές τιμές τους και υπολογίζει την υπό συνθήκη πιθανότητα που περιγράφηκε παραπάνω. Για κάθε υποψήφιο όρο υπολογίζεται ο αριθμός των παραδειγμάτων που ανήκουν στην κλάση στόχο και ικανοποιούν τον συγκεκριμένο όρο, καθώς και ο συνολικός αριθμός των παραδειγμάτων που καλύπτονται από αυτόν. Με βάση τα μεγέθη αυτά προκύπτει η πιθανότητα ένα παράδειγμα που ικανοποιεί τον όρο να ανήκει στην κλάση στόχο.

Η επιλογή του καταλληλότερου όρου πραγματοποιείται με βάση τρία διαδοχικά κριτήρια. Αρχικά επιλέγεται ο όρος που παρουσιάζει τη μεγαλύτερη υπό συνθήκη πιθανότητα της κλάσης στόχου, δηλαδή ο όρος για τον οποίο τα περισσότερα από τα παραδείγματα που καλύπτονται ανήκουν πράγματι στην κλάση αυτή. Σε περίπτωση που περισσότεροι όροι εμφανίζουν την ίδια πιθανότητα, προτιμάται εκείνος που καλύπτει τον μεγαλύτερο αριθμό θετικών παραδειγμάτων, δηλαδή παραδειγμάτων

που ανήκουν στην κλάση στόχο. Τέλος, αν εξακολουθεί να υπάρχει ισοπαλία, επιλέγεται ο όρος με τη μεγαλύτερη συνολική κάλυψη παραδειγμάτων στο σύνολο δεδομένων. Με τον τρόπο αυτό επιλύονται περιπτώσεις ισοπαλίας μεταξύ υποψήφιων όρων και διασφαλίζεται ότι επιλέγεται ο όρος που περιγράφει με τον πιο αντιπροσωπευτικό τρόπο την κλάση στόχο.

Ο κώδικας 6.1 παρουσιάζει την υλοποίηση της παραπάνω διαδικασίας.

Κώδικας 6.1 Υλοποίηση της μεθόδου `_best_term`

```
def _best_term(self, df, target_col, target_val, used_cols):

    best_term = None
    best_prob = -1
    best_pos_covered = -1
    best_total_covered = -1

    for col in df.columns:
        if col == target_col or col in used_cols:
            continue

        for val in df[col].unique():

            subset = df[df[col] == val]

            if len(subset) == 0:
                continue

            pos = len(subset[subset[target_col] ==
target_val])
            total = len(subset)

            prob = pos / total

            if prob > best_prob:
                best_prob = prob
                best_term = (col, val)
                best_pos_covered = pos
                best_total_covered = total

            elif prob == best_prob:
                if pos > best_pos_covered:
                    best_term = (col, val)
                    best_pos_covered = pos
                    best_total_covered = total
                elif pos == best_pos_covered and total
> best_total_covered:
                    best_term = (col, val)
                    best_total_covered = total

    return best_term, best_prob
```

Δημιουργία κανόνων ανά κλάση

Η δημιουργία των κανόνων πραγματοποιείται μέσω της μεθόδου `_learn_rules_for_class()`, η οποία εφαρμόζει τη στρατηγική *separate-and-conquer*.

Η διαδικασία ξεκινά με την επιλογή μιας συγκεκριμένης κλάσης στόχου και επαναλαμβάνεται όσο υπάρχουν παραδείγματα της κλάσης αυτής στο σύνολο δεδομένων.

Σε κάθε επανάληψη:

1. Δημιουργείται ένας νέος κανόνας.
2. Επιλέγεται ο καλύτερος διαθέσιμος όρος.
3. Το σύνολο δεδομένων περιορίζεται μόνο στα παραδείγματα που ικανοποιούν τον όρο

Η διαδικασία συνεχίζεται επαναληπτικά μέχρι ο κανόνας να καλύπτει αποκλειστικά παραδείγματα της κλάσης στόχου, επιτυγχάνοντας πλήρη καθαρότητα.

Αφού ολοκληρωθεί ο κανόνας, τα παραδείγματα που καλύπτονται από αυτόν αφαιρούνται από το σύνολο δεδομένων και η διαδικασία επαναλαμβάνεται για τα υπόλοιπα παραδείγματα της ίδιας κλάσης.

Ο κώδικας 6.2 παρουσιάζει την υλοποίηση της παραπάνω διαδικασίας.

Κώδικας 6.2 Υλοποίηση της μεθόδου `_learn_rules_for_class()`

```
def _learn_rules_for_class(self, df, target_col, target_val):  
  
    df_remaining = df.copy()  
    class_rules = []  
  
    while (df_remaining[target_col] == target_val).any():  
  
        rule = []  
        used_cols = []  
        df_work = df_remaining.copy()  
  
        while True:  
            term, prob = self._best_term(  
                df_work, target_col, target_val, used_cols  
            )  
  
            if term is None:  
                break  
  
            col, val = term  
            rule.append((col, val))  
            used_cols.append(col)  
  
            df_work = df_work[df_work[col] == val]  
  
            if all(df_work[target_col] == target_val):  
                break  
  
        class_rules.append(rule)  
  
        df_remaining = df_remaining.drop(df_work.index)  
  
    return class_rules
```

Εκπαίδευση του μοντέλου

Η συνολική εκπαίδευση του μοντέλου πραγματοποιείται μέσω της μεθόδου **`fit()`**.

Κατά τη διαδικασία αυτή:

1. Ελέγχεται ότι όλα τα χαρακτηριστικά του συνόλου δεδομένων είναι κατηγορικά.
2. Προσδιορίζεται η στήλη που αντιστοιχεί στην κλάση στόχο.
3. Εκτελείται η διαδικασία δημιουργίας κανόνων ξεχωριστά για κάθε κλάση.

Μετά την ολοκλήρωση της εκπαίδευσης υπολογίζεται επίσης η default class, η οποία αντιστοιχεί στην πλειοψηφική κλάση του συνόλου εκπαίδευσης.

Ο κώδικας 6.3 παρουσιάζει την υλοποίηση της παραπάνω διαδικασίας.

Κώδικας 6.3 Υλοποίηση της μεθόδου fit()

```
def fit(self, df, target_col):  
  
    for col in df.columns:  
        if is_numeric_dtype(df[col]):  
            raise ValueError(  
                f"Ο PRISM απαιτεί κατηγορικά χαρακτηριστικά. "  
                f"Η στήλη '{col}' είναι αριθμητική."  
            )  
  
    self.target_col = target_col  
    self.rules = {}  
  
    for target_val in df[target_col].unique():  
        self.rules[target_val] = self._learn_rules_for_class(  
            df, target_col, target_val  
        )  
  
    self.default_target = df[target_col].mode()[0]  
  
    return self.rules
```

Εφαρμογή στο Σύνολο δεδομένων Play Tennis

Η υλοποίηση εφαρμόζεται στο κατηγορικό σύνολο δεδομένων τύπου Play Tennis, το οποίο περιλαμβάνει τα εξής χαρακτηριστικά:

- **Outlook** (Sunny, Overcast, Rain)
- **Humidity** (High, Normal)
- **Wind** (Weak, Strong)

Στόχος είναι η πρόβλεψη της μεταβλητής PlayTennis (Yes/No).

Η εφαρμογή του συνόλου δεδομένων, η κλήση της μεθόδου εκπαίδευσης και η εκτύπωση των παραγόμενων κανόνων υλοποιήθηκαν στον κώδικα 6.4.

Κώδικας 6.4 Εφαρμογή PRISM στο σύνολο δεδομένων Play Tennis

```

data = {
    "Outlook": ["Sunny", "Sunny", "Overcast", "Rain", "Rain",
               "Overcast", "Sunny", "Rain", "Overcast"],
    "Humidity": ["High", "High", "High", "Normal", "Normal",
                "Normal", "Normal", "High", "High"],
    "Wind": ["Weak", "Strong", "Weak", "Weak", "Strong",
            "Strong", "Weak", "Weak", "Strong"],
    "PlayTennis": ["No", "No", "Yes", "Yes", "No",
                  "Yes", "Yes", "No", "Yes"]
}

df = pd.DataFrame(data)

prism = CanonicalPrism()
rules = prism.fit(df, target_col="PlayTennis")

for cls, rs in rules.items():
    print(f"\nCLASS = {cls}")
    for i, r in enumerate(rs, 1):
        conditions = " AND ".join(f"{c} = {v}" for c, v in r)
        print(f"Rule {i}: IF {conditions} THEN {cls}")

print("\nDefault class:", prism.default_target)

```

Η εκπαίδευση του αλγορίθμου παράγαγε τους εξής κανόνες:

CLASS = No

Rule 1: IF Outlook = Sunny AND Humidity = High THEN No

Rule 2: IF Outlook = Rain AND Humidity = High THEN No

Rule 3: IF Outlook = Rain AND Wind = Strong THEN No

CLASS = Yes

Rule 1: IF Outlook = Overcast THEN Yes

Rule 2: IF Humidity = Normal AND Wind = Weak THEN Yes

Default class: Yes

Μετατροπή κανόνων σε πίνακα DMN

Πέραν της εκπαίδευσης, η υλοποίηση περιλαμβάνει μηχανισμό εξαγωγής των κανόνων σε DMN πίνακα αποφάσεων, ώστε να μπορούν να αξιοποιηθούν σε επιχειρησιακά συστήματα όπως το Camunda.

Η διαδικασία περιλαμβάνει τα εξής στάδια:

- **Προσδιορισμός εισόδων:** Εντοπίζονται όλα τα χαρακτηριστικά που εμφανίζονται στους κανόνες. Κάθε χαρακτηριστικό αντιστοιχεί σε μία στήλη εισόδου του πίνακα αποφάσεων.
- **Μετατροπή κανόνων σε γραμμές πίνακα:** Κάθε κανόνας του PRISM μετατρέπεται σε μία γραμμή του DMN πίνακα. Τα χαρακτηριστικά που δεν συμμετέχουν στον κανόνα δηλώνονται με το σύμβολο αδιαφορίας (-).
- **Καθορισμός εξόδου:** Η έξοδος κάθε γραμμής αντιστοιχεί στην κλάση που προβλέπει ο κανόνας.
- **Πολιτική ενεργοποίησης (hit policy):** Ορίζεται ως FIRST, ώστε ο πίνακας να λειτουργεί όπως οι κανόνες PRISM: ο πρώτος κανόνας που ικανοποιείται καθορίζει την απόφαση.
- **Αποθήκευση σε XML:** Το παραγόμενο αρχείο DMN είναι συμβατό με το Camunda και μπορεί να εισαχθεί απευθείας στο περιβάλλον για περαιτέρω εκτέλεση ή οπτικοποίηση.

Ο κώδικας 6.5 παρουσιάζει την υλοποίηση της παραπάνω διαδικασίας.

Κώδικας 6.5 Διαδικασία μετατροπής κανόνων σε πίνακα DMN

```
def export_prism_to_dmn(prism, decision_name, filename):  
    """  
    Μετατρέπει τους PRISM κανόνες (CanonicalPrism)  
    σε DMN decision table συμβατό με Camunda  
    """  
  
    inputs = sorted({  
        term[0]  
        for rules in prism.rules.values()  
        for rule in rules  
        for term in rule  
    })
```

```

definitions = ET.Element(
    "definitions",
    {
        "xmlns": "https://www.omg.org/spec/DMN/20191111/MODEL/",
        "xmlns:camunda": "http://camunda.org/schema/1.0/dmn",
        "id": f"def_{uuid.uuid4()}",
        "name": decision_name,
        "namespace": "http://camunda.org/schema/1.0/dmn"
    }
)

decision = ET.SubElement(
    definitions,
    "decision",
    {
        "id": f"dec_{uuid.uuid4()}",
        "name": decision_name
    }
)

table = ET.SubElement(
    decision,
    "decisionTable",
    {
        "id": f"dt_{uuid.uuid4()}",
        "hitPolicy": "FIRST"
    }
)

for inp in inputs:
    i = ET.SubElement(table, "input")
    expr = ET.SubElement(i, "inputExpression", {"typeRef":
"string"})
    ET.SubElement(expr, "text").text = inp

ET.SubElement(
    table,
    "output",
    {
        "name": prism.target_col,
        "typeRef": "string"
    }
)

for class_label, rules in prism.rules.items():

    for rule in rules:
        r = ET.SubElement(table, "rule")

        rule_map = {attr: val for attr, val in rule}

        for inp in inputs:
            e = ET.SubElement(r, "inputEntry")
            ET.SubElement(e, "text").text = (

```

```

        f"\{rule_map[inp]}\\" if inp in rule_map else "-"
    )

    out = ET.SubElement(r, "outputEntry")
    ET.SubElement(out, "text").text = str(class_label)

xml = minidom.parseString(
    ET.tostring(definitions, encoding="utf-8")
).toprettyxml(indent=" ")

with open(filename, "w", encoding="utf-8") as f:
    f.write(xml)

print(f"\n DMN αρχείο δημιουργήθηκε: {filename}")

```

PRISM Decision Table Hit policy: First					
	When	And	And	Then	Annotations
	Humidity	Outlook	Wind	PlayTennis	
	string	string	string	string	
1	"High"	"Sunny"	-	No	
2	"High"	"Rain"	-	No	
3	-	"Rain"	"Strong"	No	
4	-	"Overcast"	-	Yes	
5	"Normal"	-	"Weak"	Yes	
+	-	-	-		

Εικόνα 6. 1 Πίνακας Αποφάσεων DMN

Ο πίνακας της Εικόνας 6.1 παρουσιάζει τη δομημένη αναπαράσταση των κανόνων ταξινόμησης που προέκυψαν από την εφαρμογή του αλγορίθμου PRISM στο σύνολο δεδομένων *Play Tennis*. Κάθε γραμμή του πίνακα αντιστοιχεί σε έναν κανόνα της μορφής IF-THEN, όπου τα χαρακτηριστικά Humidity, Outlook και Wind αποτελούν τις συνθήκες του κανόνα, ενώ το PlayTennis αντιπροσωπεύει την τελική απόφαση ταξινόμησης.

Πιο συγκεκριμένα, ο πρώτος κανόνας υποδεικνύει ότι όταν η υγρασία είναι High και ο καιρός Sunny, τότε η απόφαση είναι PlayTennis = No. Ο δεύτερος κανόνας δηλώνει ότι όταν ο καιρός είναι Rain και η υγρασία High, τότε επίσης η απόφαση είναι PlayTennis = No. Ο τρίτος κανόνας δείχνει ότι όταν ο καιρός είναι Rain και ο άνεμος Strong, τότε η απόφαση είναι και πάλι PlayTennis = No. Αντίθετα, ο τέταρτος κανόνας υποδεικνύει ότι όταν ο καιρός είναι Overcast, τότε η απόφαση είναι PlayTennis = Yes,

ανεξάρτητα από τις τιμές των άλλων χαρακτηριστικών. Τέλος, ο πέμπτος κανόνας δηλώνει ότι όταν η υγρασία είναι Normal και ο άνεμος Weak, τότε η απόφαση είναι PlayTennis = Yes.

Η ολοκληρωμένη υλοποίηση της παραπάνω διαδικασίας για τον αλγόριθμο PRISM είναι διαθέσιμη στον ακόλουθο σύνδεσμο:

<https://github.com/DanaeKouimtzipou/prism-to-dmn>

6.8 Σύνοψη

Στο κεφάλαιο αυτό παρουσιάστηκε ο αλγόριθμος PRISM, ένας αλγόριθμος επαγωγής κανόνων που χρησιμοποιείται για την παραγωγή κανόνων ταξινόμησης απευθείας από δεδομένα. Αρχικά αναλύθηκε το θεωρητικό υπόβαθρο των μεθόδων επαγωγής κανόνων και η βασική ιδέα της αναπαράστασης της γνώσης μέσω κανόνων της μορφής if-then.

Στη συνέχεια παρουσιάστηκε η λειτουργία του PRISM και η διαδικασία δημιουργίας κανόνων μέσω της στρατηγικής *separate-and-conquer*, κατά την οποία οι κανόνες παράγονται σταδιακά ώστε να καλύπτουν συγκεκριμένα υποσύνολα των δεδομένων. Αναλύθηκαν επίσης τα βασικά στάδια της μεθοδολογίας του αλγορίθμου, όπως η επιλογή της κλάσης στόχου, ο υπολογισμός των πιθανοτήτων για τα χαρακτηριστικά, η επιλογή των όρων που μεγιστοποιούν την ακρίβεια του κανόνα και η επαναληπτική εξειδίκευση των κανόνων μέχρι την επίτευξη ικανοποιητικής καθαρότητας.

Στη συνέχεια εξετάστηκαν τα βασικά πλεονεκτήματα και οι περιορισμοί του PRISM. Ιδιαίτερη έμφαση δόθηκε στην ερμηνευσιμότητα των κανόνων που παράγονται, καθώς και στην ευελιξία που προσφέρει η ανεξάρτητη δομή τους. Παράλληλα επισημάνθηκαν ορισμένοι περιορισμοί, όπως η ευαισθησία του αλγορίθμου σε θορυβώδη δεδομένα και η ανάγκη διακριτοποίησης των συνεχών χαρακτηριστικών.

Τέλος, παρουσιάστηκε ένα αναλυτικό παράδειγμα εφαρμογής του αλγορίθμου στο σύνολο δεδομένων Play Tennis, το οποίο ανέδειξε βήμα προς βήμα τη διαδικασία δημιουργίας κανόνων. Η θεωρητική αυτή ανάλυση συμπληρώθηκε με την πρακτική υλοποίηση του PRISM σε γλώσσα Python, καθώς και με τη μετατροπή των παραγόμενων κανόνων σε πίνακα αποφάσεων DMN. Με τον τρόπο αυτό αναδείχθηκε πώς οι κανόνες που εξάγονται από δεδομένα μπορούν να αναπαρασταθούν σε τυποποιημένη μορφή και να αξιοποιηθούν σε συστήματα επιχειρησιακών αποφάσεων.

Κεφάλαιο 7: Πειραματική Αξιολόγηση PRISM και CART σε Συνθετικό Σύνολο Δεδομένων

Το κεφάλαιο αυτό παρουσιάζει την πειραματική εφαρμογή και αξιολόγηση των μεθόδων εξαγωγής κανόνων που εξετάζονται στην παρούσα εργασία. Αρχικά περιγράφεται ο σχεδιασμός του πειραματικού πλαισίου και η δημιουργία ενός συνθετικού συνόλου δεδομένων βασισμένου σε προκαθορισμένους επιχειρησιακούς κανόνες απόφασης. Στη συνέχεια εφαρμόζονται δύο διαφορετικές προσεγγίσεις μάθησης, ο αλγόριθμος εξαγωγής κανόνων PRISM και ο αλγόριθμος δέντρων απόφασης CART, με στόχο την παραγωγή κανόνων απόφασης από τα δεδομένα. Οι παραγόμενοι κανόνες μετασχηματίζονται σε πίνακες απόφασης σύμφωνα με το πρότυπο DMN, ώστε να είναι συμβατά με συστήματα διαχείρισης επιχειρησιακών αποφάσεων. Τέλος, πραγματοποιείται αξιολόγηση των αποτελεσμάτων με στόχο τη διερεύνηση του βαθμού στον οποίο οι παραγόμενοι κανόνες αποτυπώνουν τη λογική του αρχικού μηχανισμού λήψης απόφασης.

7.1 Σχεδιασμός Πειραματικού Πλαισίου

Στο πλαίσιο της πειραματικής αξιολόγησης των μεθόδων εξαγωγής κανόνων που εξετάζονται, σχεδιάστηκε ένα ελεγχόμενο πειραματικό περιβάλλον, το οποίο προσομοιώνει μια απλή διαδικασία επιχειρησιακής λήψης απόφασης. Συγκεκριμένα, το πειραματικό πλαίσιο αφορά την απόφαση έγκρισης ή απόρριψης μιας αίτησης δανείου. Η απόφαση αυτή καθορίζεται από ένα σύνολο προκαθορισμένων επιχειρησιακών κανόνων, οι οποίοι βασίζονται σε δύο βασικά χαρακτηριστικά του αιτούντος, την ηλικία (Age) και το εισόδημα (Income). Με βάση τους κανόνες αυτούς προσδιορίζεται η μεταβλητή-στόχος (Loan_Approval), η οποία αποτυπώνει την τελική απόφαση ως έγκριση (Approve) ή απόρριψη (Reject). Οι κανόνες αυτοί χρησιμοποιούνται τόσο για τον ορισμό της λογικής του μηχανισμού απόφασης όσο και για τη δημιουργία ενός συνθετικού συνόλου δεδομένων, το οποίο αξιοποιείται στη συνέχεια για την εκπαίδευση και αξιολόγηση των αλγορίθμων εξαγωγής κανόνων.

Οι επιχειρησιακοί κανόνες που χρησιμοποιήθηκαν για τον καθορισμό της απόφασης διατυπώνονται ως εξής:

1. Εάν η ηλικία είναι μικρότερη των 18 ετών, τότε η αίτηση απορρίπτεται.
2. Εάν η ηλικία είναι μεγαλύτερη των 65 ετών, τότε η αίτηση απορρίπτεται.
3. Εάν η ηλικία βρίσκεται στο διάστημα [18, 65] και το εισόδημα είναι μεγαλύτερο ή ίσο των 33.001 μονάδων, τότε η αίτηση εγκρίνεται.

Με βάση τους παραπάνω κανόνες δημιουργήθηκε ένα συνθετικό σύνολο δεδομένων, δηλαδή ένα σύνολο δεδομένων που δεν προέρχεται από πραγματικές παρατηρήσεις αλλά παράγεται μέσω υπολογιστικών διαδικασιών για σκοπούς ανάλυσης και πειραματισμού. Για τη δημιουργία του συνόλου δεδομένων χρησιμοποιήθηκε η γλώσσα προγραμματισμού Python και οι βιβλιοθήκες NumPy και Pandas. Η διαδικασία παραγωγής των δεδομένων βασίζεται στην τυχαία δημιουργία τιμών για τις μεταβλητές Age και Income και στην εφαρμογή των επιχειρησιακών κανόνων για τον προσδιορισμό της μεταβλητής στόχου Loan_Approval.

Πιο συγκεκριμένα, η διαδικασία δημιουργίας του συνθετικού συνόλου δεδομένων περιλαμβάνει τα ακόλουθα βήματα:

- Τυχαία παραγωγή τιμών ηλικίας στο διάστημα $[0, 100]$.
- Τυχαία παραγωγή τιμών εισοδήματος στο διάστημα $[0, 100000]$.
- Εφαρμογή των επιχειρησιακών κανόνων σε κάθε ζεύγος τιμών (Age, Income).
- Ανάθεση της ετικέτας *Approve* ή *Reject* στη μεταβλητή στόχο Loan_Approval.

Ο Κώδικας 7.1 παρουσιάζει τη διαδικασία δημιουργίας του συνθετικού dataset.

Κώδικας 7.1: Δημιουργία συνθετικού dataset

```
import pandas as pd
import numpy as np

np.random.seed(42)

n = 100

age = np.random.randint(0, 100, n)
income = np.random.randint(0, 100000, n)

approval = []

for a, inc in zip(age, income):
    if a < 18 or a > 65:
        approval.append("Reject") # Changed 0 to "Reject" for
consistency
    elif 18 <= a <= 65 and 33001 <= inc <= 100000:
        approval.append("Approve")
    else:
        approval.append("Reject")

df = pd.DataFrame({
    "Age": age,
    "Income": income,
    "Loan_Approval": approval
})

df.to_csv("loan_dataset.csv", index=False)
```

Το τελικό σύνολο δεδομένων (dataset_loan.csv) αποτελείται από 100 εγγραφές, καθεμία από τις οποίες περιλαμβάνει τις ακόλουθες μεταβλητές:

- **Age:** Ακέραια αριθμητική μεταβλητή που λαμβάνει τιμές στο διάστημα [0, 100]. Το εύρος αυτό καλύπτει το σύνολο των πιθανών ηλικιακών περιπτώσεων, συμπεριλαμβανομένων τιμών που οδηγούν αυτομάτως σε απόρριψη σύμφωνα με τους επιχειρησιακούς κανόνες.
- **Income:** Αριθμητική μεταβλητή που λαμβάνει τιμές στο διάστημα [0, 100000], επιτρέποντας τη διάκριση μεταξύ διαφορετικών επιπέδων εισοδήματος σύμφωνα με τα προκαθορισμένα όρια απόφασης.
- **Loan_Approval:** Κατηγορική μεταβλητή-στόχος που λαμβάνει τις τιμές *Approve* ή *Reject* και αποτυπώνει την τελική απόφαση έγκρισης ή απόρριψης της αίτησης, όπως αυτή προκύπτει από την εφαρμογή των επιχειρησιακών

κανόνων.

Στον Πίνακα 7.1 παρουσιάζονται ενδεικτικά οι πρώτες εγγραφές του παραγόμενου συνόλου δεδομένων.

Πίνακας 7. 1 Παρουσίαση Ενδεικτικών Εγγραφών

Age	Income	Loan_Approval
51	12185	Reject
92	63704	Reject
14	86779	Reject
71	39099	Reject
60	8571	Reject
20	38044	Approve
82	51214	Reject
86	61228	Reject
74	48984	Reject
74	40774	Reject

Οι ανωτέρω εγγραφές καταδεικνύουν τον τρόπο με τον οποίο εφαρμόζονται οι επιχειρησιακοί κανόνες στο σύνολο δεδομένων. Συγκεκριμένα, παρατηρείται ότι οι περιπτώσεις στις οποίες η ηλικία βρίσκεται εκτός του διαστήματος [18, 65] οδηγούν αυτομάτως σε απόρριψη της αίτησης. Αντίθετα, όταν η ηλικία βρίσκεται εντός του διαστήματος [18, 65], η απόφαση αξιολογείται περαιτέρω με βάση το επίπεδο εισοδήματος. Ειδικότερα, εάν το εισόδημα είναι μεγαλύτερο ή ίσο των 33.001 μονάδων, η αίτηση εγκρίνεται, ενώ σε διαφορετική περίπτωση απορρίπτεται. Η τελική απόφαση αποτυπώνεται στη δυαδική μεταβλητή `Loan_Approval`, η οποία λαμβάνει τις τιμές *Approve* ή *Reject*.

7.2 Σκοπός Πειραματικής Διαδικασίας

Η συγκεκριμένη πειραματική διαδικασία επιτρέπει:

- Τη σύγκριση μεταξύ αλγορίθμων εξαγωγής κανόνων (PRISM) και δέντρων απόφασης (CART).
- Την αξιολόγηση της ικανότητας κάθε μεθόδου να αναπαράγει τον αρχικό συμβολικό κανόνα.

Πιο συγκεκριμένα, η ύπαρξη ενός προκαθορισμένου και πλήρως ορισμένου μηχανισμού λήψης απόφασης επιτρέπει την αντικειμενική αξιολόγηση των παραγόμενων μοντέλων. Καθώς ο τρόπος με τον οποίο παράγεται η μεταβλητή-στόχος είναι εκ των προτέρων γνωστός και διατυπωμένος με ρητούς κανόνες, καθίσταται δυνατή η άμεση και συστηματική σύγκριση μεταξύ του αρχικού πλαισίου απόφασης και των κανόνων που εξάγονται από κάθε αλγόριθμο.

Στην περίπτωση των αλγορίθμων εξαγωγής κανόνων, όπως ο PRISM, το ενδιαφέρον επικεντρώνεται στην ικανότητά τους να παράγουν σαφείς και άμεσα ερμηνεύσιμους κανόνες απόφασης. Αντιθέτως, τα δέντρα απόφασης, όπως ο CART, βασίζονται σε στατιστικά κριτήρια διαχωρισμού (Gini impurity) και επιδιώκουν τη βέλτιστη διαίρεση του χώρου χαρακτηριστικών με στόχο τη μείωση της αβεβαιότητας. Κατά συνέπεια, ενδέχεται να προσεγγίζουν τον αρχικό μηχανισμό χωρίς να τον αναπαράγουν ακριβώς, ιδίως ως προς τα ακριβή αριθμητικά όρια.

Η σύγκριση αυτή επιτρέπει τη διερεύνηση θεμελιωδών διαφορών μεταξύ δύο φιλοσοφιών μάθησης:

- της συμβολικής προσέγγισης, η οποία στοχεύει στην εξαγωγή ρητών, λογικά δομημένων κανόνων,
- και της στατιστικής προσέγγισης, η οποία στοχεύει στη βελτιστοποίηση της προβλεπτικής απόδοσης μέσω αριθμητικών κριτηρίων.

Επειδή στο συγκεκριμένο πείραμα ο μηχανισμός απόφασης είναι γνωστός και πλήρως καθορισμένος, δημιουργείται ένα ιδανικό πλαίσιο για τη μελέτη των διαφορών μεταξύ των δύο προσεγγίσεων. Έτσι, μπορούμε να αξιολογήσουμε όχι μόνο την ακρίβεια των μοντέλων, αλλά και το κατά πόσο αποτυπώνουν πιστά τη λογική του αρχικού συστήματος, καθώς και τα πλεονεκτήματα και τους περιορισμούς κάθε μεθόδου.

7.3 Εφαρμογή του Αλγορίθμου PRISM

Ακολουθεί η εφαρμογή του αλγορίθμου PRISM στο συνθετικό σύνολο δεδομένων που περιγράφηκε προηγουμένως, με στόχο την αξιολόγηση της ικανότητάς του να ανακατασκευάσει τον αρχικό μηχανισμό λήψης απόφασης μέσω ρητών κανόνων ταξινόμησης.

Ο αλγόριθμος PRISM δεν εφαρμόζεται απευθείας σε συνεχείς αριθμητικές μεταβλητές, αλλά απαιτεί κατηγορικά χαρακτηριστικά. Για τον λόγο αυτό, πριν την εκπαίδευση του μοντέλου πραγματοποιήθηκε διαδικασία διακριτοποίησης (discretization) των αριθμητικών μεταβλητών Age και Income.

Τα όρια των κατηγοριών καθορίστηκαν έτσι ώστε να επιτρέπουν έναν σαφή και ερμηνεύσιμο διαχωρισμό του χώρου χαρακτηριστικών, με γνώμονα τη λειτουργική απλοποίηση της δομής των δεδομένων και τη διευκόλυνση της εφαρμογής του αλγορίθμου PRISM.

Η μεταβλητή **Age** μετασχηματίστηκε στις ακόλουθες κατηγορίες:

- **underage** : Age < 18
- **middle** : $18 \leq \text{Age} \leq 65$
- **old** : Age > 65

Η μεταβλητή **Income** διακριτοποιήθηκε ως εξής:

- **low** : $\text{Income} \leq 33.000$
- **mid** : $33.001 \leq \text{Income} \leq 65.000$
- **high** : $65.001 \leq \text{Income} \leq 100.000$

Η διαδικασία διακριτοποίησης των αριθμητικών μεταβλητών υλοποιήθηκε με τη χρήση του Microsoft Excel, αξιοποιώντας συναρτήσεις λογικού ελέγχου της μορφής IF. Μέσω των συναρτήσεων αυτών κατέστη δυνατή η αυτόματη αντιστοίχιση κάθε αριθμητικής τιμής σε μία από τις προκαθορισμένες κατηγορίες, σύμφωνα με τα όρια που ορίστηκαν προηγουμένως.

Πιο συγκεκριμένα, για κάθε εγγραφή του συνόλου δεδομένων εφαρμόστηκε έλεγχος συνθηκών, έτσι ώστε η τιμή κάθε μεταβλητής να ενταχθεί στη σωστή κατηγορία. Η διαδικασία αυτή επέτρεψε τον συστηματικό μετασχηματισμό του αρχικού αριθμητικού συνόλου δεδομένων σε κατηγορικό, διατηρώντας παράλληλα την ερμηνευσιμότητα των χαρακτηριστικών και διευκολύνοντας την εφαρμογή του αλγορίθμου PRISM.

Οι συναρτήσεις που χρησιμοποιήθηκαν παρουσιάζονται παρακάτω:

Age: =IF(A2<18,"underage",IF(A2<=65,"middle","old"))

Income: =IF(B2<=33000,"low",IF(B2<=65000,"mid","high"))

Στον Πίνακα 7.2 παρουσιάζονται οι πρώτες δέκα εγγραφές του συνόλου δεδομένων μετά τη διαδικασία διακριτοποίησης (dataset_categorical).

Πίνακας 7. 2 Ενδεικτικές εγγραφές μετά τη διακριτοποίηση

Age	Income	Loan_Approval
MIDDLE	LOW	REJECT
OLD	MID	REJECT
UNDERAGE	HIGH	REJECT
OLD	MID	REJECT
MIDDLE	LOW	REJECT
MIDDLE	MID	APPROVE
OLD	MID	REJECT
OLD	MID	REJECT

OLD	MID	REJECT
OLD	MID	REJECT

Όπως προκύπτει από τον ανωτέρω πίνακα, οι αριθμητικές μεταβλητές έχουν αντικατασταθεί πλήρως από κατηγορικές τιμές, γεγονός που επιτρέπει την άμεση εφαρμογή του αλγορίθμου PRISM για την εξαγωγή κανόνων ταξινόμησης.

Οι κανόνες που ορίσαμε, μετά την διακριτοποίηση πρέπει να είναι οι εξής:

1. If age = Underage THEN reject
2. if age = Old THEN reject
3. if age = Middle and income = mid THEN approve
4. if age = Middle and income = high THEN approve

Εκπαίδευση του PRISM

Η εκπαίδευση πραγματοποιήθηκε επί του πλήρους συνόλου των 100 εγγραφών. Ο αλγόριθμος εφαρμόστηκε σύμφωνα με την κανονική εκδοχή του PRISM, η οποία βασίζεται στη στρατηγική separate-and-conquer.

Η διαδικασία για κάθε κλάση της μεταβλητής Loan_Approval περιλαμβάνει:

1. Επιλογή της συνθήκης (ATTRIBUTE = VALUE) που μεγιστοποιεί την πιθανότητα εμφάνισης της συγκεκριμένης κλάσης.
2. Προοδευτική προσθήκη επιπλέον συνθηκών, έως ότου ο κανόνας επιτύχει πλήρη καθαρότητα (precision = 1).
3. Αφαίρεση των καλυπτόμενων παρατηρήσεων από το dataset.
4. Επανάληψη της διαδικασίας έως ότου καλυφθούν όλες οι περιπτώσεις της κλάσης.

Η εκπαίδευση ολοκληρώνεται όταν όλες οι εγγραφές του συνόλου δεδομένων καλυφθούν από κάποιον παραγόμενο κανόνα. Το αποτέλεσμα είναι ένα πλήρες και

αμοιβαία αποκλειόμενο σύνολο κανόνων που καλύπτει εξαντλητικά τον χώρο χαρακτηριστικών.

Παραγόμενοι Κανόνες

Οι κανόνες που εξήχθησαν από τον αλγόριθμο συνοψίζονται παρακάτω:

```
=== CLASS Reject ===
```

```
Rule 1: IF Age = OLD THEN Reject
```

```
Rule 2: IF Age = UNDERAGE THEN Reject
```

```
Rule 3: IF Income = LOW THEN Reject
```

```
=== CLASS Approve ===
```

```
Rule 1: IF Age = MIDDLE AND Income = MID THEN Approve
```

```
Rule 2: IF Income = HIGH AND Age = MIDDLE THEN Approve
```

```
DEFAULT RULE: Reject
```

Μετατροπή των Κανόνων σε Πίνακα Απόφασης DMN

Μετά την ολοκλήρωση της εκπαίδευσης, οι παραγόμενοι κανόνες μετασχηματίστηκαν σε πίνακα απόφασης σύμφωνα με το πρότυπο DMN.

Η διαδικασία περιλαμβάνει:

- Αντιστοίχιση των μεταβλητών Age και Income ως input expressions.
- Ορισμό της μεταβλητής Loan_Approval ως output.
- Μετατροπή κάθε κανόνα PRISM σε γραμμή πίνακα απόφασης.
- Ορισμό πολιτικής εκτέλεσης (hit policy = FIRST), ώστε να εφαρμόζεται ο πρώτος κανόνας που ικανοποιείται.

PRISM Loan Approval

Hit policy: First

	When	And	Then	Annotations
	Age	Income	Loan_Approval	
	string	string	string	
1	"old"	-	Reject	
2	"underage"	-	Reject	
3	-	"low"	Reject	
4	"middle"	"mid"	Approve	
5	"middle"	"high"	Approve	
6	-	-	Reject	
+				

Εικόνα 7. 1 Πίνακας Αποφάσεων του αλγορίθμου PRISM

7.4 Αξιολόγηση των Παραγόμενων Κανόνων PRISM

Η ανάλυση των κανόνων που παρήγαγε ο PRISM καταδεικνύει ότι ο αλγόριθμος κατάφερε να αναπαραστήσει με σαφήνεια και συνέπεια τη λογική δομή του αρχικού μηχανισμού λήψης απόφασης. Το τελικό σύνολο κανόνων, όπως αποτυπώνεται και στον πίνακα απόφασης DMN, καλύπτει εξαντλητικά τον χώρο χαρακτηριστικών.

Παρατηρείται ότι:

- Οι περιπτώσεις *Age = underage* και *Age = Old* οδηγούν άμεσα σε απόρριψη (reject), ανεξαρτήτως εισοδήματος.
- Οι περιπτώσεις *Age = middle* και *Income = mid* ή *Income = high* οδηγούν σε έγκριση (APPROVE).
- Η κατηγορία *Income = low* οδηγεί σε απόρριψη (reject), όπως και οποιαδήποτε άλλη περίπτωση.

Ο κανόνας αυτός δεν υπήρχε ρητά στους αρχικούς κανόνες που τέθηκαν κατά τον σχεδιασμό του πειράματος, αλλά προέκυψε αυτόνομα από τη διαδικασία μάθησης. Η εμφάνισή του αναδεικνύει την ικανότητα του PRISM να εντοπίζει επαρκείς και γενικευμένες συνθήκες απόφασης, ακόμη και όταν αυτές δεν έχουν διατυπωθεί ρητά στον αρχικό συμβολικό ορισμό.

Η γενίκευση αυτή προκύπτει άμεσα από τα ίδια τα δεδομένα. Συγκεκριμένα, στο σύνολο δεδομένων όλες οι εγγραφές για τις οποίες το εισόδημα ανήκει στην

κατηγορία LOW οδηγούν σε απόφαση απόρριψης (REJECT). Δεν υπάρχει καμία περίπτωση έγκρισης σε αυτήν την κατηγορία εισοδήματος. Ως αποτέλεσμα, η συνθήκη $INCOME = LOW$ αποτελεί από μόνη της επαρκές και πλήρως διακριτικό κριτήριο ταξινόμησης.

Η συγκεκριμένη περίπτωση δείχνει ότι η συμβολική μάθηση δεν περιορίζεται στην απλή αναπαραγωγή των αρχικά διατυπωμένων κανόνων. Αντίθετα, μπορεί να εντοπίσει και να διατυπώσει με σαφή τρόπο λογικές σχέσεις που προκύπτουν από τα ίδια τα δεδομένα, ακόμη και αν δεν είχαν εκφραστεί ρητά στον αρχικό σχεδιασμό. Με αυτόν τον τρόπο ενισχύεται η διαφάνεια του μοντέλου και γίνεται πιο κατανοητή η εσωτερική δομή του μηχανισμού λήψης απόφασης.

Τέλος, προέκυψε και ένας default rule, ο οποίος ενεργοποιείται στην περίπτωση που καμία από τις προηγούμενες συνθήκες δεν ικανοποιείται και οδηγεί σε απόφαση απόρριψης (REJECT). Η ύπαρξη ενός τέτοιου προεπιλεγμένου κανόνα αποτελεί χαρακτηριστικό της μεθόδου PRISM, καθώς ο αλγόριθμος κατασκευάζει ένα σύνολο κανόνων που καλύπτουν τις πιο καθαρές και διακριτικές περιπτώσεις και στη συνέχεια χρησιμοποιεί έναν default rule για τις υπόλοιπες μη καλυπτόμενες εγγραφές. Στο συγκεκριμένο σύνολο δεδομένων, η επιλογή της απόφασης REJECT ως προεπιλεγμένης κατηγορίας αιτιολογείται από την κατανομή των εγγραφών, από τις 100 συνολικές αιτήσεις, οι 73 οδηγούν σε απόρριψη.

7.5 Εφαρμογή του Αλγορίθμου CART

Ακολουθεί η εφαρμογή του αλγορίθμου CART στο ίδιο συνθετικό σύνολο δεδομένων, με στόχο την αξιολόγηση της ικανότητάς του να αναπαραστήσει τον αρχικό μηχανισμό λήψης απόφασης μέσω ενός ιεραρχικού δέντρου ταξινόμησης.


Εκπαίδευση του CART

Για την εφαρμογή του αλγορίθμου CART χρησιμοποιήθηκε η υλοποίηση DecisionTreeClassifier της βιβλιοθήκης scikit-learn. Σε αντίθεση με τον PRISM, δεν πραγματοποιήθηκε διακριτοποίηση των μεταβλητών, καθώς ο CART μπορεί να επεξεργαστεί απευθείας συνεχείς αριθμητικές τιμές και να προσδιορίσει αυτόματα τα κατάλληλα σημεία διαχωρισμού (thresholds).

Το μοντέλο εκπαιδεύτηκε στο πλήρες συνθετικό σύνολο δεδομένων των 100 εγγραφών, με κριτήριο διαχωρισμού Gini και χωρίς περιορισμό στο μέγιστο βάθος του δέντρου ($max_depth=None$), επιτρέποντας την πλήρη ανάπτυξή του έως ότου επιτευχθεί καθαρός διαχωρισμός των κλάσεων.

Περιγραφή της Δομής του Παραγόμενου Δέντρου

Το δέντρο απόφασης που προέκυψε από την εκπαίδευση του μοντέλου αποτυπώνει γραφικά τη διαδικασία διαδοχικών διαχωρισμών που εφαρμόζει ο αλγόριθμος CART. Στο ακόλουθο σχήμα παρουσιάζεται η τελική μορφή του δέντρου, όπως παράχθηκε από το μοντέλο.



Εικόνα 7. 2 Παραγόμενο Δέντρο Απόφασης

Η δομή του δέντρου είναι ιεραρχική και ξεκινά από έναν αρχικό κόμβο (root node), στον οποίο πραγματοποιείται ο πρώτος διαχωρισμός με βάση τη μεταβλητή Age και το αριθμητικό όριο:

- $Age \leq 62.5$

Ο αρχικός αυτός κόμβος διαχωρίζει το σύνολο των δεδομένων σε δύο κλάδους:

1. παρατηρήσεις με $Age \leq 62.5$
2. παρατηρήσεις με $Age > 62.5$

Στον κλάδο όπου $Age \leq 62.5$, ακολουθεί δεύτερος διαχωρισμός με βάση τη μεταβλητή Income και το όριο:

- $Income \leq 31847$

Ο κόμβος αυτός δημιουργεί δύο νέες υποομάδες δεδομένων. Στην περίπτωση όπου ισχύει $Income > 31847$, το δέντρο προχωρά σε τρίτο διαχωρισμό με βάση τη μεταβλητή:

- $Age \leq 18.5$

Ο διαχωρισμός αυτός οδηγεί σε δύο τελικούς κόμβους (leaf nodes), οι οποίοι δεν διασπώνται περαιτέρω.

Αντίθετα, στον κλάδο όπου $Age > 62.5$ δεν πραγματοποιείται επιπλέον διαχωρισμός και το δέντρο καταλήγει απευθείας σε τελικό κόμβο.

Συνολικά, το δέντρο καταλήγει σε 4 φύλλα (leaves), καθένας από τους οποίους αντιστοιχεί σε μία συγκεκριμένη τιμή της μεταβλητής Loan_Approval (Approve ή Reject).

Η απεικόνιση αυτή καταδεικνύει τη διαδοχική εξειδίκευση του χώρου των δεδομένων μέσω αριθμητικών ορίων, όπου κάθε επίπεδο του δέντρου προσθέτει ένα επιπλέον κριτήριο διαχωρισμού.

Μετατροπή του Δέντρου σε Πίνακα Απόφασης DMN

Μετά την ολοκλήρωση της εκπαίδευσης του μοντέλου CART, πραγματοποιήθηκε αυτοματοποιημένη μετατροπή του παραγόμενου δέντρου απόφασης σε πίνακα απόφασης DMN.

Η διαδικασία μετατροπής βασίστηκε στην εκμετάλλευση της εσωτερικής αναπαράστασης του δέντρου και περιλαμβάνει τα ακόλουθα στάδια:

1. Εντοπισμός των τελικών κόμβων (leaf nodes)

Ανακτήθηκαν όλοι οι κόμβοι του δέντρου για τους οποίους δεν υπάρχουν περαιτέρω διαχωρισμοί. Κάθε τέτοιος κόμβος αντιστοιχεί σε μία τελική απόφαση.

2. Ανάκτηση του μονοπατιού από τη ρίζα έως κάθε φύλλο

Για κάθε leaf node προσδιορίστηκε το αντίστοιχο μονοπάτι συνθηκών που ακολουθείται από τη ρίζα του δέντρου έως τον συγκεκριμένο κόμβο. Το μονοπάτι αυτό αποτελεί ακολουθία διαδοχικών ελέγχων της μορφής:

- χαρακτηριστικό $\leq$ threshold

- χαρακτηριστικό > threshold

3. Μετατροπή μονοπατιού σε κανόνα απόφασης

Κάθε πλήρες μονοπάτι μετασχηματίστηκε σε έναν κανόνα της μορφής: IF (σύνολο συνθηκών) THEN (Loan_Approval)
Οι αριθμητικές συνθήκες διατηρήθηκαν ακριβώς όπως προέκυψαν από το δέντρο, ώστε να εξασφαλίζεται απόλυτη ισοδυναμία με το εκπαιδευμένο μοντέλο.

4. Δημιουργία πίνακα απόφασης DMN

Για κάθε κανόνα δημιουργήθηκε μία γραμμή (rule) σε πίνακα απόφασης XML, με στήλες εισόδου τις μεταβλητές:

- Age
- Income

και στήλη εξόδου τη μεταβλητή:

- Loan_Approval

Η πολιτική εκτέλεσης (hit policy) ορίστηκε ως: hitPolicy = UNIQUE, καθώς κάθε συνδυασμός συνθηκών οδηγεί σε μία και μοναδική τελική απόφαση, χωρίς αλληλοεπικαλύψεις κανόνων.

Loan Approval				
Hit policy: Unique				
	When	And	Then	Annotations
	Age	Income	Loan_Approval	
	double	double	string	
1	<= 62.50	<= 31847.00	Reject	
2	<= 18.50	> 31847.00	Reject	
3	> 18.50	> 31847.00	Approve	
4	> 62.50	-	Reject	
+	-	-		

Εικόνα 7. 3 Πίνακας Αποφάσεων του αλγορίθμου CART

7.6 Αξιολόγηση των Παραγόμενων Κανόνων CART

Από τη διαδικασία μετατροπής προέκυψαν οι ακόλουθοι τέσσερις κανόνες:

IF Age $\leq$ 62.5 AND Income $\leq$ 31847 $\rightarrow$ Reject

IF Age $\leq$ 18.5 AND Income $>$ 31847 $\rightarrow$ Reject

IF Age $>$ 18.5 AND Income $>$ 31847 $\rightarrow$ Approve

IF Age $>$ 62.5 $\rightarrow$ Reject

Τα αρχικά επιχειρησιακά όρια που χρησιμοποιήθηκαν για τη δημιουργία του dataset ήταν:

- Age $\leq$ 18
- Age $\geq$ 65
- Income $>$ 30.000

Ωστόσο, ο CART παρήγαγε τα εξής thresholds:

- Age $\leq$ 18.5
- Age $\leq$ 62.5
- Income $\leq$ 31847

Η διαφοροποίηση αυτή οφείλεται στον τρόπο υπολογισμού των thresholds στον CART. Ο CART δεν γνωρίζει τους αρχικούς κανόνες. Εξετάζει όλες τις πιθανές τιμές διαχωρισμού μεταξύ διαδοχικών ταξινομημένων τιμών ενός χαρακτηριστικού και επιλέγει το σημείο που ελαχιστοποιεί τη Gini impurity. Συγκεκριμένα, το threshold υπολογίζεται ως ο μέσος όρος δύο διαδοχικών τιμών του dataset.

Πιο συγκεκριμένα:

(A) Το 18.5 αντί 18

Στο dataset παρατηρούνται ηλικίες όπως 17 και 20, ενώ δεν υπάρχει η ενδιαμέση τιμή 18, για την οποία αλλάζει η κλάση από Reject σε Approve.

Ο CART, αφού ταξινομήσει τις μοναδικές τιμές της μεταβλητής Age, εξετάζει ως πιθανά σημεία διαχωρισμού τον μέσο όρο δύο διαδοχικών τιμών. Στην προκειμένη

περίπτωση, εφόσον οι γειτονικές τιμές γύρω από το όριο είναι 17 (Reject) και 20 (Approve), το υποψήφιο threshold υπολογίζεται ως:

$$(17+20)/2=18.5$$

Επομένως, το 18.5 αποτελεί σημείο διαχωρισμού που προκύπτει από τα διαθέσιμα δεδομένα. Δεδομένου ότι η ηλικία λαμβάνει ακέραιες τιμές, η συνθήκη $\text{Age} \leq 18.5$ είναι πρακτικά ισοδύναμη με $\text{Age} \leq 18$.

Άρα το παραγόμενο threshold δεν μεταβάλλει τον κανόνα απόφασης.

(B) Το 62.5 αντί 65

Στο dataset παρατηρείται ότι όλες οι εγγραφές με ηλικία 63 ετών και άνω οδηγούν σε απόφαση Reject. Δεν υπάρχει καμία περίπτωση έγκρισης για ηλικία ≥ 63 .

Αντίθετα, στο dataset υπάρχουν εγκρίσεις για ηλικίες έως και 62 ετών (π.χ. 61 και 62). Επομένως, το πραγματικό σημείο μετάβασης από Approve σε Reject, με βάση τα δεδομένα, εντοπίζεται μεταξύ των τιμών 62 (Approve) και 63 (Reject).

Ο CART, αφού ταξινομήσει τις τιμές της μεταβλητής Age, υπολογίζει ως πιθανό threshold τον μέσο όρο αυτών των δύο διαδοχικών τιμών:

$$(62+63)/2=62.5$$

Συνεπώς, το όριο 62.5 προκύπτει μαθηματικά από τη συγκεκριμένη κατανομή των δεδομένων και δεν μεταβάλλει τον κανόνα απόφασης.

(Γ) Το 31847 αντί 30000

Στο dataset παρατηρούνται τιμές εισοδήματος όπως 30535 (Reject) και 33159 (Approve), οι οποίες βρίσκονται γύρω από το σημείο μετάβασης από απόρριψη σε έγκριση. Παράλληλα, χαμηλότερες τιμές, όπως 3561 και 26854, οδηγούν σε Reject, ενώ υψηλότερες, όπως 38044, οδηγούν σε Approve.

Το αρχικό επιχειρησιακό όριο ήταν 30000, όμως η συγκεκριμένη τιμή δεν εμφανίζεται στο dataset. Στην προκειμένη περίπτωση, το σημείο αλλαγής κλάσης εντοπίζεται μεταξύ των τιμών 30535 (Reject) και 33159 (Approve). Ο μέσος όρος τους είναι:

$$(30535+33159)/2=31847$$

Επομένως, το 31847 αποτελεί σημείο διαχωρισμού που προκύπτει από τα διαθέσιμα δεδομένα.

Συνεπώς, το μοντέλο δεν επιλέγει το θεωρητικό όριο που είχε τεθεί κατά τον αρχικό σχεδιασμό, αλλά το σημείο διαχωρισμού που προκύπτει από τα ίδια τα δεδομένα και οδηγεί στον καθαρότερο δυνατό διαχωρισμό των κλάσεων. Η τιμή του threshold καθορίζεται από τη μαθηματική διαδικασία υπολογισμού που εφαρμόζει ο CART, δηλαδή από τον μέσο όρο διαδοχικών ταξινομημένων τιμών που ανήκουν σε διαφορετικές κλάσεις και ελαχιστοποιούν τη Gini impurity. Κατά συνέπεια, η

παρατηρούμενη μετατόπιση του ορίου δεν συνιστά σφάλμα ή απόκλιση από τη λογική του αρχικού κανόνα, αλλά αποτελεί φυσική και αναμενόμενη συνέπεια τόσο της μεθοδολογίας του αλγορίθμου όσο και της συγκεκριμένης κατανομής του dataset.

Αναλυτική αξιολόγηση κάθε κανόνα

Κανόνας 1: IF Age $\leq$ 62.5 AND Income $\leq$ 31847 $\rightarrow$ Reject

Στους αρχικούς κανόνες, η απόρριψη διατυπωνόταν ρητά μόνο για ηλικίες εκτός του διαστήματος [18, 65]. Η έγκριση προβλεπόταν αποκλειστικά όταν η ηλικία βρισκόταν εντός του διαστήματος [18, 65] και το εισόδημα ήταν $\geq$ 33.001. Κατά συνέπεια, για τις ενδιάμεσες ηλικίες, το εισόδημα αποτελούσε τον καθοριστικό παράγοντα, εάν δεν υπερέβαινε το όριο, η αίτηση δεν μπορούσε να εγκριθεί.

Στον κανόνα του CART, η συνθήκη Age $\leq$ 62.5 δεν είναι εκείνη που καθορίζει ουσιαστικά την απόρριψη. Ο πραγματικός διαχωριστικός παράγοντας είναι το Income $\leq$ 31847, καθώς η έγκριση στο σύστημα ενεργοποιείται μόνο όταν το εισόδημα υπερβαίνει το αντίστοιχο κατώφλι. Η ηλικιακή συνθήκη λειτουργεί περισσότερο ως δομικός περιορισμός του συγκεκριμένου κλάδου του δέντρου και όχι ως κύριο κριτήριο λήψης απόφασης.

Με άλλα λόγια, για τις ηλικίες που δεν απορρίπτονται ήδη από τους καθαρά ηλικιακούς κανόνες, το εισόδημα είναι αυτό που προσδιορίζει το αποτέλεσμα. Εφόσον δεν πληρούται η προϋπόθεση υψηλού εισοδήματος, η αίτηση απορρίπτεται. Επομένως, ο κανόνας αποτυπώνει ρητά κάτι που στους αρχικούς κανόνες ήταν έμμεσο, ότι εντός του επιτρεπτού ηλικιακού πλαισίου, το χαμηλό εισόδημα συνεπάγεται απόρριψη.

Κανόνας 2: IF Age $\leq$ 18.5 AND Income $>$ 31847 $\rightarrow$ Reject

Ο αρχικός κανόνας όριζε ρητά ότι κάθε αιτών με ηλικία μικρότερη ή ίση των 18 ετών απορρίπτεται ανεξαρτήτως του επιπέδου εισοδήματός του. Στον παραγόμενο κανόνα του CART, η απόφαση απόρριψης για τις ηλικίες κάτω των 18 εμφανίζεται σε συνδυασμό με μία επιπλέον συνθήκη σχετική με το εισόδημα (Income $>$ 31847). Η παρουσία αυτής της δεύτερης μεταβλητής δεν αντανακλά μεταβολή της επιχειρησιακής λογικής, αλλά προκύπτει από τη δομική φύση του δέντρου απόφασης.

Συγκεκριμένα, το δέντρο κατασκευάζεται μέσω ιεραρχικών διαχωρισμών. Κάθε τελικός κανόνας αντιστοιχεί σε ένα πλήρες μονοπάτι από τη ρίζα έως ένα φύλλο. Εάν σε προηγούμενο επίπεδο έχει προηγηθεί διαχωρισμός με βάση το εισόδημα, τότε η συνθήκη αυτή «κληρονομείται» στο τελικό μονοπάτι, ακόμη και αν δεν είναι ουσιαστικά αναγκαία για τη λήψη της συγκεκριμένης απόφασης. Κατά συνέπεια, η συνθήκη του εισοδήματος στον συγκεκριμένο κανόνα δεν λειτουργεί ως ουσιαστικός παράγοντας διαφοροποίησης, αλλά ως τυπικό στοιχείο της δενδρικής αναπαράστασης.

Η συνολική συμπεριφορά του μοντέλου επιβεβαιώνει ότι καμία παρατήρηση με ηλικία μικρότερη ή ίση των 18 ετών δεν εγκρίνεται, ανεξαρτήτως εισοδήματος. Επομένως, σε λειτουργικό επίπεδο, ο CART διατηρεί πλήρως τον αρχικό απόλυτο ηλικιακό περιορισμό. Η διαφορά εντοπίζεται μόνο στη μορφολογική διατύπωση του κανόνα και όχι στην ουσία της απόφασης.

Κανόνας 3: IF Age > 18.5 AND Income > 31847 → Approve

Στον αρχικό σχεδιασμό, η απόφαση έγκρισης προϋπέθετε την ταυτόχρονη ικανοποίηση τριών παραμέτρων: ηλικία εντός του διαστήματος 18–65 ετών και εισόδημα άνω των 30.000.

Στον κανόνα που παρήχθη από το δέντρο απόφασης, η έγκριση διατυπώνεται ως Age > 18.5 και Income > 31847, χωρίς αναφορά στο ανώτατο ηλικιακό όριο, δηλαδή για τις περιπτώσεις όπου ισχύει Age > 65. Ο περιορισμός αυτός όμως αποτυπώνεται σε διαφορετικό κανόνα απόρριψης (Age > 62.5 → Reject), με αποτέλεσμα το τελικό αποδεκτό ηλικιακό εύρος να προκύπτει συνδυαστικά από τη συνολική δομή των κανόνων.

Συνεπώς, ο κανόνας παραμένει συμβατός με την αρχική προδιαγραφή, καθώς η έγκριση εξακολουθεί να αφορά αποκλειστικά άτομα που βρίσκονται εντός του επιτρεπτού ηλικιακού πλαισίου και διαθέτουν επαρκές εισόδημα. Παρότι το ηλικιακό όριο δεν εμφανίζεται συγκεντρωμένο στον ίδιο κανόνα, διασφαλίζεται μέσω του συνδυασμού του με τους υπόλοιπους κανόνες του συστήματος.

Κανόνας 4: IF Age > 62.5 → Reject

Στον κανόνα που παρήχθη από το δέντρο απόφασης, η απόρριψη ενεργοποιείται για ηλικίες άνω των 62.5 ετών. Παρότι το αριθμητικό όριο δεν ταυτίζεται ακριβώς με το αρχικό (65), ο ρόλος του κανόνα είναι ο ίδιος, θέτει ανώτατο ηλικιακό περιορισμό και αποκλείει τις μεγαλύτερες ηλικίες από τη διαδικασία έγκρισης. Επιπλέον, ο κανόνας εφαρμόζεται ανεξάρτητα από το εισόδημα, όπως ακριβώς και στον αρχικό μηχανισμό.

Επομένως, ο συγκεκριμένος κανόνας αποδίδει σωστά τη βασική λογική του αρχικού συστήματος, δηλαδή ότι πέρα από ένα συγκεκριμένο ηλικιακό όριο η απόφαση είναι πάντα απόρριψη.

Συνοψίζοντας, η σύγκριση των αρχικών κανόνων με τους κανόνες που παρήχθησαν από το δέντρο απόφασης δείχνει ότι η βασική λογική του συστήματος διατηρείται. Στο παραγόμενο σύνολο κανόνων, οι Κανόνες 2 και 4 αναπαριστούν ουσιαστικά τους ηλικιακούς περιορισμούς (απόρριψη για μικρές και μεγάλες ηλικίες), ενώ ο Κανόνας 3 αποτυπώνει τον μηχανισμό έγκρισης για τις ενδιάμεσες ηλικίες με υψηλό εισόδημα. Επομένως, οι βασικές προϋποθέσεις επιλεξιμότητας και έγκρισης καλύπτονται πλήρως.

Ο Κανόνας 1 εμφανίζεται επιπλέον ως ρητή διατύπωση της απόρριψης λόγω χαμηλού εισοδήματος για τις επιτρεπτές ηλικίες. Στον αρχικό σχεδιασμό, η συνθήκη αυτή ήταν έμμεση, καθώς η έγκριση οριζόταν μόνο για υψηλό εισόδημα. Συνεπώς, η μη

ικανοποίηση της προϋπόθεσης οδηγούσε λογικά σε απόρριψη. Το δέντρο απόφασης, επιδιώκοντας πλήρη και ρητή ταξινόμηση όλων των δυνατών περιπτώσεων, εκφράζει αυτή τη συνθήκη ως αυτοτελή κανόνα. Υπό αυτή την έννοια, ο Κανόνας 1 δεν εισάγει νέα λογική, αλλά καθιστά σαφή μια συνέπεια που ήδη προέκυπτε από τους αρχικούς κανόνες.

Συνολικά, παρατηρείται ότι το παραγόμενο σύνολο κανόνων είναι λειτουργικά ισοδύναμο με το αρχικό. Οι διαφοροποιήσεις εντοπίζονται κυρίως στον τρόπο αναπαράστασης και στη ρητή διατύπωση ορισμένων συνθηκών, χωρίς να μεταβάλλεται η ουσία του μηχανισμού λήψης απόφασης.

7.7 Συγκριτική Αποτίμηση PRISM και CART

Η σύγκριση μεταξύ του αλγορίθμου PRISM και του αλγορίθμου CART αναδεικνύει ουσιαστικές διαφοροποιήσεις ως προς τον τρόπο με τον οποίο αναπαρίσταται και αξιοποιείται η γνώση που προκύπτει από τα δεδομένα. Παρότι και οι δύο προσεγγίσεις οδηγούν σε ορθές ταξινομικές αποφάσεις στο συγκεκριμένο πειραματικό σύνολο δεδομένων, διαφοροποιούνται σημαντικά ως προς τη δομή των κανόνων που παράγουν, τον βαθμό ερμηνευσιμότητας και τη δυνατότητα πρακτικής αξιοποίησής τους σε πραγματικά περιβάλλοντα λήψης αποφάσεων.

Δομή και Χαρακτηριστικά των Κανόνων του CART

Οι κανόνες του CART αποτυπώνουν με ακρίβεια τις αριθμητικές σχέσεις μεταξύ εισοδήματος και ηλικίας, μέσω συγκεκριμένων κατωφλίων. Η μέθοδος εντοπίζει βέλτιστα σημεία διαχωρισμού στα δεδομένα και δημιουργεί κανόνες που βασίζονται σε ακριβείς αριθμητικές ανισότητες.

Η δομή των κανόνων είναι αυστηρά ιεραρχική, καθώς κάθε τελική απόφαση εξαρτάται από την ακολουθία των προηγούμενων διαχωρισμών του δέντρου. Με άλλα λόγια, κάθε κανόνας προκύπτει ως μονοπάτι από τη ρίζα προς ένα φύλλο και δεν υφίσταται ανεξάρτητα από το υπόλοιπο δέντρο.

Παρότι αυτή η προσέγγιση επιτρέπει λεπτομερή διάκριση των περιπτώσεων και υψηλή αριθμητική ακρίβεια, καθιστά τους κανόνες λιγότερο άμεσα κατανοητούς. Ιδίως όταν απαιτείται η ταυτόχρονη εξέταση πολλαπλών αριθμητικών συνθηκών, η ερμηνεία της απόφασης προϋποθέτει ανάλυση ολόκληρης της διαδρομής στο δέντρο.

Δομή και Χαρακτηριστικά των Κανόνων του PRISM

Αντίθετα, οι κανόνες που παρήγαγε ο PRISM είναι απλοί, κατανοητοί και ανεξάρτητοι μεταξύ τους, γεγονός που διευκολύνει την κατανόηση και τη διαχείρισή τους. Η χρήση κατηγορικών μεταβλητών, οδηγεί σε κανόνες που μπορούν να διαβαστούν και να κατανοηθούν άμεσα από ανθρώπους, χωρίς να απαιτείται ανάλυση σύνθετης δομής.

Κάθε κανόνας εκφράζει μια σαφή πολιτική απόφασης, όπως η καθολική απόρριψη αιτήσεων χαμηλού εισοδήματος ή η έγκριση αιτήσεων υψηλού εισοδήματος. Η διατύπωση είναι άμεση και κανονιστική, γεγονός που ενισχύει τη διαφάνεια της διαδικασίας λήψης απόφασης.

Ιδιαίτερο πλεονέκτημα του PRISM αποτελεί το γεγονός ότι οι κανόνες του είναι ανεξάρτητοι μεταξύ τους και δεν ενσωματώνονται σε μια σύνθετη ιεραρχική δομή, όπως συμβαίνει στα δέντρα αποφάσεων. Αυτό επιτρέπει την εύκολη αξιολόγηση, τροποποίηση ή τεκμηρίωση κάθε κανόνα ξεχωριστά, στοιχείο ιδιαίτερα κρίσιμο σε εφαρμογές όπου απαιτείται σαφής αιτιολόγηση των αποφάσεων.

Παρότι η κατηγοριοποίηση των συνεχών μεταβλητών συνεπάγεται απώλεια λεπτομερούς αριθμητικής πληροφορίας, το όφελος σε απλότητα και κατανοησιμότητα είναι σημαντικό.

Συνολική αποτίμηση των δύο προσεγγίσεων

Συνολικά, και οι δύο αλγόριθμοι κατάφεραν να αναπαραγάγουν με επιτυχία τον αρχικό μηχανισμό λήψης αποφάσεων του συνθετικού συνόλου δεδομένων και να οδηγήσουν σε ισοδύναμες ταξινομικές αποφάσεις. Επιπλέον, οι κανόνες που παρήγαγαν μετατράπηκαν επιτυχώς σε πίνακες αποφάσεων DMN, αποδεικνύοντας ότι η γνώση που εξάγεται από δεδομένα μπορεί να ενσωματωθεί σε τυποποιημένα συστήματα λήψης αποφάσεων. Ωστόσο, η γνώση που εξήχθη αναπαραστάθηκε με διαφορετικό τρόπο. Ο CART παρείχε μια πιο λεπτομερή και αριθμητικά ακριβή περιγραφή των σχέσεων των δεδομένων μέσω μιας ιεραρχικής δομής αποφάσεων, η οποία αποτυπώνει αποτελεσματικά τις εξαρτήσεις μεταξύ των χαρακτηριστικών. Αντίθετα, ο PRISM παρήγαγε απλούς, κατανοητούς και ανεξάρτητους κανόνες IF–THEN, οι οποίοι μπορούν να ερμηνευθούν και να κατανοηθούν ευκολότερα ως επιχειρησιακοί κανόνες. Τα αποτελέσματα αυτά δείχνουν ότι διαφορετικές τεχνικές μηχανικής μάθησης μπορούν να οδηγήσουν στην ίδια απόφαση, αλλά με διαφορετικό τρόπο αναπαράστασης της γνώσης. Επομένως, η επιλογή μεταξύ των δύο προσεγγίσεων δεν εξαρτάται μόνο από την ορθότητα των αποτελεσμάτων, αλλά και από τις απαιτήσεις της εφαρμογής ως προς την ακρίβεια, την ερμηνευσιμότητα, τη συντήρηση των κανόνων και την ενσωμάτωσή τους σε συστήματα λήψης αποφάσεων.

Ο κώδικας που υλοποιεί τις διαδικασίες εξαγωγής κανόνων των αλγορίθμων και τη δημιουργία των DMN πινάκων για το συγκεκριμένο πείραμα είναι διαθέσιμος στον ακόλουθο σύνδεσμο:

https://github.com/DanaeKouimtzipidou/loan_approval_rules

7.8 Σύνοψη

Στο παρόν κεφάλαιο παρουσιάστηκε η πειραματική εφαρμογή και αξιολόγηση δύο διαφορετικών προσεγγίσεων εξαγωγής κανόνων από δεδομένα, με στόχο τη διερεύνηση της ικανότητάς τους να αναπαράγουν έναν προκαθορισμένο μηχανισμό λήψης αποφάσεων. Για τον σκοπό αυτό σχεδιάστηκε ένα ελεγχόμενο πειραματικό πλαίσιο που προσομοιώνει μια διαδικασία έγκρισης ή απόρριψης αιτήσεων δανείου, στο οποίο η απόφαση καθορίζεται από συγκεκριμένους επιχειρησιακούς κανόνες που βασίζονται στην ηλικία και το εισόδημα του αιτούντος. Με βάση αυτούς τους κανόνες δημιουργήθηκε ένα συνθετικό σύνολο δεδομένων, το οποίο χρησιμοποιήθηκε για την εκπαίδευση, την εξαγωγή κανόνων και την αξιολόγηση των αλγορίθμων.

Στη συνέχεια εφαρμόστηκε ο αλγόριθμος PRISM, μετά από κατάλληλη διακριτοποίηση των συνεχών μεταβλητών, και εξήχθησαν κανόνες ταξινόμησης που μετατράπηκαν σε πίνακα αποφάσεων DMN. Παράλληλα εφαρμόστηκε ο αλγόριθμος CART, από τον οποίο προέκυψαν κανόνες με τη μορφή ιεραρχικών διαχωρισμών, οι οποίοι επίσης μετατράπηκαν σε μορφή DMN.

Η συγκριτική ανάλυση έδειξε ότι, παρότι και οι δύο μέθοδοι μπορούν να παράγουν ορθές ταξινομικές αποφάσεις στο συγκεκριμένο σύνολο δεδομένων, διαφοροποιούνται κυρίως ως προς τη δομή και την ερμηνευσιμότητα των κανόνων που παράγουν. Ο PRISM παράγει απλούς και ανεξάρτητους κανόνες που είναι εύκολα κατανοητοί και κατάλληλοι για περιβάλλοντα όπου απαιτείται διαφάνεια στη λήψη αποφάσεων, ενώ τα δέντρα αποφάσεων αξιοποιούν πλήρως τη διαθέσιμη αριθμητική πληροφορία των δεδομένων και μπορούν να αποτυπώσουν πιο λεπτομερείς διαχωρισμούς.

Κεφάλαιο 8: Πειραματική Αξιολόγηση PRISM και CART σε Πραγματικό Σύνολο Δεδομένων

Το κεφάλαιο αυτό παρουσιάζει την πειραματική αξιολόγηση των αλγορίθμων εξαγωγής κανόνων PRISM και CART σε πραγματικό σύνολο δεδομένων που αφορά την πρόβλεψη αθέτησης δανείων. Αρχικά παρουσιάζεται η προετοιμασία των δεδομένων και η διαδικασία διακριτοποίησης των αριθμητικών μεταβλητών, ώστε να καταστούν κατάλληλες για την εφαρμογή του αλγορίθμου PRISM. Στη συνέχεια εφαρμόζονται οι αλγόριθμοι, με στόχο την παραγωγή συνόλων κανόνων που ταξινομούν τους πελάτες σε κατηγορίες χαμηλού ή υψηλού πιστωτικού κινδύνου. Επιπλέον, οι κανόνες που προκύπτουν μετατρέπονται σε πίνακες απόφασης DMN, επιτρέποντας την αναπαράσταση της λογικής των μοντέλων σε μορφή κατάλληλη για επιχειρησιακά συστήματα λήψης αποφάσεων. Τέλος, πραγματοποιείται συγκριτική ανάλυση των κανόνων που παράγονται από τους δύο αλγορίθμους, προκειμένου να διερευνηθεί ο βαθμός συμφωνίας τους και να αξιολογηθεί η ερμηνευσιμότητα των αποτελεσμάτων που προκύπτουν.

8.1 Σχεδιασμός Πειραματικού Πλαισίου

Το πειραματικό πλαίσιο αφορά την αξιολόγηση αιτήσεων δανείων και συγκεκριμένα την πρόβλεψη της πιθανότητας αθέτησης αποπληρωμής ενός δανείου από έναν πελάτη. Η συγκεκριμένη κατηγορία προβλημάτων αποτελεί ένα από τα πιο κλασικά πεδία εφαρμογής της μηχανικής μάθησης στον χρηματοοικονομικό τομέα και συνδέεται άμεσα με τη διαδικασία εκτίμησης πιστωτικού κινδύνου.

Για τον σκοπό αυτό χρησιμοποιήθηκε ένα σύνολο δεδομένων πιστωτικού κινδύνου, το οποίο αποτελείται από 2000 εγγραφές και περιλαμβάνει πληροφορίες σχετικά με οικονομικά και δημογραφικά χαρακτηριστικά πελατών που έχουν λάβει δάνειο.

Το συγκεκριμένο σύνολο δεδομένων προέρχεται από την πλατφόρμα Kaggle και είναι διαθέσιμο δημόσια για ερευνητικούς σκοπούς. Πιο συγκεκριμένα, χρησιμοποιήθηκε το dataset που διατίθεται στον ακόλουθο σύνδεσμο: <https://www.kaggle.com/code/gabrieldadcarvalho/credit-classification-ml-in-r-language/input>

Το dataset περιλαμβάνει τις ακόλουθες μεταβλητές:

clientid: Μοναδικό αναγνωριστικό κάθε εγγραφής στο dataset. Η μεταβλητή αυτή χρησιμοποιείται αποκλειστικά για την ταυτοποίηση των παρατηρήσεων και δεν συμμετέχει στη διαδικασία εκπαίδευσης των μοντέλων.

age: Η ηλικία του πελάτη. Πρόκειται για αριθμητική μεταβλητή η οποία εκφράζει τα έτη ηλικίας του αιτούντος.

income: Το ετήσιο εισόδημα του πελάτη. Η μεταβλητή αυτή αποτελεί συνεχές αριθμητικό χαρακτηριστικό που αποτυπώνει το οικονομικό επίπεδο του αιτούντος.

loan: Το ποσό του δανείου που έχει ζητηθεί από τον πελάτη. Η μεταβλητή αυτή εκφράζει το ύψος της οικονομικής υποχρέωσης που αναλαμβάνει ο αιτών.

default: Η μεταβλητή στόχος του προβλήματος ταξινόμησης. Πρόκειται για δυαδική μεταβλητή που υποδηλώνει αν ο πελάτης αθέτησε ή όχι την αποπληρωμή του δανείου.

Οι τιμές της μεταβλητής ερμηνεύονται ως εξής:

0 → good (ο πελάτης εξυπηρετεί κανονικά το δάνειο)
1 → bad (ο πελάτης αθετεί το δάνειο)

Η πρόβλεψη της μεταβλητής default αποτελεί το βασικό πρόβλημα ταξινόμησης που εξετάζεται στο παρόν πείραμα.

Προεπεξεργασία και Καθαρισμός Δεδομένων

Τα πραγματικά δεδομένα συχνά περιέχουν ελλιπείς τιμές, λανθασμένες καταχωρήσεις ή ασυνέπειες που μπορεί να επηρεάσουν την εκπαίδευση των μοντέλων μηχανικής μάθησης. Για τον λόγο αυτό πραγματοποιήθηκε διαδικασία καθαρισμού και προεπεξεργασίας των δεδομένων πριν από την εφαρμογή των αλγορίθμων.

Αρχικά το dataset φορτώθηκε στο περιβάλλον Python μέσω της βιβλιοθήκης Pandas, η οποία επιτρέπει την αποτελεσματική διαχείριση πινάκων δεδομένων. Στη συνέχεια πραγματοποιήθηκε μετατροπή των μεταβλητών income, age και loan σε αριθμητική μορφή, ώστε να διασφαλιστεί ότι όλες οι τιμές μπορούν να επεξεργαστούν σωστά από τους αλγορίθμους.

Έπειτα πραγματοποιήθηκε έλεγχος για την ύπαρξη ελλιπών τιμών (missing values) στο σύνολο δεδομένων. Οι ελλιπείς τιμές στις αριθμητικές μεταβλητές αντικαταστάθηκαν με τον μέσο όρο (mean) της αντίστοιχης μεταβλητής, ώστε να διατηρηθεί η στατιστική κατανομή των δεδομένων χωρίς να αφαιρεθούν εγγραφές από το dataset.

Κατά την περαιτέρω ανάλυση εντοπίστηκαν επίσης περιπτώσεις αρνητικών τιμών στη μεταβλητή ηλικίας. Τέτοιες τιμές δεν είναι λογικά αποδεκτές και πιθανότατα προκύπτουν από σφάλματα καταγραφής. Για την αντιμετώπιση του προβλήματος πραγματοποιήθηκε διόρθωση των τιμών αυτών μέσω αντικατάστασης με τη διάμεσο (median) των έγκυρων θετικών τιμών ηλικίας του dataset. Η επιλογή της διαμέσου μειώνει την επίδραση πιθανών ακραίων τιμών.

Τέλος, για λόγους συνέπειας και ομοιομορφίας των δεδομένων πραγματοποιήθηκε στρογγυλοποίηση των αριθμητικών μεταβλητών age, income και loan σε δύο δεκαδικά ψηφία. Η διαδικασία αυτή δεν μεταβάλλει ουσιαστικά την πληροφορία των δεδομένων, αλλά διευκολύνει την επεξεργασία και την παρουσίαση των αποτελεσμάτων.

Μετά την ολοκλήρωση της διαδικασίας καθαρισμού δημιουργήθηκε ένα νέο, καθαρό σύνολο δεδομένων, το οποίο αποθηκεύτηκε σε αρχείο και χρησιμοποιήθηκε ως βάση για την εφαρμογή των αλγορίθμων εξαγωγής κανόνων.

Ο Κώδικας 8.1 παρουσιάζει τα βήματα της διαδικασίας αυτής.

Κώδικας 8.1: Φόρτωση και αρχικός καθαρισμός του dataset

```
import pandas as pd
import numpy as np
from google.colab import drive
drive.mount('/content/drive')

df = pd.read_csv("/content/drive/MyDrive/original.csv", sep=",")

for col in ["income", "age", "loan"]:
    df[col] = pd.to_numeric(df[col], errors="coerce")

print("Missing values:")
print(df.isnull().sum())

df.fillna(df.mean(numeric_only=True), inplace=True)

print("Negative ages:")
print(df[df["age"] < 0])

median_age = df[df["age"] > 0]["age"].median()
df.loc[df["age"] < 0, "age"] = median_age

df["income"] = df["income"].round(2)
df["age"] = df["age"].round(2)
df["loan"] = df["loan"].round(2)

df.to_csv("/content/drive/MyDrive/credit_data.csv", index=False,
float_format="%.2f")

print("Dataset cleaned")
```

Στον Πίνακα 8.1 παρουσιάζονται ενδεικτικές εγγραφές του συνόλου δεδομένων μετά τη διαδικασία καθαρισμού και προεπεξεργασίας.

Πίνακας 8. 1 Παρουσίαση Ενδεικτικών Εγγραφών

clientid	income	age	loan	default
1	66155.93	59.02	8106.53	0

2	34415.15	48.12	6564.75	0
3	57317.17	63.11	8020.95	0
4	42709.53	45.75	6103.64	0
5	66952.69	18.58	8770.10	1
6	24904.06	57.47	15.50	0
7	48430.36	26.81	5722.58	0
8	24500.14	32.90	2971.00	1
9	40654.89	55.50	4755.83	0

8.2 Σκοπός της Πειραματικής Διαδικασίας

Σε αντίθεση με το προηγούμενο πείραμα, στο οποίο οι κανόνες απόφασης ήταν γνωστοί εκ των προτέρων και χρησιμοποιήθηκαν για τη δημιουργία ενός συνθετικού συνόλου δεδομένων, στο παρόν πείραμα οι σχέσεις μεταξύ των μεταβλητών δεν είναι προκαθορισμένες. Κατά συνέπεια, οι αλγόριθμοι μηχανικής μάθησης καλούνται να ανακαλύψουν αυτόνομα τα πρότυπα και τις συσχετίσεις που υπάρχουν στα δεδομένα, βασιζόμενοι αποκλειστικά στις πληροφορίες που περιέχονται στο dataset.

Ο βασικός σκοπός της πειραματικής διαδικασίας είναι η διερεύνηση της ικανότητας των αλγορίθμων PRISM και CART να εξάγουν κανόνες ταξινόμησης από πραγματικά δεδομένα και να αποτυπώνουν τις σχέσεις μεταξύ των χαρακτηριστικών που επηρεάζουν την πιθανότητα αθέτησης ενός δανείου. Μέσα από τη διαδικασία αυτή επιδιώκεται η κατανόηση του τρόπου με τον οποίο διαφορετικές μεθοδολογικές προσεγγίσεις μηχανικής μάθησης μπορούν να αναπαραστήσουν τη γνώση που προκύπτει από τα δεδομένα.

Πιο συγκεκριμένα, η πειραματική διαδικασία επιδιώκει:

- την αξιολόγηση της ικανότητας των αλγορίθμων να παράγουν σαφείς και ερμηνεύσιμους κανόνες ταξινόμησης, οι οποίοι να αποτυπώνουν τις σχέσεις μεταξύ των χαρακτηριστικών του dataset και της μεταβλητής στόχου,

- τη σύγκριση της μορφής και της δομής των κανόνων που παράγονται από κάθε αλγόριθμο, προκειμένου να αναδειχθούν οι διαφορές μεταξύ των δύο προσεγγίσεων,
- την αξιολόγηση της δυνατότητας μετατροπής των κανόνων που προκύπτουν από τα μοντέλα σε πίνακες απόφασης σύμφωνα με το πρότυπο DMN, με στόχο την ενσωμάτωσή τους σε συστήματα υποστήριξης αποφάσεων.

Η σύγκριση αυτή επιτρέπει την καλύτερη κατανόηση των διαφορών μεταξύ δύο διαφορετικών προσεγγίσεων μηχανικής μάθησης. Από τη μία πλευρά, ο αλγόριθμος PRISM ανήκει στην κατηγορία των συμβολικών μεθόδων μάθησης και παράγει σύνολα ανεξάρτητων κανόνων της μορφής *IF-THEN*, οι οποίοι είναι άμεσα ερμηνεύσιμοι από τον χρήστη. Από την άλλη πλευρά, ο αλγόριθμος CART βασίζεται σε στατιστικά κριτήρια διαχωρισμού των δεδομένων και αναπαριστά τη γνώση μέσω μιας ιεραρχικής δομής δέντρου απόφασης, από την οποία μπορούν στη συνέχεια να εξαχθούν κανόνες.

Η ανάλυση των κανόνων που προκύπτουν από τους δύο αλγορίθμους επιτρέπει την αξιολόγηση όχι μόνο της προβλεπτικής τους ικανότητας, αλλά και του βαθμού ερμηνευσιμότητας των μοντέλων που παράγονται. Η ιδιότητα αυτή είναι ιδιαίτερα σημαντική σε εφαρμογές αξιολόγησης πιστωτικού κινδύνου, όπου η κατανόηση και η αιτιολόγηση των αποφάσεων αποτελούν κρίσιμους παράγοντες για τη χρήση μοντέλων μηχανικής μάθησης σε πραγματικά συστήματα λήψης αποφάσεων.

8.3 Εφαρμογή του Αλγορίθμου PRISM

Ακολουθεί η διαδικασία εφαρμογής του αλγορίθμου PRISM στο σύνολο δεδομένων πιστωτικού κινδύνου. Η εφαρμογή του αλγορίθμου πραγματοποιήθηκε μέσω μιας σειράς διαδοχικών βημάτων, τα οποία περιλαμβάνουν τη μετατροπή των δεδομένων σε συμβολική μορφή, την ανάλυση των συνδυασμών χαρακτηριστικών και την εκπαίδευση του μοντέλου για την εξαγωγή κανόνων.

Διακριτοποίηση των συνεχών μεταβλητών

Ο αλγόριθμος PRISM λειτουργεί σε κατηγορικά δεδομένα, γεγονός που σημαίνει ότι οι μεταβλητές εισόδου πρέπει να είναι κατηγορικές. Για τον λόγο αυτό πραγματοποιείται διαδικασία διακριτοποίησης (discretization) των συνεχών αριθμητικών μεταβλητών του dataset.

Συγκεκριμένα, οι μεταβλητές *age*, *income* και *loan* χωρίζονται σε τρεις κατηγορίες χρησιμοποιώντας τη μέθοδο *quantile discretization* (*qcut*) της βιβλιοθήκης *Pandas*. Η μέθοδος αυτή χωρίζει τις τιμές κάθε μεταβλητής σε τμήματα που περιέχουν περίπου ίσο αριθμό παρατηρήσεων, επιτρέποντας μια πιο ισορροπημένη κατανομή των δεδομένων στις κατηγορίες.

Οι κατηγορίες που προέκυψαν από τη διαδικασία διακριτοποίησης ορίστηκαν με τρόπο που να αποτυπώνουν διαφορετικά επίπεδα των αντίστοιχων χαρακτηριστικών. Πιο συγκεκριμένα, η μεταβλητή *age* διαχωρίστηκε σε τρεις

κατηγορίες που αντιπροσωπεύουν διαφορετικές ηλικιακές ομάδες (*young*, *adult* και *old*). Αντίστοιχα, η μεταβλητή *income* κατηγοριοποιήθηκε σε τρία επίπεδα εισοδήματος (*low*, *medium* και *high*), ενώ η μεταβλητή *loan* διακριτοποιήθηκε σε τρεις κατηγορίες που αντιστοιχούν σε διαφορετικά επίπεδα ποσού δανείου (*small*, *medium* και *large*).

Με τον τρόπο αυτό οι συνεχείς αριθμητικές μεταβλητές μετατρέπονται σε κατηγορικές, γεγονός που επιτρέπει την αποτελεσματική εφαρμογή του αλγορίθμου PRISM για την εξαγωγή κανόνων ταξινόμησης.

Κατά τη διαδικασία διακριτοποίησης καταγράφονται επίσης τα αριθμητικά όρια (*ranges*) κάθε κατηγορίας, ώστε να είναι δυνατή η αντιστοίχιση των αρχικών αριθμητικών τιμών στις αντίστοιχες κατηγορίες. Τα όρια αυτά παρουσιάζονται στον Πίνακα 8.2.

Πίνακας 8. 2 Όρια διακριτοποίησης των μεταβλητών

Μεταβλητή	Κατηγορία	Εύρος τιμών
age	young	18.06 – 33.20
age	adult	33.20 – 48.81
age	old	48.81 – 63.97
income	low	20014.49 – 36971.27
income	medium	36971.27 – 53648.94
income	high	53648.94 – 69995.69
loan	small	1.38 – 2574.30
loan	medium	2574.30 – 5599.55
loan	large	5599.55 – 13766.05

Τα όρια αυτά προέκυψαν αυτόματα από τη διαδικασία *quantile discretization* και αντιστοιχούν στα διαστήματα τιμών των αρχικών αριθμητικών μεταβλητών που αντιστοιχούν σε κάθε κατηγορία.

Έπειτα πραγματοποιείται μετατροπή της μεταβλητής στόχου σε συμβολική μορφή. Συγκεκριμένα, οι αριθμητικές τιμές της μεταβλητής *default* αντικαθίστανται από κατηγορικές τιμές που είναι πιο εύκολα ερμηνεύσιμες.

Ο μετασχηματισμός πραγματοποιείται ως εξής:

0 → good

1 → bad

Με τον τρόπο αυτό, το πρόβλημα διατυπώνεται ως πρόβλημα δυαδικής ταξινόμησης των πελατών σε good (0) και bad (1).

Η υλοποίηση της διαδικασίας διακριτοποίησης παρουσιάζεται στον Κώδικα 8.2.

Κώδικας 8.2: Διαδικασία Διακριτοποίησης Μεταβλητών

```
import pandas as pd

df = pd.read_csv("/content/drive/MyDrive/credit_data.csv")

df = df.drop(columns=["clientid"])
df = df.dropna()

TARGET = "default"

df_new = df.copy()

df_new["age"], age_bins = pd.qcut(
    df["age"],
    q=3,
    labels=["young", "adult", "old"],
    retbins=True,
    duplicates="drop"
)

df_new["income"], income_bins = pd.qcut(
    df["income"],
    q=3,
    labels=["low", "medium", "high"],
    retbins=True,
    duplicates="drop"
)

df_new["loan"], loan_bins = pd.qcut(
    df["loan"],
    q=3,
    labels=["small", "medium", "large"],
    retbins=True,
    duplicates="drop"
)

print("\nAGE ranges:")
print("young :", age_bins[0], "to", age_bins[1])
print("adult :", age_bins[1], "to", age_bins[2])
print("old   :", age_bins[2], "to", age_bins[3])

print("\nINCOME ranges:")
print("low    :", income_bins[0], "to", income_bins[1])
print("medium :", income_bins[1], "to", income_bins[2])
print("high   :", income_bins[2], "to", income_bins[3])

print("\nLOAN ranges:")
print("small  :", loan_bins[0], "to", loan_bins[1])
print("medium :", loan_bins[1], "to", loan_bins[2])
```

```

print("large :", loan_bins[2], "to", loan_bins[3])

df_new[TARGET] = df_new[TARGET].replace({
    0: "good",
    1: "bad"
})

save_path = "/content/drive/MyDrive/credit_dataset_discretized.csv"

df_new.to_csv(save_path, index=False)

print("\nDataset saved successfully:")
print(save_path)

```

Μετά την ολοκλήρωση της διαδικασίας διακριτοποίησης δημιουργείται ένα νέο σύνολο δεδομένων (*credit_dataset_discretized.csv*) στο οποίο όλες οι μεταβλητές έχουν κατηγορικές τιμές. Στον Πίνακα 8.3 παρουσιάζονται ενδεικτικά οι 10 πρώτες εγγραφές του νέου dataset.

Πίνακας 8. 3 Παρουσίαση Ενδεικτικών Εγγραφών του Διακριτοποιημένου Dataset

income	age	loan	default
high	old	large	good
low	adult	large	good
high	old	large	good
medium	adult	large	good
high	young	large	bad
low	old	small	good
medium	young	large	good
low	young	medium	bad
medium	old	medium	good

Ο πίνακας αυτός παρουσιάζει ένα μικρό δείγμα εγγραφών από το διακριτοποιημένο dataset, στο οποίο οι αρχικές αριθμητικές μεταβλητές έχουν αντικατασταθεί από τις αντίστοιχες κατηγορικές τιμές. Η μορφή αυτή των δεδομένων είναι κατάλληλη για την εφαρμογή του αλγορίθμου PRISM στα επόμενα στάδια της ανάλυσης.

Ανάλυση συνδυασμών χαρακτηριστικών

Μετά τη διακριτοποίηση των δεδομένων πραγματοποιείται ανάλυση των πιθανών συνδυασμών των χαρακτηριστικών age, income και loan. Για κάθε συνδυασμό χαρακτηριστικών υπολογίζεται ο αριθμός των εγγραφών που ανήκουν σε κάθε κατηγορία της μεταβλητής στόχου. Η διαδικασία αυτή επιτρέπει την κατανόηση της κατανομής των δεδομένων και τον εντοπισμό περιπτώσεων στις οποίες ο ίδιος συνδυασμός χαρακτηριστικών αντιστοιχεί σε διαφορετικές τιμές της μεταβλητής στόχου.

Τέτοιες περιπτώσεις δημιουργούν ασάφεια στο σύνολο δεδομένων, καθώς ο ίδιος συνδυασμός χαρακτηριστικών μπορεί να συνδέεται με περισσότερες από μία κατηγορίες της μεταβλητής στόχου. Η ύπαρξη αυτών των συγκρούσεων μπορεί να επηρεάσει τη διαδικασία εξαγωγής κανόνων, οδηγώντας σε κανόνες που δεν είναι σαφείς ή παρουσιάζουν μειωμένη ερμηνευσιμότητα.

Για τον λόγο αυτό πραγματοποιείται επιλογή της επικρατούσας κατηγορίας (majority class) για κάθε συνδυασμό χαρακτηριστικών. Συγκεκριμένα, για κάθε μοναδικό συνδυασμό των μεταβλητών age, income και loan διατηρείται η κατηγορία της μεταβλητής στόχου που εμφανίζεται με τη μεγαλύτερη συχνότητα στο dataset. Με τον τρόπο αυτό εξαλείφονται οι αντικρουόμενες εγγραφές και δημιουργείται ένα πιο συνεπές σύνολο δεδομένων.

Με βάση τη διαδικασία αυτή δημιουργείται ένα νέο καθαρό dataset (credit_dataset_clean.csv), το οποίο αποτελεί την τελική είσοδο για την εκπαίδευση του αλγορίθμου PRISM. Το dataset αυτό διατηρεί μόνο τις εγγραφές που αντιστοιχούν στην επικρατούσα κατηγορία για κάθε συνδυασμό χαρακτηριστικών, εξασφαλίζοντας έτσι ότι κάθε συνδυασμός εισόδων αντιστοιχεί σε μία και μοναδική απόφαση ταξινόμησης.

Η υλοποίηση της διαδικασίας παρουσιάζεται στον Κώδικα 8.3.

Κώδικας 8.3: Προσδιορισμός επικρατούσας κατηγορίας και δημιουργία καθαρού dataset

```
clean_df = pd.merge(
    df,
    majority[features + [TARGET]],
    on=features,
    suffixes=("", "_majority")
)

clean_df = clean_df[clean_df[TARGET] == clean_df[TARGET +
    "_majority"]]

clean_df = clean_df.drop(columns=[TARGET + "_majority"])

print("\nClean dataset size:", len(clean_df))

clean_df.to_csv(
    "/content/drive/MyDrive/credit_dataset_clean.csv",
    index=False
```

```

)

print("\nClean dataset saved successfully.")

    on=features,
    suffixes=("", "_majority")
)

clean_df = clean_df[clean_df[TARGET] == clean_df[TARGET +
"_majority"]]

clean_df = clean_df.drop(columns=[TARGET + "_majority"])

print("\nClean dataset size:", len(clean_df))

clean_df.to_csv(
    "/content/drive/MyDrive/credit_dataset_clean.csv",
    index=False
)

```

Εκπαίδευση του αλγορίθμου PRISM

Στο επόμενο στάδιο πραγματοποιείται η εκπαίδευση του αλγορίθμου PRISM. Η εκπαίδευση του αλγορίθμου πραγματοποιήθηκε επί του πλήρους συνόλου δεδομένων, το οποίο αποτελείται από 2000 εγγραφές. Ο αλγόριθμος εφαρμόστηκε σύμφωνα με την κανονική εκδοχή του PRISM, η οποία βασίζεται στη στρατηγική *separate-and-conquer* για την εξαγωγή κανόνων ταξινόμησης.

Η διαδικασία εκπαίδευσης εκτελείται ξεχωριστά για κάθε κλάση της μεταβλητής στόχου default και περιλαμβάνει τα ακόλουθα στάδια:

- Επιλογή της συνθήκης της μορφής (*attribute = value*) που μεγιστοποιεί την πιθανότητα εμφάνισης της συγκεκριμένης κλάσης.
- Προοδευτική προσθήκη επιπλέον συνθηκών στον κανόνα μέχρι ο κανόνας να επιτύχει πλήρη καθαρότητα, δηλαδή να καλύπτει μόνο παρατηρήσεις της ίδιας κλάσης.
- Αφαίρεση των παρατηρήσεων που καλύπτονται από τον κανόνα από το σύνολο δεδομένων.
- Επανάληψη της διαδικασίας για τη δημιουργία νέων κανόνων έως ότου καλυφθούν όλες οι περιπτώσεις της συγκεκριμένης κλάσης.

Η εκπαίδευση ολοκληρώνεται όταν όλες οι εγγραφές του συνόλου δεδομένων καλυφθούν από κάποιον παραγόμενο κανόνα. Το τελικό αποτέλεσμα είναι ένα

σύνολο κανόνων ταξινόμησης που περιγράφει τις σχέσεις μεταξύ των χαρακτηριστικών age, income και loan και της μεταβλητής στόχου default.

Παραγόμενοι Κανόνες

Οι κανόνες που εξήχθησαν από τον αλγόριθμο συνοψίζονται παρακάτω:

FINAL PRISM RULES:

=== CLASS good ===

Rule 1: IF age = old THEN good

Rule 2: IF age = adult THEN good

Rule 3: IF loan = small THEN good

Rule 4: IF loan = medium AND income = high THEN good

Rule 5: IF loan = medium AND income = medium THEN good

=== CLASS bad ===

Rule 1: IF age = young AND loan = large THEN bad

Rule 2: IF age = young AND income = low AND loan = medium THEN bad

8.4 Αξιολόγηση των κανόνων PRISM

Αφού ολοκληρωθεί η διαδικασία εκπαίδευσης του αλγορίθμου PRISM και εξαχθούν οι κανόνες ταξινόμησης, στο επόμενο στάδιο πραγματοποιείται η μετατροπή των κανόνων αυτών σε πίνακα απόφασης σύμφωνα με το πρότυπο DMN.

Η μετατροπή αυτή πραγματοποιείται μέσω της δημιουργίας ενός αρχείου σε μορφή XML, το οποίο περιγράφει τη δομή ενός πίνακα απόφασης. Στον πίνακα αυτό οι μεταβλητές age, income και loan αποτελούν τις εισόδους του μοντέλου, ενώ η μεταβλητή default αποτελεί την έξοδο της απόφασης. Κάθε κανόνας που παράγεται από τον αλγόριθμο PRISM μετατρέπεται σε μία γραμμή του πίνακα απόφασης, επιτρέποντας την αναπαράσταση των κανόνων σε μορφή συμβατή με το πρότυπο DMN και την ενσωμάτωσή τους σε συστήματα υποστήριξης αποφάσεων.

Πιο συγκεκριμένα, η διαδικασία μετατροπής περιλαμβάνει τα ακόλουθα βήματα:

- Αντιστοίχιση των μεταβλητών age, income και loan ως εισόδων (*input expressions*) του πίνακα απόφασης.

- Ορισμό της μεταβλητής default ως εξόδου (*output*) της απόφασης.
- Μετατροπή κάθε κανόνα που παράγεται από τον αλγόριθμο PRISM σε μία γραμμή του πίνακα απόφασης.
- Ορισμό πολιτικής εκτέλεσης (hit policy = FIRST), σύμφωνα με την οποία εφαρμόζεται ο πρώτος κανόνας που ικανοποιείται.

Με τον τρόπο αυτό δημιουργείται ένας πλήρης πίνακας απόφασης DMN που αποτυπώνει τη γνώση που εξήχθη από τον αλγόριθμο PRISM και μπορεί να αξιοποιηθεί σε συστήματα λήψης αποφάσεων.

Το τελικό αποτέλεσμα της διαδικασίας που είναι ένα αρχείο DMN, το οποίο περιέχει όλους τους κανόνες που εξήχθησαν από τον αλγόριθμο PRISM παρουσιάζεται παρακάτω.

PRISM Credit Default		Hit policy: First			
	When	And	And	Then	Annotations
	income	age	loan	default	
	string	string	string	string	
1	-	"old"	-	good	
2	-	"adult"	-	good	
3	-	-	"small"	good	
4	"high"	-	"medium"	good	
5	"medium"	-	"medium"	good	
6	-	"young"	"large"	bad	
7	"low"	"young"	"medium"	bad	
8	-	-	-	good	
*	-	-	-	-	

Εικόνα 8. 1 Πίνακας Αποφάσεων του αλγορίθμου PRISM

Από την ανάλυση των κανόνων παρατηρείται ότι ορισμένα χαρακτηριστικά εμφανίζονται να έχουν μεγαλύτερη επίδραση στην τελική απόφαση. Συγκεκριμένα, η μεταβλητή age φαίνεται να παίζει σημαντικό ρόλο, καθώς οι κανόνες που αφορούν τις κατηγορίες *adult* και *old* οδηγούν σε απόφαση *good*, ανεξάρτητα από τις τιμές των υπολοίπων χαρακτηριστικών. Αυτό υποδηλώνει ότι οι πελάτες μεγαλύτερης ηλικίας εμφανίζουν μικρότερη πιθανότητα αθέτησης πληρωμής.

Επιπλέον, η μεταβλητή *loan* φαίνεται επίσης να επηρεάζει την τελική πρόβλεψη. Για παράδειγμα, όταν το ποσό του δανείου ανήκει στην κατηγορία *small*, η απόφαση είναι *good*, γεγονός που υποδηλώνει ότι μικρότερα δάνεια συνδέονται με χαμηλότερο πιστωτικό κίνδυνο.

Παράλληλα, παρατηρείται ότι σε περιπτώσεις όπου το εισόδημα βρίσκεται στα επίπεδα *high* ή *medium* και το ποσό του δανείου *medium* η πρόβλεψη του μοντέλου

παραμένει *good*. Το εύρημα αυτό υποδηλώνει ότι τα μεσαίου μεγέθους δάνεια θεωρούνται σχετικά ασφαλή όταν συνοδεύονται από επαρκές επίπεδο εισοδήματος, καθώς οι πελάτες με μεσαίο ή υψηλό εισόδημα φαίνεται να έχουν μεγαλύτερη δυνατότητα αποπληρωμής των οικονομικών τους υποχρεώσεων.

Αντίθετα, οι κανόνες που οδηγούν στην κατηγορία *bad* σχετίζονται κυρίως με την ηλικιακή κατηγορία *young* σε συνδυασμό με συγκεκριμένα επίπεδα δανείου ή εισοδήματος. Συγκεκριμένα, όταν ένας πελάτης ανήκει στην κατηγορία *young* και έχει μεγάλο ποσό δανείου *large*, το μοντέλο προβλέπει αυξημένη πιθανότητα αθέτησης. Παρόμοια συμπεριφορά παρατηρείται και στην περίπτωση όπου το εισόδημα είναι *low* και η ηλικία *young* και το εισόδημα *medium* γεγονός που υποδηλώνει υψηλότερο πιστωτικό κίνδυνο για νεότερους πελάτες με χαμηλότερη οικονομική δυνατότητα.

Τέλος, ο πίνακας περιλαμβάνει έναν γενικό κανόνα προεπιλογής (default rule), ο οποίος εφαρμόζεται όταν καμία από τις προηγούμενες συνθήκες δεν ικανοποιείται. Στην περίπτωση αυτή η απόφαση είναι *good*, γεγονός που υποδηλώνει ότι η πλειοψηφία των εγγραφών στο dataset ανήκει στην κατηγορία πελατών που εξυπηρετούν κανονικά το δάνειό τους.

Συνολικά, οι κανόνες που παράγονται από τον αλγόριθμο PRISM είναι απλοί και εύκολα ερμηνεύσιμοι, γεγονός που αποτελεί σημαντικό πλεονέκτημα των συμβολικών μεθόδων μάθησης. Η αναπαράστασή τους σε μορφή πίνακα απόφασης DMN επιτρέπει την εύκολη ενσωμάτωσή τους σε συστήματα υποστήριξης αποφάσεων που χρησιμοποιούνται για την αξιολόγηση πιστωτικού κινδύνου.

8.5 Εφαρμογή του Αλγορίθμου CART

Ακολουθεί η εφαρμογή του αλγορίθμου CART στο αριθμητικό σύνολο δεδομένων πιστωτικού κινδύνου. Για την υλοποίηση του αλγορίθμου χρησιμοποιήθηκε η βιβλιοθήκη *scikit-learn* της γλώσσας προγραμματισμού *Python*, η οποία παρέχει την κλάση *DecisionTreeClassifier* για την εκπαίδευση μοντέλων δέντρων αποφάσεων.

Προετοιμασία των δεδομένων

Αρχικά πραγματοποιείται η φόρτωση του συνόλου δεδομένων που δημιουργήθηκε μετά τη διαδικασία καθαρισμού. Στη συνέχεια πραγματοποιείται και πάλι μετατροπή της μεταβλητής στόχου *default* σε πιο ερμηνεύσιμη κατηγορική μορφή. Συγκεκριμένα, η τιμή 0 αντιστοιχίζεται στην κατηγορία *good*, ενώ η τιμή 1 αντιστοιχίζεται στην κατηγορία *bad*.

Τα χαρακτηριστικά εισόδου του μοντέλου είναι οι μεταβλητές *age*, *income* και *loan*, οι οποίες παραμένουν σε αριθμητική μορφή. Σε αντίθεση με τον αλγόριθμο PRISM, ο CART μπορεί να επεξεργαστεί απευθείας συνεχείς αριθμητικές μεταβλητές χωρίς να απαιτείται διαδικασία διακριτοποίησης.


Εκπαίδευση του δέντρου αποφάσεων

Στο επόμενο στάδιο πραγματοποιείται η εκπαίδευση του δέντρου αποφάσεων χρησιμοποιώντας την κλάση `DecisionTreeClassifier`. Για τον έλεγχο της πολυπλοκότητας του μοντέλου ορίζεται μέγιστο βάθος δέντρου ίσο με τέσσερα επίπεδα (`max_depth = 4`), ώστε να αποφευχθεί η υπερπροσαρμογή (*overfitting*) και να διατηρηθεί η ερμηνευσιμότητα του μοντέλου.

Κατά τη διαδικασία εκπαίδευσης, ο αλγόριθμος εξετάζει διαδοχικά τα χαρακτηριστικά του dataset και επιλέγει σε κάθε κόμβο το χαρακτηριστικό και την τιμή κατωφλίου που οδηγούν στον καλύτερο διαχωρισμό των δεδομένων, με βάση το κριτήριο Gini impurity. Μέσω επαναλαμβανόμενων διασπάσεων δημιουργείται μια ιεραρχική δομή, στην οποία κάθε εσωτερικός κόμβος αντιστοιχεί σε μια συνθήκη διάσπασης και κάθε φύλλο του δέντρου αντιστοιχεί σε μια τελική πρόβλεψη της κλάσης.

Μετά την ολοκλήρωση της εκπαίδευσης, το παραγόμενο μοντέλο οπτικοποιείται σε μορφή γραφήματος, το οποίο απεικονίζει τη δομή του δέντρου αποφάσεων και τις συνθήκες που χρησιμοποιούνται για την ταξινόμηση των δεδομένων.

Η ακόλουθη εικόνα παρουσιάζει το δέντρο αποφάσεων που προέκυψε από την εφαρμογή του αλγορίθμου CART στο σύνολο δεδομένων πιστωτικού κινδύνου.



Εικόνα 8. 2 Παραγόμενο Δέντρο Απόφασης από τον αλγόριθμο CART

Η δομή του παραγόμενου δέντρου αποφάσεων απεικονίζει τη διαδικασία με την οποία το μοντέλο διαχωρίζει τα δεδομένα με στόχο την πρόβλεψη της κατάστασης αποπληρωμής του δανείου. Η διαδικασία ξεκινά από τον κόμβο ρίζας, στον οποίο

εξετάζεται το χαρακτηριστικό age . Συγκεκριμένα, το πρώτο σημείο διάσπασης πραγματοποιείται στη συνθήκη $age \leq 34.925$. Η επιλογή αυτού του χαρακτηριστικού υποδηλώνει ότι η ηλικία αποτελεί τον σημαντικότερο παράγοντα για τον αρχικό διαχωρισμό των δεδομένων, καθώς οδηγεί στη μεγαλύτερη μείωση της τιμής Gini.

Για τις περιπτώσεις όπου η συνθήκη $age \leq 34.925$ ισχύει, το μοντέλο προχωρά σε περαιτέρω διαχωρισμό με βάση το χαρακτηριστικό $loan$, εξετάζοντας τη συνθήκη $loan \leq 5834.04$. Το υποδέντρο αυτό αναλύει περαιτέρω τα δεδομένα μέσω διαδοχικών ελέγχων στα χαρακτηριστικά $loan$ και $income$, δημιουργώντας μικρότερα και περισσότερο ομοιογενή υποσύνολα. Παρατηρείται ότι σε αρκετές περιπτώσεις τα τελικά φύλλα του δέντρου καταλήγουν στην κλάση $good$, γεγονός που υποδηλώνει ότι τα περισσότερα δείγματα αυτής της ομάδας αντιστοιχούν σε πελάτες που εξυπηρετούν κανονικά το δάνειό τους.

Αντίθετα, όταν η αρχική συνθήκη $age \leq 34.925$ δεν ικανοποιείται, το μοντέλο οδηγείται στο δεξί υποδέντρο. Σε αυτή την περίπτωση, ο διαχωρισμός πραγματοποιείται κυρίως με βάση το ύψος του δανείου ($loan$) και το εισόδημα ($income$). Για παράδειγμα, η συνθήκη $loan \leq 7707.78$ οδηγεί σε περαιτέρω διάσπαση με βάση το χαρακτηριστικό $income$, δημιουργώντας κόμβους που ταξινομούν τα δείγματα είτε ως $good$ είτε ως bad .

Καθώς προχωράμε προς τα φύλλα του δέντρου, οι κόμβοι γίνονται ολοένα και πιο ομοιογενείς, γεγονός που αποτυπώνεται στις χαμηλές τιμές του δείκτη Gini. Τα φύλλα του δέντρου αντιστοιχούν στις τελικές αποφάσεις του μοντέλου και αποτελούν τις προβλέψεις της κλάσης για κάθε πιθανό συνδυασμό συνθηκών των χαρακτηριστικών.

Με τον τρόπο αυτό, κάθε διαδρομή από τον κόμβο ρίζας έως ένα φύλλο του δέντρου αντιστοιχεί σε έναν σαφή κανόνα απόφασης. Οι κανόνες αυτοί μπορούν στη συνέχεια να εξαχθούν και να μετατραπούν σε κανόνες ενός πίνακα αποφάσεων DMN.

8.6 Αξιολόγηση των κανόνων CART

Μετά την εκπαίδευση και την ανάλυση του δέντρου αποφάσεων, η λογική του μοντέλου μετατράπηκε σε σύνολο κανόνων απόφασης και οργανώθηκε σε πίνακα αποφάσεων DMN. Η διαδικασία αυτή βασίζεται στην εξαγωγή των διαδρομών απόφασης του δέντρου, δηλαδή των μονοπατιών που ξεκινούν από τον κόμβο ρίζας και καταλήγουν στα φύλλα του δέντρου.

Οι κανόνες που εξήχθησαν από το δέντρο οργανώθηκαν σε έναν πίνακα αποφάσεων σύμφωνα με το πρότυπο DMN. Στον πίνακα αυτό, κάθε γραμμή αντιστοιχεί σε έναν κανόνα, ενώ οι στήλες εισόδου αντιπροσωπεύουν τα χαρακτηριστικά του συνόλου δεδομένων, συγκεκριμένα τις μεταβλητές age , $income$ και $loan$. Η στήλη εξόδου αντιστοιχεί στη μεταβλητή $default$, η οποία εκφράζει την τελική απόφαση του μοντέλου σχετικά με το αν ένας πελάτης θεωρείται αξιόπιστος ή παρουσιάζει κίνδυνο αθέτησης αποπληρωμής.

Το αρχείο DMN που δημιουργήθηκε αποθηκεύτηκε σε μορφή XML και εισήχθη σε περιβάλλον μοντελοποίησης επιχειρησιακών κανόνων, όπως το Camunda Modeler, όπου και παρουσιάζεται σε μορφή πίνακα αποφάσεων.

Loan Approval Hit policy: Unique					
	When	And	And	Then	Annotations
	income double	age double	loan double	default string	
1	≤ 21430.57	≤ 34.92	≤ 3283.44	good	
2	> 21430.57	≤ 34.92	≤ 3283.44	good	
3	≤ 38026.90	≤ 34.92	> 3283.44	bad	
4	> 38026.90	≤ 34.92	> 3283.44	good	
5	≤ 58474.98	≤ 34.92	≤ 7707.78	bad	
6	> 58474.98	≤ 34.92	≤ 7707.78	good	
7	≤ 69455.70	≤ 34.92	> 7707.78	bad	
8	> 69455.70	≤ 34.92	> 7707.78	bad	
9	-	> 34.92	-	good	
+	-	-	-		

Εικόνα 8. 3 Πίνακας Αποφάσεων του αλγορίθμου CART

Από την ανάλυση των κανόνων προκύπτει ότι η ηλικία αποτελεί τον βασικότερο παράγοντα για τον αρχικό διαχωρισμό των δεδομένων, καθώς όλες οι πρώτες οκτώ γραμμές του πίνακα αφορούν περιπτώσεις όπου $\text{age} \leq 34.92$, ενώ ο τελευταίος κανόνας καλύπτει τις περιπτώσεις όπου $\text{age} > 34.92$. Στην τελευταία αυτή περίπτωση το μοντέλο προβλέπει ότι ο πελάτης δεν θα παρουσιάσει αθέτηση αποπληρωμής, γεγονός που υποδηλώνει ότι τα άτομα μεγαλύτερης ηλικίας στο συγκεκριμένο σύνολο δεδομένων εμφανίζουν χαμηλότερο πιστωτικό κίνδυνο.

Για τις περιπτώσεις όπου $\text{age} \leq 34.92$, η απόφαση εξαρτάται κυρίως από το ύψος του δανείου (loan) και το επίπεδο εισοδήματος (income). Παρατηρείται ότι όταν το ποσό του δανείου είναι σχετικά μικρό ($\text{loan} \leq 3283.44$), η πρόβλεψη του μοντέλου είναι $\text{default} = \text{good}$, ανεξάρτητα από μικρές διακυμάνσεις στο εισόδημα. Αντίθετα, σε περιπτώσεις όπου το δάνειο είναι μεγαλύτερο, η τελική απόφαση επηρεάζεται περισσότερο από το επίπεδο εισοδήματος του πελάτη.

Ειδικότερα, όταν το ποσό του δανείου είναι υψηλό και το εισόδημα βρίσκεται σε χαμηλότερα επίπεδα, το μοντέλο προβλέπει αυξημένη πιθανότητα αθέτησης. Αυτό αποτυπώνεται σε κανόνες όπως εκείνοι όπου $\text{loan} > 3283.44$ και $\text{income} \leq 38026.90$, καθώς και στις περιπτώσεις όπου το δάνειο υπερβαίνει το όριο των 7707.78 και το εισόδημα δεν ξεπερνά τα 69455.70.

Συνολικά, οι κανόνες που προκύπτουν από το μοντέλο αναδεικνύουν μια σαφή σχέση μεταξύ εισοδήματος, ύψους δανείου και πιστωτικού κινδύνου. Τα άτομα με

υψηλότερα εισοδήματα ή μικρότερα δάνεια εμφανίζουν μικρότερη πιθανότητα αθέτησης, ενώ ο συνδυασμός χαμηλού εισοδήματος και υψηλού ποσού δανείου οδηγεί συχνότερα σε πρόβλεψη αρνητικής πιστοληπτικής συμπεριφοράς.

Ο κώδικας που υλοποιεί τις διαδικασίες εξαγωγής κανόνων των αλγορίθμων και τη δημιουργία των DMN πινάκων για το συγκεκριμένο πείραμα είναι διαθέσιμος στον ακόλουθο σύνδεσμο:

<https://github.com/DanaeKouimtzipou/credit-project>

8.7 Συγκριτική Αποτίμηση PRISM και CART

Ακολουθεί η σύγκριση των κανόνων που παράγονται από τον αλγόριθμο CART με τους κανόνες που προκύπτουν από τον αλγόριθμο PRISM. Η σύγκριση βασίζεται στην αντιστοίχιση των αριθμητικών κατωφλίων που εμφανίζονται στους κανόνες του CART με τις κατηγορίες που προκύπτουν από τη διαδικασία διακριτοποίησης των μεταβλητών ηλικίας, εισοδήματος και ποσού δανείου.

Κανόνας 1: $\text{income} \leq 21430.5$ AND $\text{age} \leq 34.92$ AND $\text{loan} \leq 3283.44 \rightarrow \text{good}$

Το όριο $\text{income} \leq 21430.57$ βρίσκεται εντός της κατηγορίας low. Η συνθήκη $\text{age} \leq 34.92$ καλύπτει τιμές από τις κατηγορίες young και ένα μικρό τμήμα της κατηγορίας adult, ωστόσο το μεγαλύτερο μέρος των τιμών αντιστοιχεί στην κατηγορία young. Η συνθήκη $\text{loan} \leq 3283.44$ καλύπτει τιμές των κατηγοριών small και medium, με μεγαλύτερη συγκέντρωση στην κατηγορία small.

Ο κανόνας αυτός περιγράφει κυρίως περιπτώσεις νεαρών πελατών με χαμηλό εισόδημα και σχετικά μικρό ή μεσαίο ποσό δανείου που ταξινομούνται ως καλοί πελάτες. Η λογική αυτή παρουσιάζει μερική αντιστοιχία με τον κανόνα του PRISM:

IF loan = small THEN good

καθώς το μικρό ποσό δανείου οδηγεί επίσης σε θετική αξιολόγηση.

Κανόνας 2: $\text{income} > 21430.57$ AND $\text{age} \leq 34.92$ AND $\text{loan} \leq 3283.44 \rightarrow \text{good}$

Η συνθήκη $\text{income} > 21430.57$ καλύπτει τμήμα της κατηγορίας low, ολόκληρη την κατηγορία medium και high. Η ηλικία $\text{age} \leq 34.92$ αντιστοιχεί κυρίως στην κατηγορία young. Η συνθήκη $\text{loan} \leq 3283.44$ καλύπτει τιμές των κατηγοριών small και medium, με μεγαλύτερη συγκέντρωση στην κατηγορία small.

Η λογική του κανόνα αυτού παρουσιάζει σημαντική αντιστοιχία με τον κανόνα του PRISM:

IF loan = medium AND income = medium THEN good

καθώς και στις δύο περιπτώσεις ένας συνδυασμός μεσαίου εισοδήματος και μεσαίου ποσού δανείου οδηγεί σε θετική απόφαση.

Κανόνας 3: $\text{income} \leq 38026.90$ AND $\text{age} \leq 34.92$ AND $\text{loan} > 3283.44 \rightarrow \text{bad}$

Η συνθήκη $\text{income} \leq 38026.90$ καλύπτει κυρίως τις κατηγορίες low και ένα μικρό τμήμα της medium, με κύρια τάση προς low. Η ηλικία $\text{age} \leq 34.92$ αντιστοιχεί κυρίως στην κατηγορία young. Η συνθήκη $\text{loan} > 3283.44$ καλύπτει μεγάλο μέρος της κατηγορίας medium και ολόκληρη την κατηγορία large.

Ο κανόνας αυτός παρουσιάζει σημαντική αντιστοιχία με τον κανόνα του PRISM:

IF age = young AND income = low AND loan = medium THEN bad

καθώς και στις δύο περιπτώσεις ο συνδυασμός νεαρής ηλικίας, χαμηλού εισοδήματος και μεσαίου ποσού δανείου συνδέεται με αυξημένη πιθανότητα αθέτησης.

Κανόνας 4: $\text{income} > 38026.90$ AND $\text{age} \leq 34.92$ AND $\text{loan} > 3283.44 \rightarrow \text{good}$

Η συνθήκη $\text{income} > 38026.90$ αντιστοιχεί στις κατηγορίες medium και high. Η ηλικία $\text{age} \leq 34.92$ αντιστοιχεί κυρίως στην κατηγορία young. Η συνθήκη $\text{loan} > 3283.44$ αντιστοιχεί στις κατηγορίες medium και large.

Η λογική αυτή παρουσιάζει αντιστοιχία με τον κανόνα του PRISM:

IF loan = medium AND income = high THEN good

καθώς και στις δύο περιπτώσεις η ύπαρξη υψηλότερου εισοδήματος σε συνδυασμό με μεσαίο ποσό δανείου οδηγεί σε θετική αξιολόγηση.

Κανόνας 5: $\text{income} \leq 58474.98$ AND $\text{age} \leq 34.92$ AND $\text{loan} \leq 7707.78 \rightarrow \text{bad}$

Η συνθήκη $\text{income} \leq 58474.98$ καλύπτει κυρίως τις κατηγορίες low και medium. Η ηλικία $\text{age} \leq 34.92$ αντιστοιχεί κυρίως στην κατηγορία young. Η συνθήκη $\text{loan} \leq 7707.78$ καλύπτει τις κατηγορίες medium και ένα μέρος της large, με κύρια τάση προς medium.

Η λογική αυτή παρουσιάζει αντιστοιχία με τον κανόνα του PRISM:

IF age = young AND income = low AND loan = medium THEN bad

καθώς ο συνδυασμός νεαρής ηλικίας και μεσαίου ποσού δανείου εμφανίζει αυξημένο πιστωτικό κίνδυνο.

Κανόνας 6: $\text{income} > 58474.98$ AND $\text{age} \leq 34.92$ AND $\text{loan} \leq 7707.78 \rightarrow \text{good}$

Η συνθήκη $\text{income} > 58474.98$ αντιστοιχεί στην κατηγορία high. Η ηλικία $\text{age} \leq 34.92$ αντιστοιχεί κυρίως στην κατηγορία young. Η συνθήκη $\text{loan} \leq 7707.78$ καλύπτει κυρίως την κατηγορία medium.

Ο κανόνας αυτός παρουσιάζει άμεση αντιστοιχία με τον κανόνα του PRISM:

IF loan = medium AND income = high THEN good

καθώς και στις δύο περιπτώσεις ο συνδυασμός υψηλού εισοδήματος και μεσαίου ποσού δανείου οδηγεί σε θετική αξιολόγηση.

Κανόνας 7: $\text{income} \leq 69455.70$ AND $\text{age} \leq 34.92$ AND $\text{loan} > 7707.78 \rightarrow \text{bad}$

Η συνθήκη $\text{income} \leq 69455.70$ καλύπτει σχεδόν ολόκληρο το εύρος των κατηγοριών low, medium και high. Η ηλικία $\text{age} \leq 34.92$ αντιστοιχεί κυρίως στην κατηγορία young. Η συνθήκη $\text{loan} > 7707.78$ αντιστοιχεί σχεδόν αποκλειστικά στην κατηγορία large.

Η περίπτωση αυτή παρουσιάζει ισχυρή αντιστοιχία με τον κανόνα του PRISM:

IF age = young AND loan = large THEN bad

καθώς το μεγάλο ποσό δανείου σε νεαρούς πελάτες συνδέεται με αυξημένη πιθανότητα αθέτησης.

Κανόνας 8: $\text{age} > 34.92 \rightarrow \text{good}$

Η συνθήκη αυτή καλύπτει κυρίως τις κατηγορίες adult και old, με μεγαλύτερη συγκέντρωση στην κατηγορία adult. Η παρατήρηση αυτή παρουσιάζει άμεση αντιστοιχία με τους κανόνες του PRISM:

IF age = adult THEN good
IF age = old THEN good

οι οποίοι οδηγούν επίσης σε θετική απόφαση.

Συνολικά, η σύγκριση των κανόνων δείχνει ότι οι δύο αλγόριθμοι οδηγούν σε παρόμοια πρότυπα λήψης αποφάσεων, παρά το γεγονός ότι χρησιμοποιούν διαφορετική αναπαράσταση των δεδομένων. Ο CART βασίζεται σε αριθμητικά κατώφλια για τον διαχωρισμό των δεδομένων, ενώ ο PRISM δημιουργεί κανόνες απευθείας σε κατηγοριοποιημένες τιμές. Παρά τη διαφορετική μεθοδολογία, αρκετοί κανόνες εμφανίζουν σημαντική αντιστοιχία ως προς τις συνθήκες και τα αποτελέσματα των αποφάσεων.

8.8 Σύνοψη

Στο κεφάλαιο αυτό παρουσιάζεται η πειραματική εφαρμογή των αλγορίθμων PRISM και CART σε ένα πραγματικό σύνολο δεδομένων πιστωτικού κινδύνου με στόχο την εξαγωγή κανόνων ταξινόμησης και την αναπαράστασή τους σε μορφή πινάκων απόφασης. Η ανάλυση βασίζεται σε χαρακτηριστικά που περιγράφουν το προφίλ των πελατών, όπως η ηλικία, το εισόδημα και το ποσό του δανείου, ενώ η μεταβλητή στόχος αφορά την πιθανότητα αθέτησης αποπληρωμής του δανείου.

Τα αποτελέσματα της πειραματικής διαδικασίας δείχνουν ότι και οι δύο αλγόριθμοι είναι σε θέση να παράγουν σαφείς κανόνες ταξινόμησης, οι οποίοι αποτυπώνουν τις βασικές σχέσεις μεταξύ των χαρακτηριστικών του συνόλου δεδομένων και της

μεταβλητής στόχου. Οι κανόνες αυτοί επιτρέπουν την κατανόηση των συνθηκών υπό τις οποίες ένας πελάτης ταξινομείται ως χαμηλού ή υψηλού πιστωτικού κινδύνου, γεγονός που ενισχύει τη διαφάνεια της διαδικασίας λήψης αποφάσεων.

Παράλληλα, η σύγκριση των κανόνων που παράγονται από τους δύο αλγορίθμους αναδεικνύει διαφορές στη μορφή και στη δομή τους. Ο αλγόριθμος PRISM παράγει ένα σύνολο ανεξάρτητων κανόνων οι οποίοι δημιουργούνται με διαδοχική εξειδίκευση των συνθηκών, ενώ ο CART παράγει κανόνες που προκύπτουν από τις διαδρομές ενός δέντρου αποφάσεων. Ως αποτέλεσμα, οι κανόνες του CART εμφανίζονται συχνά πιο ιεραρχικά δομημένοι, ενώ οι κανόνες του PRISM παρουσιάζουν πιο άμεση και απλοποιημένη μορφή.

Η συγκριτική ανάλυση δείχνει επίσης ότι, παρά τις διαφορετικές μεθοδολογικές προσεγγίσεις των δύο αλγορίθμων, σε αρκετές περιπτώσεις εντοπίζονται παρόμοια πρότυπα ταξινόμησης. Συγκεκριμένα, χαρακτηριστικά όπως η ηλικία, το εισόδημα και το ποσό του δανείου εμφανίζονται να διαδραματίζουν καθοριστικό ρόλο στη διαδικασία πρόβλεψης της αθέτησης. Για παράδειγμα, μεγαλύτερες ηλικιακές κατηγορίες συνδέονται συχνότερα με χαμηλότερο πιστωτικό κίνδυνο, ενώ ο συνδυασμός νεαρής ηλικίας και υψηλότερου ποσού δανείου τείνει να σχετίζεται με αυξημένη πιθανότητα αθέτησης.

Τέλος, τα αποτελέσματα της ανάλυσης δείχνουν ότι οι κανόνες που παράγονται από τα μοντέλα μπορούν να μετατραπούν αποτελεσματικά σε πίνακες απόφασης σύμφωνα με το πρότυπο DMN. Η μετατροπή αυτή επιτρέπει την αναπαράσταση της λογικής των μοντέλων σε μια τυποποιημένη και κατανοητή μορφή, η οποία μπορεί να αξιοποιηθεί σε επιχειρησιακά περιβάλλοντα και σε συστήματα υποστήριξης αποφάσεων.

Κεφάλαιο 9: Συμπεράσματα

Στο παρόν κεφάλαιο παρουσιάζονται συνοπτικά τα κύρια ευρήματα της πτυχιακής εργασίας. Αρχικά γίνεται μια σύντομη ανασκόπηση των προηγούμενων ενοτήτων, ενώ στη συνέχεια αναδεικνύεται η συμβολή της έρευνας, επισημαίνονται οι περιορισμοί της και διατυπώνονται προτάσεις για μελλοντική διερεύνηση του θέματος. Τέλος, καταλήγουμε στα βασικά συμπεράσματα της μελέτης.

9.1 Ανασκόπηση εργασίας

Η παρούσα πτυχιακή εργασία είχε ως κύριο αντικείμενο τη διερεύνηση της αξιοποίησης τεχνικών μηχανικής μάθησης για την αυτόματη εξαγωγή κανόνων από δεδομένα και τη μετατροπή τους σε μορφή συμβατή με πίνακες αποφάσεων βάσει του προτύπου DMN, με στόχο την υποστήριξη της λήψης επιχειρησιακών αποφάσεων.

Αρχικά, στο εισαγωγικό κεφάλαιο αναδείχθηκε η σημασία των πληροφοριακών συστημάτων στη λειτουργία των σύγχρονων οργανισμών, καθώς και ο κρίσιμος ρόλος των επιχειρησιακών κανόνων στη διαμόρφωση αποτελεσματικών διαδικασιών. Τονίστηκε ότι οι πίνακες αποφάσεων αποτελούν βασικό εργαλείο αναπαράστασης της επιχειρησιακής λογικής, ενώ επισημάνθηκαν οι περιορισμοί της χειροκίνητης δημιουργίας κανόνων, η οποία ενδέχεται να μην αξιοποιεί πλήρως τη γνώση που περιέχεται στα δεδομένα.

Στο πλαίσιο αυτό, η εργασία εστίασε στη δυνατότητα σύνδεσης της μηχανικής μάθησης με τα συστήματα διαχείρισης επιχειρησιακών διαδικασιών (BPM), με στόχο την αυτοματοποιημένη εξαγωγή κανόνων και την ενίσχυση της διαδικασίας λήψης αποφάσεων. Οι βασικοί στόχοι περιλάμβαναν τη μελέτη τεχνικών εξαγωγής κανόνων, τη μετατροπή των αποτελεσμάτων τους σε πίνακες αποφάσεων και τη σύγκριση διαφορετικών μεθόδων ως προς τα χαρακτηριστικά τους.

Στη συνέχεια, στο δεύτερο κεφάλαιο πραγματοποιήθηκε βιβλιογραφική ανασκόπηση, όπου παρουσιάστηκαν οι βασικές έννοιες που σχετίζονται με τη χρήση τεχνικών μηχανικής μάθησης σε περιβάλλοντα BPM, η σημασία των κανόνων απόφασης ως μέσο αναπαράστασης γνώσης και η χρήση πινάκων αποφάσεων στο πλαίσιο του προτύπου DMN. Παράλληλα, αναλύθηκε η έννοια της εξαγωγής κανόνων από δεδομένα και παρουσιάστηκαν οι βασικές κατηγορίες αλγορίθμων που χρησιμοποιούνται για τον σκοπό αυτό, με ιδιαίτερη έμφαση στους αλγορίθμους CART και PRISM.

Το τρίτο κεφάλαιο επικεντρώθηκε στη μοντελοποίηση επιχειρησιακών διαδικασιών και αποφάσεων μέσω των προτύπων BPMN και DMN. Αναδείχθηκε η σημασία του διαχωρισμού της ροής διαδικασιών από τη λογική των αποφάσεων, καθώς και τα πλεονεκτήματα της χρήσης της DMN για την τυποποιημένη και εκτελέσιμη αναπαράσταση επιχειρησιακών κανόνων. Παρουσιάστηκαν τα βασικά δομικά στοιχεία της DMN, όπως τα διαγράμματα απαιτήσεων απόφασης (DRD), οι πίνακες

αποφάσεων και οι boxed expressions, καθώς και η έννοια της υπηρεσίας απόφασης ως μέσο ενσωμάτωσης της λογικής σε πληροφοριακά συστήματα.

Στο τέταρτο κεφάλαιο παρουσιάστηκε η μέθοδος των δέντρων απόφασης, η οποία αποτελεί μία από τις βασικές και πιο διαδεδομένες τεχνικές μηχανικής μάθησης για προβλήματα ταξινόμησης. Αναλύθηκε η δομή των δέντρων, η διαδικασία εκπαίδευσής τους και ο τρόπος με τον οποίο πραγματοποιείται η διάσπαση των δεδομένων με βάση χαρακτηριστικά και κριτήρια βελτιστοποίησης. Επιπλέον, επισημάνθηκε η ιδιαίτερη σημασία των δέντρων απόφασης ως ερμηνεύσιμων μοντέλων, καθώς επιτρέπουν την εξαγωγή κανόνων της μορφής if-then μέσω των διαδρομών από τη ρίζα προς τα φύλλα. Η ιδιότητα αυτή τα καθιστά ιδιαίτερα κατάλληλα για εφαρμογές υποστήριξης αποφάσεων και για τη σύνδεση της μηχανικής μάθησης με επιχειρησιακά συστήματα.

Στο πέμπτο κεφάλαιο αναλύθηκε εκτενώς ο αλγόριθμος CART (Classification and Regression Trees), ως μία από τις πιο διαδεδομένες υλοποιήσεις δέντρων απόφασης. Παρουσιάστηκε η διαδικασία κατασκευής του μοντέλου, η οποία βασίζεται στην επαναληπτική διάσπαση των δεδομένων με στόχο τη δημιουργία ομοιογενών υποσυνόλων ως προς τη μεταβλητή στόχο. Ιδιαίτερη έμφαση δόθηκε στα κριτήρια επιλογής των χαρακτηριστικών και των σημείων διάσπασης, καθώς και στη δυαδική δομή των δέντρων που παράγει ο CART. Στη συνέχεια, αναλύθηκε ο τρόπος εξαγωγής κανόνων απόφασης από το δέντρο, όπου κάθε διαδρομή από τη ρίζα έως ένα φύλλο αντιστοιχεί σε έναν κανόνα της μορφής if-then. Τέλος, παρουσιάστηκε η διαδικασία μετατροπής των κανόνων αυτών σε πίνακες αποφάσεων σύμφωνα με το πρότυπο DMN, επιτρέποντας την ενσωμάτωσή τους σε επιχειρησιακά συστήματα.

Στο έκτο κεφάλαιο παρουσιάστηκε ο αλγόριθμος PRISM, ο οποίος ανήκει στην κατηγορία των αλγορίθμων επαγωγής κανόνων. Σε αντίθεση με τα δέντρα απόφασης, ο PRISM δεν δημιουργεί μια ιεραρχική δομή, αλλά παράγει κανόνες απευθείας από τα δεδομένα μέσω μιας επαναληπτικής διαδικασίας επιλογής συνθηκών που μεγιστοποιούν την ακρίβεια κάθε κανόνα. Αναλύθηκε ο τρόπος με τον οποίο κατασκευάζονται οι κανόνες για κάθε κατηγορία στόχο, καθώς και η διαδικασία κάλυψης των δεδομένων μέσω διαδοχικής δημιουργίας κανόνων. Ιδιαίτερη έμφαση δόθηκε στη μορφή και τα χαρακτηριστικά των παραγόμενων κανόνων, οι οποίοι είναι ανεξάρτητοι μεταξύ τους και άμεσα ερμηνεύσιμοι. Όπως και στην περίπτωση του CART, οι κανόνες που προέκυψαν μετατράπηκαν σε πίνακες αποφάσεων DMN.

Στο έβδομο κεφάλαιο πραγματοποιήθηκε η πειραματική αξιολόγηση των αλγορίθμων CART και PRISM σε ένα συνθετικό σύνολο δεδομένων που αφορά την έγκριση ή την απόρριψη ενός δανείου. Περιγράφηκε η δομή του συνόλου δεδομένων και η διαδικασία εφαρμογής των δύο αλγορίθμων για την εξαγωγή κανόνων απόφασης. Στη συνέχεια, οι κανόνες που προέκυψαν μετατράπηκαν σε πίνακες αποφάσεων DMN, προκειμένου να καταστεί δυνατή η σύγκριση της μορφής και της δομής τους. Μέσω της ανάλυσης αυτής εξετάστηκαν διαφορές στον αριθμό των κανόνων, στη σαφήνεια των συνθηκών και στον τρόπο κάλυψης των δεδομένων, αναδεικνύοντας τα πλεονεκτήματα και τις ιδιαιτερότητες κάθε μεθόδου σε ένα ελεγχόμενο περιβάλλον.

Στο όγδοο κεφάλαιο παρουσιάστηκε η εφαρμογή των δύο αλγορίθμων σε πραγματικό σύνολο δεδομένων που αφορά την πρόβλεψη αθέτησης δανείων. Αρχικά περιγράφηκε η διαδικασία προεπεξεργασίας των δεδομένων, η οποία περιλάμβανε καθαρισμό, επιλογή χαρακτηριστικών και κατάλληλη διαμόρφωση των μεταβλητών. Στη συνέχεια εφαρμόστηκαν οι αλγόριθμοι CART και PRISM για την εξαγωγή κανόνων ταξινόμησης, οι οποίοι μετατράπηκαν σε πίνακες αποφάσεων DMN. Τα αποτελέσματα αξιολογήθηκαν ως προς τη χρησιμότητά τους σε πραγματικό επιχειρησιακό πλαίσιο, λαμβάνοντας υπόψη τη σαφήνεια, την ερμηνευσιμότητα και τη δυνατότητα ενσωμάτωσης των κανόνων σε συστήματα λήψης αποφάσεων. Η ανάλυση αυτή ανέδειξε τις διαφορές των δύο προσεγγίσεων σε πραγματικές συνθήκες, καθώς και τις δυνατότητες αξιοποίησής τους για την υποστήριξη επιχειρησιακών αποφάσεων.

9.2 Συνεισφορά έρευνας

Η παρούσα εργασία συμβάλλει στη διερεύνηση της σύνδεσης μεταξύ τεχνικών μηχανικής μάθησης και συστημάτων επιχειρησιακών αποφάσεων, προτείνοντας ένα ολοκληρωμένο πλαίσιο για την εξαγωγή, αναπαράσταση και αξιοποίηση κανόνων από δεδομένα σε μορφή συμβατή με το πρότυπο DMN.

Μία από τις βασικές συνεισφορές της έρευνας είναι η ανάδειξη της δυνατότητας μετατροπής των αποτελεσμάτων μοντέλων μηχανικής μάθησης σε δομημένους και εκτελέσιμους πίνακες αποφάσεων. Η διαδικασία αυτή γεφυρώνει το χάσμα μεταξύ της ανάλυσης δεδομένων και της επιχειρησιακής εφαρμογής, επιτρέποντας την άμεση ενσωμάτωση της εξαγόμενης γνώσης σε πληροφοριακά συστήματα. Με τον τρόπο αυτό, αποδεικνύεται ότι τα δεδομένα μπορούν να αξιοποιηθούν όχι μόνο για πρόβλεψη, αλλά και για την παραγωγή κατανοητών και εφαρμόσιμων επιχειρησιακών κανόνων.

Παράλληλα, η χρήση του προτύπου DMN προσφέρει σημαντικά πλεονεκτήματα σε σχέση με την απλή υλοποίηση των κανόνων σε γλώσσες προγραμματισμού. Ενώ οι κανόνες που υλοποιούνται σε κώδικα είναι εκτελέσιμοι, παραμένουν στενά συνδεδεμένοι με την τεχνική υλοποίηση του συστήματος και η κατανόησή τους απαιτεί συνήθως γνώσεις προγραμματισμού. Αντίθετα, η DMN αποτελεί ένα διεθνώς αναγνωρισμένο πρότυπο αναπαράστασης αποφάσεων που επιτρέπει την περιγραφή των κανόνων με τρόπο κατανοητό τόσο από τεχνικούς όσο και από επιχειρησιακούς χρήστες. Επιπλέον, οι πίνακες αποφάσεων μπορούν να συντηρούνται και να τροποποιούνται ανεξάρτητα από τον πηγαίο κώδικα της εφαρμογής, διευκολύνοντας την προσαρμογή της επιχειρησιακής λογικής στις μεταβαλλόμενες απαιτήσεις των οργανισμών. Τέλος, η συμβατότητα της DMN με σύγχρονες πλατφόρμες BPM επιτρέπει την άμεση ενσωμάτωση και εκτέλεση των αποφάσεων στο πλαίσιο πραγματικών επιχειρησιακών διαδικασιών.

Ταυτόχρονα, η εργασία προσφέρει μια συγκριτική ανάλυση δύο διαφορετικών προσεγγίσεων εξαγωγής κανόνων, των αλγορίθμων CART και PRISM. Μέσα από την

πειραματική αξιολόγηση, αναδείχθηκαν ουσιαστικές διαφορές ως προς τη δομή, την ερμηνευσιμότητα και τη μορφή των παραγόμενων κανόνων. Συγκεκριμένα, διαπιστώθηκε ότι τα δέντρα απόφασης (CART) οδηγούν σε πιο συμπαγή και ιεραρχικά οργανωμένα μοντέλα παράγουν κανόνες με αριθμητική ακρίβεια, ενώ οι αλγόριθμοι επαγωγής κανόνων (PRISM) παράγουν πιο ανεξάρτητους και κατανοητούς κανόνες. Το εύρημα αυτό συμβάλλει στην κατανόηση του πότε κάθε προσέγγιση είναι καταλληλότερη, ανάλογα με τις απαιτήσεις της εκάστοτε εφαρμογής.

Μια ακόμη σημαντική συνεισφορά είναι η πρακτική εφαρμογή των παραπάνω μεθόδων τόσο σε συνθετικά όσο και σε πραγματικά δεδομένα. Μέσω της ανάλυσης αυτής επιβεβαιώθηκε ότι οι τεχνικές μηχανικής μάθησης μπορούν να αποδώσουν κανόνες που αντανakλούν ουσιαστικά πρότυπα των δεδομένων και μπορούν να αξιοποιηθούν σε πραγματικά επιχειρησιακά σενάρια, όπως η πρόβλεψη αθέτησης δανείων. Η εφαρμογή σε πραγματικό σύνολο δεδομένων ενισχύει τη χρηστικότητα και τη ρεαλιστικότητα των αποτελεσμάτων της μελέτης.

Σε επίπεδο γνώσης, η εργασία συμβάλλει στην κατανόηση του τρόπου με τον οποίο τεχνικές μηχανικής μάθησης μπορούν να συνδυαστούν με συστήματα επιχειρησιακών αποφάσεων και το πρότυπο DMN. Τα αποτελέσματα έδειξαν ότι οι κανόνες που εξάγονται από μοντέλα μηχανικής μάθησης μπορούν να μετατραπούν σε τυποποιημένες και εκτελέσιμους πίνακες αποφάσεων υποστηρίζοντας τη λήψη αποφάσεων βάσει δεδομένων. Με τον τρόπο αυτό μειώνεται η εξάρτηση από αποκλειστικά χειροκίνητες ή εμπειρικές προσεγγίσεις και ενισχύεται η αποτελεσματικότητα των επιχειρησιακών διαδικασιών.

9.3 Περιορισμοί έρευνας και μελλοντική κατεύθυνση

Παρά τη συμβολή της παρούσας εργασίας στη σύνδεση τεχνικών μηχανικής μάθησης με συστήματα επιχειρησιακών αποφάσεων, υπάρχουν ορισμένοι περιορισμοί που πρέπει να ληφθούν υπόψη και οι οποίοι μπορούν να αποτελέσουν αφετηρία για μελλοντική έρευνα.

Αρχικά, ένας βασικός περιορισμός αφορά το εύρος των αλγορίθμων που εξετάστηκαν. Η εργασία επικεντρώθηκε σε δύο συγκεκριμένες προσεγγίσεις εξαγωγής κανόνων, τον CART και τον PRISM. Αν και οι μέθοδοι αυτές είναι αντιπροσωπευτικές και ευρέως χρησιμοποιούμενες, δεν καλύπτουν το σύνολο των διαθέσιμων τεχνικών μηχανικής μάθησης. Υπάρχουν και άλλες προσεγγίσεις, όπως ensemble μέθοδοι ή πιο σύγχρονοι αλγόριθμοι, οι οποίες θα μπορούσαν να προσφέρουν διαφορετικά ή βελτιωμένα αποτελέσματα ως προς την ακρίβεια και τη μορφή των παραγόμενων κανόνων.

Ακόμη, δεν πραγματοποιήθηκε εκτενής ποσοτική αξιολόγηση των μοντέλων ως προς μετρικές απόδοσης, όπως η ακρίβεια, η ανάκληση ή άλλοι δείκτες αξιολόγησης, καθώς η έμφαση δόθηκε κυρίως στην ερμηνευσιμότητα και στη μορφή των κανόνων. Αν και αυτή η επιλογή είναι συμβατή με τον στόχο της εργασίας, η ενσωμάτωση

ποσοτικών μετρικών θα μπορούσε να προσφέρει μια πιο ολοκληρωμένη εικόνα της απόδοσης των αλγορίθμων.

Επιπλέον, η πειραματική αξιολόγηση δεν πραγματοποιήθηκε σε ιδιαίτερα μεγάλα και σύνθετα σύνολα δεδομένων με μεγάλο αριθμό χαρακτηριστικών. Σε τέτοιες περιπτώσεις, η αύξηση του πλήθους των χαρακτηριστικών μπορεί να οδηγήσει στην παραγωγή μεγαλύτερου αριθμού κανόνων και πιο σύνθετων πινάκων αποφάσεων, επηρεάζοντας την ερμηνευσιμότητα και τη διαχειρισιμότητά τους. Ωστόσο, ο περιορισμός αυτός θα μπορούσε να αντιμετωπιστεί με τεχνικές επιλογής χαρακτηριστικών (feature selection), οι οποίες επιτρέπουν τον εντοπισμό των πιο σημαντικών μεταβλητών και τη μείωση της πολυπλοκότητας των μοντέλων.

Όσον αφορά τη μελλοντική κατεύθυνση της έρευνας, προκύπτουν αρκετές ενδιαφέρουσες προοπτικές. Μία σημαντική επέκταση θα ήταν η διερεύνηση και άλλων τεχνικών μηχανικής μάθησης για την εξαγωγή κανόνων, καθώς και η σύγκρισή τους με τις μεθόδους που χρησιμοποιήθηκαν στην παρούσα εργασία. Παράλληλα, η ενσωμάτωση ensemble μεθόδων ή υβριδικών προσεγγίσεων θα μπορούσε να οδηγήσει σε πιο ακριβή και αξιόπιστα αποτελέσματα.

Ακόμη, μελλοντική έρευνα θα μπορούσε να εστιάσει στη διερεύνηση της εφαρμογής της προτεινόμενης προσέγγισης σε διαφορετικούς τομείς, όπως η υγεία, οι χρηματοοικονομικές υπηρεσίες ή η διαχείριση κινδύνου, προκειμένου να αξιολογηθεί η αποτελεσματικότητά της σε πραγματικές και πολύπλοκες συνθήκες. Η επέκταση αυτή θα συμβάλει στην καλύτερη κατανόηση των δυνατοτήτων και των περιορισμών της σύνδεσης μεταξύ μηχανικής μάθησης και επιχειρησιακών αποφάσεων.

Τέλος, μελλοντική έρευνα θα μπορούσε να εστιάσει στην εφαρμογή και αξιολόγηση της προτεινόμενης προσέγγισης σε μεγαλύτερα και πιο σύνθετα σύνολα δεδομένων. Η διερεύνηση αυτή θα επέτρεπε την αξιολόγηση της κλιμάκωσης της μεθοδολογίας σε περιπτώσεις με μεγάλο αριθμό χαρακτηριστικών και κανόνων, καθώς και τη μελέτη της επίδρασής τους στην ερμηνευσιμότητα και τη διαχειρισιμότητα των παραγόμενων πινάκων αποφάσεων. Η επέκταση αυτή θα συνέβαλλε στην καλύτερη κατανόηση των δυνατοτήτων και των περιορισμών της αξιοποίησης τεχνικών μηχανικής μάθησης για την αυτόματη παραγωγή επιχειρησιακών κανόνων και τη μετατροπή τους σε πίνακες αποφάσεων DMN.

Συνολικά, οι περιορισμοί της παρούσας εργασίας δεν αναιρούν τη συμβολή της, αλλά αναδεικνύουν πεδία περαιτέρω διερεύνησης, τα οποία μπορούν να οδηγήσουν σε πιο ολοκληρωμένες και αποδοτικές λύσεις στο μέλλον.

9.4 Σύνοψη

Η παρούσα πτυχιακή εργασία επικεντρώθηκε στη διερεύνηση της αξιοποίησης τεχνικών μηχανικής μάθησης για την εξαγωγή επιχειρησιακών κανόνων από δεδομένα και τη μετατροπή τους σε πίνακες αποφάσεων DMN. Μέσα από τη μελέτη

των αλγορίθμων CART και PRISM, καθώς και την εφαρμογή τους σε συνθετικά και πραγματικά σύνολα δεδομένων, αναδείχθηκε η δυνατότητα παραγωγής ερμηνεύσιμων και αξιοποιήσιμων κανόνων για την υποστήριξη της λήψης αποφάσεων.

Τα αποτελέσματα της εργασίας έδειξαν ότι διαφορετικές τεχνικές μηχανικής μάθησης οδηγούν σε διαφορετικές μορφές αναπαράστασης γνώσης, καθεμία με τα δικά της πλεονεκτήματα ως προς τη δομή, την ερμηνευσιμότητα και την πρακτική εφαρμογή. Παράλληλα, αναδείχθηκε ότι η μετατροπή των κανόνων σε πίνακες αποφάσεων DMN αποτελεί ένα αποτελεσματικό μέσο γεφύρωσης μεταξύ της ανάλυσης δεδομένων και των επιχειρησιακών συστημάτων.

Συνολικά, η εργασία ανέδειξε τη σημασία της αξιοποίησης τεχνικών μηχανικής μάθησης για τη διαμόρφωση τεκμηριωμένων και διαφανών αποφάσεων, συμβάλλοντας στη βελτίωση των επιχειρησιακών διαδικασιών. Η προτεινόμενη προσέγγιση συνδυάζει θεωρητικά και πρακτικά στοιχεία, προσφέροντας ένα χρήσιμο πλαίσιο για την ενσωμάτωση της μηχανικής μάθησης σε συστήματα λήψης αποφάσεων.

Κλείνοντας, η μελέτη αυτή επιβεβαιώνει ότι ο συνδυασμός μηχανικής μάθησης και DMN μπορεί να συμβάλει στη δημιουργία πιο διαφανών, τεκμηριωμένων και αποτελεσματικών συστημάτων λήψης αποφάσεων, ενώ παράλληλα αναδεικνύει ενδιαφέρουσες προοπτικές για περαιτέρω έρευνα και εφαρμογή σε πραγματικά επιχειρησιακά περιβάλλοντα.

BIBΛΙΟΓΡΑΦΙΑ

Almutairi, M.K. (2022) *Expressive and explainable rule-based classification*. PhD thesis, University of Reading.

Batoulis, K., Meyer, A., Bazhenova, E., Decker, G. and Weske, M. (2015) 'Extracting Decision Logic from Process Models', in *Proceedings of the 27th International Conference on Advanced Information Systems Engineering (CAiSE)*. Cham: Springer, pp. 349–366. https://doi.org/10.1007/978-3-319-19069-3_22

Breiman, L., Friedman, J.H., Olshen, R.A. and Stone, C.J. (1984) *Classification and Regression Trees*. New York: Wadsworth. <https://doi.org/10.1002/widm.8>

Cendrowska, J. (1987) 'PRISM: An algorithm for inducing modular rules', *International Journal of Man-Machine Studies*, 27(4), pp. 349–370. [https://doi.org/10.1016/S0020-7373\(87\)80003-2](https://doi.org/10.1016/S0020-7373(87)80003-2)

Dumas, M., La Rosa, M., Mendling, J. and Reijers, H.A. (2018) *Fundamentals of Business Process Management*. 2nd edn. Berlin: Springer. <https://doi.org/10.1007/978-3-662-56509-4>

Etinger, D., Simić, S.D. and Buljubašić, L. (2019) 'Automated decision-making with DMN: from decision trees to decision tables', in *Proceedings of the 42nd International Convention on Information and Communication Technology, Electronics and Microelectronics (MIPRO)*. IEEE. <https://doi.org/10.23919/MIPRO.2019.8756694>

Figl, K., Mendling, J., Tokdemir, G. and Vanthienen, J. (2021) *What we know and what we do not know about DMN*. <https://doi.org/10.18417/emisa.13.2>

Fürnkranz, J. (1999) 'Separate-and-Conquer Rule Learning', *Artificial Intelligence Review*, 13(1), pp. 3–54. <https://doi.org/10.1023/A:1006524209794>

Han, J., Kamber, M. and Pei, J. (2011) *Data Mining: Concepts and Techniques*. 3rd edn. Burlington: Morgan Kaufmann. <https://doi.org/10.1016/C2009-0-61819-5>

Kotsiantis, S.B. (2011) *Decision trees: a recent overview*, *Artificial Intelligence Review*, 39(4), pp. 261–283. <https://doi.org/10.1007/s10462-011-9272-4>

Laurson, U. and Maggi, F.M. (2017) *A Tool for the Analysis of DMN Decision Tables*. University of Tartu.

Lewis, R.J. (2000) *An Introduction to Classification and Regression Tree (CART) Analysis*. Harbor-UCLA Medical Center.

Marrella, A. (2019) 'What automated planning can do for business process management', *Business & Information Systems Engineering*, 61(1), pp. 81–88. https://doi.org/10.1007/978-3-319-74030-0_1

Object Management Group (OMG) (2011) *Business Process Model and Notation (BPMN), Version 2.0*.

Object Management Group (OMG) (2019) *Decision Model and Notation (DMN), Version 1.3*.

Quinlan, J.R. (1986) 'Induction of Decision Trees', *Machine Learning*, 1(1), pp. 81–106. <https://doi.org/10.1007/BF00116251>

Safavian, S.R. and Landgrebe, D. (1991) 'A survey of decision tree classifier methodology', *IEEE Transactions on Systems, Man, and Cybernetics*, 21(3), pp. 660–674. <https://doi.org/10.1109/21.97458>

van der Aalst, W.M.P. (2011) *Process Mining: Discovery, Conformance and Enhancement of Business Processes*. Berlin: Springer. <https://doi.org/10.1007/978-3-642-19345-3>

Weske, M. (2012) *Business Process Management: Concepts, Languages, Architectures*. 2nd edn. Berlin: Springer. <https://doi.org/10.1007/978-3-642-28616-2>